

第 3 章 非线性规划

3.1 基本概念

在现实世界的许多优化问题中，目标函数或约束条件往往呈现出非线性特征，这类问题无法用线性规划模型描述。以最小化形式的非线性规划问题为例，其数学模型为

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & \begin{cases} g_i(\mathbf{x}) \geq 0, \quad i = 1, 2, \dots, m \\ h_j(\mathbf{x}) = 0, \quad j = m + 1, m + 2, \dots, m + l \end{cases} \end{aligned} \quad (3.1)$$

其中, $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$ 为决策向量, $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 为目标函数, $g_i(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 为不等式约束函数, $h_j(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 为等式约束函数。对于迭代算法, 本章以 $\mathbf{x}^{(0)}$ 表示初始点, 由算法生成的迭代点序列为 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(k)}$, 简记为 $\{\mathbf{x}^{(k)}\}$ 。

3.1.1 最优解

与线性规划不同, 非线性规划问题可能存在多个最优解。根据最优解的性质, 可将其划分为局部最优解、严格局部最优解、全局最优解和严格全局最优解。

定义 3.1 给定 $\mathbf{x}^* \in \mathbb{R}^n$, 若存在 $\varepsilon > 0$, 使得对任意满足 $\|\mathbf{x} - \mathbf{x}^*\| \leq \varepsilon$ 的 $\mathbf{x}$ 都有 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, 则称 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的局部最优解, $f(\mathbf{x}^*)$ 为对应的局部最优值。进一步, 若对任意满足 $\|\mathbf{x} - \mathbf{x}^*\| \leq \varepsilon$ 且 $\mathbf{x} \neq \mathbf{x}^*$ 的 $\mathbf{x}$ 都有 $f(\mathbf{x}) > f(\mathbf{x}^*)$, 则称 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的严格局部最优解, $f(\mathbf{x}^*)$ 为对应的严格局部最优值。

针对图 3.1 中所示的一维函数 $f(x)$, 点 x_1, x_2, x_3 均为局部最优解, 其中 x_1, x_2 为严格局部最优解。

定义 3.2 给定 $\mathbf{x}^* \in \mathbb{R}^n$, 若对任意 $\mathbf{x}$ 都有 $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, 则称 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的全局最优解, $f(\mathbf{x}^*)$ 为对应的全局最优值。进一步, 若对任意 $\mathbf{x} \neq \mathbf{x}^*$ 都有 $f(\mathbf{x}) > f(\mathbf{x}^*)$, 则称 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的严格全局最优解, $f(\mathbf{x}^*)$ 为对应的严格全局最优值。

结合图 3.1 可知, x_2 不仅是全局最优解, 还是严格全局最优解。对于最大化形式的非线性规划问题, 仅须将定义中的不等号反向, 即可得到其对应最优解的概念。




图 3.1 非线性规划最优解

考虑二次型函数

$$\begin{aligned}
 f(\mathbf{x}) &= a_{11}x_1^2 + 2a_{12}x_1x_2 + \cdots + 2a_{1n}x_1x_n + a_{22}x_2^2 + 2a_{23}x_2x_3 + \cdots + a_{nn}x_n^2 \\
 &= \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j \\
 &= \mathbf{x}^T \mathbf{A} \mathbf{x}
 \end{aligned}$$

其中, $\mathbf{A}$ 为 $n \times n$ 对称矩阵, 即 $a_{ij} = a_{ji}$ 。显然, 一个二次型唯一确定一个对称矩阵 $\mathbf{A}$ 。反之, 一个对称矩阵 $\mathbf{A}$ 也唯一确定一个二次型。

定义 3.3 设 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$ 为实二次型。

- (1) **正定二次型** 若对任意 $\mathbf{x} \neq \mathbf{0}$, 恒有 $f(\mathbf{x}) > 0$ 。
- (2) **负定二次型** 若对任意 $\mathbf{x} \neq \mathbf{0}$, 恒有 $f(\mathbf{x}) < 0$ 。
- (3) **半正定二次型** 若对任意 $\mathbf{x} \neq \mathbf{0}$, 恒有 $f(\mathbf{x}) \geq 0$, 且对某些 $\mathbf{x} \neq \mathbf{0}$, 有 $f(\mathbf{x}) = 0$ 。
- (4) **半负定二次型** 若对任意 $\mathbf{x} \neq \mathbf{0}$, 恒有 $f(\mathbf{x}) \leq 0$, 且对某些 $\mathbf{x} \neq \mathbf{0}$, 有 $f(\mathbf{x}) = 0$ 。

若二次型 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 分别为正定、负定、半正定、半负定, 则其对应的对称矩阵 $\mathbf{A}$ 称为正定矩阵、负定矩阵、半正定矩阵、半负定矩阵。此外, 根据线性代数理论, 实二次型 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 正定的充分必要条件为其矩阵 $\mathbf{A}$ 的各阶顺序主子式均大于零。

定义 3.4 设 $f(\mathbf{x})$ 在 $\mathbf{x}^{(0)}$ 处二阶连续可微, 则二阶泰勒 (Taylor) 展开式为

$$f(\mathbf{x}) = f(\mathbf{x}^{(0)}) + \nabla f(\mathbf{x}^{(0)})^T (\mathbf{x} - \mathbf{x}^{(0)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(0)})^T \nabla^2 f(\hat{\mathbf{x}}) (\mathbf{x} - \mathbf{x}^{(0)})$$

其中, $\hat{\mathbf{x}} = \mathbf{x}^{(0)} + \alpha(\mathbf{x} - \mathbf{x}^{(0)})$, $\alpha \in (0, 1)$ 。

将 $\hat{\mathbf{x}}$ 代入, 上式可转化为

$$\begin{aligned}
 f(\mathbf{x}) &= f(\mathbf{x}^{(0)}) + \nabla f(\mathbf{x}^{(0)})^T (\mathbf{x} - \mathbf{x}^{(0)}) + \\
 &\quad \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(0)})^T \nabla^2 f(\mathbf{x}^{(0)}) (\mathbf{x} - \mathbf{x}^{(0)}) + o(\|\mathbf{x} - \mathbf{x}^{(0)}\|^2)
 \end{aligned}$$

当 $\mathbf{x} \rightarrow \mathbf{x}^{(0)}$ 时, 可知 $o(\|\mathbf{x} - \mathbf{x}^{(0)}\|^2)$ 是 $\|\mathbf{x} - \mathbf{x}^{(0)}\|^2$ 的高阶无穷小, 即

$$\lim_{\mathbf{x} \rightarrow \mathbf{x}^{(0)}} \frac{o(\|\mathbf{x} - \mathbf{x}^{(0)}\|^2)}{\|\mathbf{x} - \mathbf{x}^{(0)}\|^2} = 0$$

3.1.2 最优性理论

定理 3.1 设 $f(\mathbf{x})$ 可微, 若 $\mathbf{x}^*$ 为局部最优解, 则必有

$$\nabla f(\mathbf{x}^*) = \left(\frac{\partial f(\mathbf{x}^*)}{\partial x_1}, \frac{\partial f(\mathbf{x}^*)}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x}^*)}{\partial x_n} \right)^T = \mathbf{0}$$

此时, 称 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的稳定点或驻点。

证明. 因 $f(\mathbf{x})$ 可微且 $\mathbf{x}^*$ 为其局部最优解, 对任意方向 $\mathbf{d} \in \mathbb{R}^n$ 及充分小的 $\lambda > 0$, 由一阶泰勒展开式可得

$$\begin{aligned} f(\mathbf{x}) &= f(\mathbf{x}^* + \lambda \mathbf{d}) \\ &= f(\mathbf{x}^*) + \lambda \nabla f(\mathbf{x}^*)^T \mathbf{d} + o(\lambda \|\mathbf{d}\|) \\ &\geq f(\mathbf{x}^*) \end{aligned}$$

不等式两边同时减去 $f(\mathbf{x}^*)$, 整理得

$$\nabla f(\mathbf{x}^*)^T \mathbf{d} + \frac{o(\lambda \|\mathbf{d}\|)}{\lambda} \geq 0$$

当 $\lambda \rightarrow 0$ 时, 有 $\nabla f(\mathbf{x}^*)^T \mathbf{d} \geq 0$. 又因该式对任意 $\mathbf{d}$ 成立, 可推得 $\nabla f(\mathbf{x}^*) = \mathbf{0}$. $\square$

定理 3.1 称为无约束优化问题的一阶必要条件. 容易验证, 函数 $f(\mathbf{x})$ 在点 $\mathbf{x}$ 处的梯度 $\nabla f(\mathbf{x})$ 必与函数过该点的等值面正交. 梯度方向为函数值上升最快的方向, 负梯度方向为函数值下降最快的方向。

定理 3.2 设 $f(\mathbf{x})$ 二阶连续可微, 若 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 且海森 (Hessian) 矩阵

$$\nabla^2 f(\mathbf{x}^*) = \begin{pmatrix} \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_3} & \dots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2^2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_3} & \dots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_3} & \dots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n^2} \end{pmatrix}$$

正定, 则 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的严格局部最优解。

证明. 先证 $\mathbf{x}^*$ 为局部最优解, 采用反证法. 设 $\mathbf{x}^*$ 不是局部最优解, 则存在点列 $\{\mathbf{x}^{(k)}\} \rightarrow \mathbf{x}^*$, 使得

$$f(\mathbf{x}^{(k)}) < f(\mathbf{x}^*)$$

考虑二阶泰勒展开式, 有

$$\begin{aligned} f(\mathbf{x}^{(k)}) &= f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x}^{(k)} - \mathbf{x}^*) + \\ &\quad \frac{1}{2} (\mathbf{x}^{(k)} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x}^{(k)} - \mathbf{x}^*) + o(\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2) \\ &< f(\mathbf{x}^*) \end{aligned}$$

记 $\mathbf{d}^{(k)} = \frac{\mathbf{x}^{(k)} - \mathbf{x}^*}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|}$, 上式整理得

$$(\mathbf{d}^{(k)})^T \nabla^2 f(\mathbf{x}^*) \mathbf{d}^{(k)} + \frac{2o(\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2)}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2} < 0$$

因 $\|\mathbf{d}^{(k)}\| = 1$, 故存在收敛子列 $\{\mathbf{d}^{(k_j)}\} \rightarrow \mathbf{d}$. 对上述不等式沿 $\{k_j\}$ 取极限, 得

$$\mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} \leq 0$$

与 $\nabla^2 f(\mathbf{x}^*)$ 正定相矛盾, 因此 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的局部最优解。

接下来证明 $\mathbf{x}^*$ 为严格局部最优解, 仍采用反证法。设 $\mathbf{x}^*$ 不是严格局部极小点, 则存在点列 $\{\mathbf{x}^{(k)}\} \rightarrow \mathbf{x}^*$, 使得

$$f(\mathbf{x}^{(k)}) = f(\mathbf{x}^*)$$

由定理 3.1 可知, $\nabla f(\mathbf{x}^{(k)}) = \mathbf{0}$ 。考虑梯度函数的一阶泰勒展开式, 有

$$\nabla f(\mathbf{x}^{(k)}) = \nabla f(\mathbf{x}^*) + \nabla^2 f(\mathbf{x}^*)(\mathbf{x}^{(k)} - \mathbf{x}^*) + o(\mathbf{x}^{(k)} - \mathbf{x}^*)$$

注意, $\nabla f(\mathbf{x}^*)$ 与 $\nabla f(\mathbf{x}^{(k)})$ 均为 $\mathbf{0}$ 。令 $\mathbf{d}^{(k)} = \frac{\mathbf{x}^{(k)} - \mathbf{x}^*}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|}$, 上式整理得

$$\nabla^2 f(\mathbf{x}^*) \mathbf{d}^{(k)} + \frac{o(\mathbf{x}^{(k)} - \mathbf{x}^*)}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|} = \mathbf{0}$$

同理, 存在收敛子列 $\{\mathbf{d}^{(k_j)}\} \rightarrow \mathbf{d}$, 取极限得

$$\nabla^2 f(\mathbf{x}^*) \mathbf{d} = \mathbf{0}$$

与 $\nabla^2 f(\mathbf{x}^*)$ 正定矛盾, 故 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的严格局部最优解。 $\square$

定理 3.3 设 $f(\mathbf{x})$ 二阶连续可微, 若 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的局部最优解, 则 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 且海森矩阵

$$\nabla^2 f(\mathbf{x}^*) = \begin{pmatrix} \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_3} & \cdots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2^2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_3} & \cdots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_2} & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n \partial x_3} & \cdots & \frac{\partial^2 f(\mathbf{x}^*)}{\partial x_n^2} \end{pmatrix}$$

半正定。

证明. 由定理 3.1 可知, $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 。考虑二阶泰勒展开式, 有

$$\begin{aligned} f(\mathbf{x}^* + \lambda \mathbf{d}) &= f(\mathbf{x}^*) + \frac{1}{2} \lambda^2 \mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} + o(\lambda^2 \|\mathbf{d}\|^2) \\ &\geq f(\mathbf{x}^*) \end{aligned}$$

上式整理得

$$\mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} + \frac{2o(\lambda^2 \|\mathbf{d}\|^2)}{\lambda^2} \geq 0$$

令 $\lambda \rightarrow 0$, 则

$$\mathbf{d}^T \nabla^2 f(\mathbf{x}^*) \mathbf{d} \geq 0$$

即海森矩阵 $\nabla^2 f(\mathbf{x}^*)$ 半正定。 □

例 3.1 判断函数 $f(\mathbf{x}) = x_1^2 - x_2^2$ 是否存在最优解。

解. 根据无约束优化问题的一阶必要性定理 3.1, 函数的梯度为

$$\frac{\partial f(\mathbf{x})}{\partial x_1} = 2x_1, \quad \frac{\partial f(\mathbf{x})}{\partial x_2} = -2x_2$$

令 $f(\mathbf{x}) = 0$, 即 $2x_1 = 0, -2x_2 = 0$, 解得稳定点 $\mathbf{x} = (x_1, x_2)^T = (0, 0)^T$ 。

利用二阶充分性定理 3.2 判断该稳定点是否为极值点。海森矩阵为

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

该海森矩阵为不定矩阵, 因此 $\mathbf{x} = (0, 0)^T$ 不是最优解。

3.1.3 下降迭代算法

对于大多数非线性规划问题, 其解析解往往难以直接求得。通常采用下降迭代算法, 从初始点 $\mathbf{x}^{(0)}$ 出发, 依照既定规则, 先找一个比 $\mathbf{x}^{(0)}$ 更好的点 $\mathbf{x}^{(1)}$, 再找比 $\mathbf{x}^{(1)}$ 更好的点 $\mathbf{x}^{(2)}$, 如此继续下去, 生成迭代序列 $\{\mathbf{x}^{(k)}\}$ 。

定义 3.5 若迭代序列 $\{\mathbf{x}^{(k)}\}$ 存在极限点 $\mathbf{x}^*$, 即

$$\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| = 0$$

则称序列 $\{\mathbf{x}^{(k)}\}$ 收敛于 $\mathbf{x}^*$ 。

定义 3.6 对于最小化问题, 若迭代序列 $\{\mathbf{x}^{(k)}\}$ 对应的目标函数值 $\{f(\mathbf{x}^{(k)})\}$ 严格单调递减, 即

$$f(\mathbf{x}^{(0)}) > f(\mathbf{x}^{(1)}) > \cdots > f(\mathbf{x}^{(k)}) > \cdots$$

则将具备该性质的迭代算法称为下降迭代算法。

下降迭代算法通常包括以下四步。

- (1) **选取初始点** 选定初始迭代点 $\mathbf{x}^{(0)}$, 令 $k = 0$ 。

- (2) **确定搜索方向** 若当前迭代 $\mathbf{x}^{(k)}$ 并非问题的最优解, 则从 $\mathbf{x}^{(k)}$ 出发确定搜索方向 $\mathbf{p}^{(k)}$, 要求沿该方向能够找到使目标函数值下降的点。对于约束优化问题, 根据所选用算法的不同, 还须保证新迭代点为可行点。
- (3) **确定步长** 沿搜索方向 $\mathbf{p}^{(k)}$ 迭代, 得到 $\mathbf{x}^{(k+1)}$ 。即在射线 $\mathbf{x} = \mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}$ ($\lambda \geq 0$) 上, 选取步长 λ_k , 确定下一个迭代点

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$$

且满足函数值下降条件

$$f(\mathbf{x}^{(k+1)}) = f(\mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}) < f(\mathbf{x}^{(k)})$$

- (4) **判断终止准则** 若迭代点 $\mathbf{x}^{(k+1)}$ 满足终止准则, 则迭代停止。否则, 返回步骤 (2) 继续迭代。

在下降迭代算法中, 搜索方向 $\mathbf{p}^{(k)}$ 和步长 λ_k 的选择至关重要, 不同的选择策略对应不同的优化算法, 如梯度法、牛顿法、共轭梯度法等。为提升算法的收敛速度, 通常选取步长 λ_k 使得目标函数沿搜索方向的下降最大, 即求解如下一维优化问题

$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

该过程称为最优一维搜索或线搜索, 由此确定的步长称为最优步长。

定理 3.4 设 $f(\mathbf{x})$ 连续可微, 迭代点 $\mathbf{x}^{(k+1)}$ 由如下规则生成

$$\begin{cases} \lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \end{cases}$$

则有

$$\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(k)} = 0$$

即采用最优步长迭代时, 搜索方向 $\mathbf{p}^{(k)}$ 与目标函数的梯度方向正交。

由于迭代不可能无限进行, 需要设定合适的终止准则来判断当前迭代点是否已足够接近最优解, 常见的有以下三种。

- (1) **绝对误差准则** 当相邻两次迭代点或目标函数值的距离变化小于预设精度时, 迭代停止, 即

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \varepsilon_1, |f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| \leq \varepsilon_2$$

- (2) **相对误差准则** 当相邻两次迭代点或目标函数值的相对变化小于预设精度时, 迭代停止, 即

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k)}\|} \leq \varepsilon_3, \frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{|f(\mathbf{x}^{(k)})|} \leq \varepsilon_4$$

(3) **梯度准则** 当目标函数梯度的范数小于预设精度时, 迭代停止, 即

$$\|\nabla f(\mathbf{x}^{(k)})\| \leq \varepsilon_5$$

其中, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_5 > 0$ 为允许误差, 代表求解精度。

下降迭代算法的收敛性与收敛速度, 由目标函数的性质及搜索方向和步长选取的策略共同决定。后续章节将深入探讨几种经典的下降算法及其性能。

3.2 凸优化介绍

3.2.1 凸函数

定义 3.7 设 $f(\mathbf{x})$ 为凸集 Ω 上的函数, 若对任意两点 $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$, 以及任意 $\alpha \in (0, 1)$, 有

$$f(\alpha \mathbf{x}_1 + (1 - \alpha) \mathbf{x}_2) \leq \alpha f(\mathbf{x}_1) + (1 - \alpha) f(\mathbf{x}_2)$$

则称 $f(\mathbf{x})$ 为定义在 Ω 上的凸函数。

定义 3.8 若对任意两点 $\mathbf{x}_1 \neq \mathbf{x}_2 \in \Omega$, 以及任意 $\alpha \in (0, 1)$, 恒有

$$f(\alpha \mathbf{x}_1 + (1 - \alpha) \mathbf{x}_2) < \alpha f(\mathbf{x}_1) + (1 - \alpha) f(\mathbf{x}_2)$$

则称 $f(\mathbf{x})$ 为定义在 Ω 上的严格凸函数。

若 $-f(\mathbf{x})$ 为凸函数或严格凸函数, 则称 $f(\mathbf{x})$ 为凹函数或严格凹函数。根据定义可判断, 图 3.2(a) 为凸函数, 图 3.2(b) 为凹函数。从几何视角来看, 凸函数的图像位于其定义域内任意两点所连线的下方。




图 3.2 凸、凹函数的几何意义

命题 3.1 设 $f(\mathbf{x})$ 为凸集 Ω 上的凸函数, 则对任意 $\beta \geq 0$, 函数 $\beta f(\mathbf{x})$ 仍为 Ω 上的凸函数。

命题 3.2 设 $f_1(\mathbf{x})$ 和 $f_2(\mathbf{x})$ 均为凸集 Ω 上的凸函数, 则其和函数 $f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x})$ 仍为 Ω 上的凸函数。

3.2.2 判定定理

定理 3.5 设 $f(\mathbf{x})$ 为凸集 Ω 上的一阶可微函数, 则 $f(\mathbf{x})$ 为 Ω 上的凸函数的充分必要条件是, 对任意 $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$, 恒有

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T(\mathbf{x}_2 - \mathbf{x}_1)$$

证明. 根据凸函数的定义, 对任意 $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$, 以及任意 $\alpha \in (0, 1)$, 有

$$f(\alpha \mathbf{x}_2 + (1 - \alpha)\mathbf{x}_1) \leq \alpha f(\mathbf{x}_2) + (1 - \alpha)f(\mathbf{x}_1) \quad (3.2)$$

将左端函数进行一阶泰勒展开, 得到

$$\begin{aligned} f(\alpha \mathbf{x}_2 + (1 - \alpha)\mathbf{x}_1) &= f(\mathbf{x}_1 + \alpha(\mathbf{x}_2 - \mathbf{x}_1)) \\ &= f(\mathbf{x}_1) + \alpha \nabla f(\mathbf{x}_1)^T(\mathbf{x}_2 - \mathbf{x}_1) + o(\alpha \|\mathbf{x}_2 - \mathbf{x}_1\|) \end{aligned} \quad (3.3)$$

将式 (3.3) 代入式 (3.2), 移项化简后两边同时除以 α , 可知

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T(\mathbf{x}_2 - \mathbf{x}_1) + \frac{o(\alpha \|\mathbf{x}_2 - \mathbf{x}_1\|)}{\alpha}$$

令 $\alpha \rightarrow 0$, 即得

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T(\mathbf{x}_2 - \mathbf{x}_1)$$

另外, 对任意 $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$, 以及 $\alpha \in (0, 1)$, 记

$$\mathbf{x} = \alpha \mathbf{x}_1 + (1 - \alpha)\mathbf{x}_2$$

由条件得到

$$\begin{aligned} f(\mathbf{x}_1) &\geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{x}_1 - \mathbf{x}) \\ &= f(\mathbf{x}) + (1 - \alpha)\nabla f(\mathbf{x})^T(\mathbf{x}_1 - \mathbf{x}_2) \end{aligned} \quad (3.4)$$

以及

$$f(\mathbf{x}_2) \geq f(\mathbf{x}) + \alpha \nabla f(\mathbf{x})^T(\mathbf{x}_2 - \mathbf{x}_1) \quad (3.5)$$

将式 (3.4) 乘以 α 、式 (3.5) 乘以 $(1 - \alpha)$ 后相加, 得到

$$f(\mathbf{x}) \leq \alpha f(\mathbf{x}_1) + (1 - \alpha)f(\mathbf{x}_2)$$

由定义可知, $f(\mathbf{x})$ 为凸函数。 □

该定理表明, 凸函数在其定义域内任意一点处的切平面位于函数图像的下方, 即该切平面为函数图像的支撑超平面。

定理 3.6 设 $f(\mathbf{x})$ 为凸集 Ω 上的二阶可微函数, 则 $f(\mathbf{x})$ 为 Ω 上的凸函数的充分必要条件是, 对任意 $\mathbf{x} \in \Omega$, 恒有 $\nabla^2 f(\mathbf{x})$ 半正定。

证明. 根据定理 3.5, 对任意 $\mathbf{x} \in \Omega$, 方向 $\mathbf{d} \in \mathbb{R}^n$, 以及任意 $\alpha \in (0, 1)$, 有

$$f(\mathbf{x} + \alpha \mathbf{d}) \geq f(\mathbf{x}) + \alpha \nabla f(\mathbf{x})^T \mathbf{d} \quad (3.6)$$

将左端函数作二阶泰勒展开, 得到

$$f(\mathbf{x} + \alpha \mathbf{d}) = f(\mathbf{x}) + \alpha \nabla f(\mathbf{x})^T \mathbf{d} + \frac{1}{2} \alpha^2 \mathbf{d}^T \nabla^2 f(\mathbf{x}) \mathbf{d} + o(\alpha^2 \|\mathbf{d}\|^2) \quad (3.7)$$

比较式 (3.6) 和 (3.7) 并整理得

$$\mathbf{d}^T \nabla^2 f(\mathbf{x}) \mathbf{d} \geq \frac{2o(\alpha^2 \|\mathbf{d}\|^2)}{\alpha^2}$$

令 $\alpha \rightarrow 0$, 右端趋于 0, 因此 $\mathbf{d}^T \nabla^2 f(\mathbf{x}) \mathbf{d} \geq 0$, 即海森矩阵 $\nabla^2 f(\mathbf{x})$ 半正定。

另外, 任取 $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$, 由二阶中值定理, 存在 $\alpha \in (0, 1)$, 记

$$\mathbf{x} = \mathbf{x}_1 + \alpha(\mathbf{x}_2 - \mathbf{x}_1) = \alpha \mathbf{x}_2 + (1 - \alpha) \mathbf{x}_1$$

使得

$$f(\mathbf{x}_2) = f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1) + \frac{1}{2} (\mathbf{x}_2 - \mathbf{x}_1)^T \nabla^2 f(\mathbf{x}) (\mathbf{x}_2 - \mathbf{x}_1)$$

由于 $\nabla^2 f(\mathbf{x})$ 半正定, 有

$$\frac{1}{2} (\mathbf{x}_2 - \mathbf{x}_1)^T \nabla^2 f(\mathbf{x}) (\mathbf{x}_2 - \mathbf{x}_1) \geq 0$$

从而

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1)$$

上式表明定理 3.5 成立, 因此 $f(\mathbf{x})$ 为凸函数。 $\square$

进一步, 若对任意 $\mathbf{x} \in \Omega$ 恒有 $\nabla^2 f(\mathbf{x}) > \mathbf{0}$, 即海森矩阵正定, 则 $f(\mathbf{x})$ 为凸集 Ω 上的严格凸函数。此处证明略, 读者可参考上述证明自行推导。

例 3.2 试证明: 函数 $f(\mathbf{x}) = x_1^2 + x_2^2$ 为严格凸函数。

证明. 任取 $\mathbf{x}_1 = (a_1, b_1)^T$, $\mathbf{x}_2 = (a_2, b_2)^T$, 有

$$f(\mathbf{x}_1) = a_1^2 + b_1^2, \quad f(\mathbf{x}_2) = a_2^2 + b_2^2$$

计算得到梯度为

$$\nabla f(\mathbf{x}_1) = (2a_1, 2b_1)^T$$

将上述表达式代入严格凸函数的一阶条件, 须验证

$$a_2^2 + b_2^2 > a_1^2 + b_1^2 + (2a_1, 2b_1) \begin{pmatrix} a_2 - a_1 \\ b_2 - b_1 \end{pmatrix}$$

整理化简后, 等价于

$$(a_2 - a_1)^2 + (b_2 - b_1)^2 > 0$$

由于 $\mathbf{x}_1 \neq \mathbf{x}_2$, 上式恒成立, 因此 $f(\mathbf{x})$ 为严格凸函数。

接下来尝试利用二阶条件证明。梯度为

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_1} = 2\mathbf{x}_1, \quad \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_2} = 2\mathbf{x}_2$$

进一步, 计算有

$$\frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x}_1^2} = 2, \quad \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x}_2^2} = 2, \quad \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x}_1 \partial \mathbf{x}_2} = \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x}_2 \partial \mathbf{x}_1} = 0$$

由此, 可得函数的海森矩阵为

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

因海森矩阵 $\nabla^2 f(\mathbf{x})$ 正定, 根据二阶条件判定, $f(\mathbf{x})$ 为严格凸函数。 $\square$

命题 3.3 设 $f(\mathbf{x})$ 为凸集 Ω 上的可微凸函数, 若存在 $\mathbf{x}^* \in \Omega$, 使得对任意 $\mathbf{x} \in \Omega$, 都有

$$\nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \geq 0$$

则 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的全局最优解。

证明. 采用反证法。设 $f(\mathbf{x})$ 为凸函数, 且 $\mathbf{x}^*$ 不是全局最优解, 则存在 $\mathbf{x} \in \Omega$, 使 $f(\mathbf{x}) < f(\mathbf{x}^*)$ 。对于任意 $\alpha \in (0, 1)$, 根据凸函数的定义可得

$$f(\alpha \mathbf{x} + (1 - \alpha)\mathbf{x}^*) \leq \alpha f(\mathbf{x}) + (1 - \alpha)f(\mathbf{x}^*) < f(\mathbf{x}^*)$$

当 $\alpha \rightarrow 0$ 时, 有 $\alpha \mathbf{x} + (1 - \alpha)\mathbf{x}^* \rightarrow \mathbf{x}^*$ 。该结论与 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的局部最优解相矛盾, 因此 $\mathbf{x}^*$ 必为 $f(\mathbf{x})$ 的全局最优解。 $\square$

通过图 3.3 不难看出, $\nabla f(\mathbf{x}^*)$ 与 $\mathbf{x} - \mathbf{x}^*$ 的夹角为锐角。

3.2.3 凸规划

对于非线性规划问题 (3.1), 若目标函数 $f(\mathbf{x})$ 为凸函数, 不等式约束函数 $g_i(\mathbf{x}) \geq 0$ 为凹函数, 等式约束函数 $h_j(\mathbf{x}) = 0$ 为线性函数, 则称该规划问题为凸规划。由上一节可知, 若存在可行解, 则可行域为凸集。若存在最优解, 则最优解集为凸集。

命题 3.4 凸规划问题的任意局部最优解必为全局最优解。进一步, 若目标函数为严格凸函数且最优解存在, 则最优解必唯一。




图 3.3 凸函数性质

例 3.3 试判断下述非线性规划问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) = x_1^2 + x_2^2 - 4x_1 + 4 \\ \text{s.t.} \quad & \begin{cases} g_1(\mathbf{x}) = x_1 - x_2 + 2 \geq 0 \\ g_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \geq 0 \\ g_3(\mathbf{x}) = x_1 \geq 0 \\ g_4(\mathbf{x}) = x_2 \geq 0 \end{cases} \end{aligned}$$

为凸规划。

解. 首先分析目标函数, 其海森矩阵为

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

该矩阵正定, 因此 $f(\mathbf{x})$ 为严格凸函数。其次分析约束函数, 即

$$g_1(\mathbf{x}) = x_1 - x_2 + 2, \quad g_3(\mathbf{x}) = x_1, \quad g_4(\mathbf{x}) = x_2$$

均为线性函数, 既是凸函数也是凹函数。对于 $g_2(\mathbf{x}) = -x_1^2 + x_2 - 1$, 其海森矩阵为

$$\nabla^2 g_2(\mathbf{x}) = \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix}$$

该矩阵半负定, 因此 $g_2(\mathbf{x})$ 为凹函数。因此, 该非线性规划问题的目标函数为凸函数, 不等式约束函数为凹函数, 等式约束函数为线性函数, 满足凸规划定义。

3.3 无约束优化问题

考虑无约束优化问题

$$\min \quad f(\mathbf{x}) \quad (3.8)$$

其中, 决策变量 $\mathbf{x} \in \mathbb{R}^n$ 。依据目标函数的一阶与二阶微分信息, 可分别构造梯度法与牛顿 (Newton) 法两类经典的下降迭代算法。

3.3.1 梯度法

梯度法, 又称最速下降法, 是求解无约束优化问题 (3.8) 的基本算法。在下降迭代算法框架中, 梯度法选取迭代点的负梯度方向作为搜索方向, 即 $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$ 。每一步迭代均沿该方向执行一维搜索, 寻找使目标函数下降最多的步长, 逐渐逼近问题的最优解。当 $\nabla f(\mathbf{x}^{(k)}) \neq \mathbf{0}$ 时, $\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)}) < 0$, 因此负梯度方向为下降方向。梯度法的具体迭代步骤如下:

- (1) 选定初始点 $\mathbf{x}^{(0)}$, 令 $k = 0$ 。
- (2) 计算目标函数值 $f(\mathbf{x}^{(k)})$ 和梯度 $\nabla f(\mathbf{x}^{(k)})$, 若 $\|\nabla f(\mathbf{x}^{(k)})\|^2 \leq \varepsilon$, 则停止迭代, 得到最优解 $\mathbf{x}^{(k)}$ 和最优值 $f(\mathbf{x}^{(k)})$ 。否则, 进入下一步。
- (3) 执行一维搜索, 通过下式求解最优步长

$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)}))$$

更新迭代点 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \lambda_k \nabla f(\mathbf{x}^{(k)})$ 。返回步骤 (2) 继续迭代。

当目标函数二阶连续可微时, 可推导出最优步长的解析公式。具体来说, 将 $f(\mathbf{x})$ 在迭代点 $\mathbf{x}^{(k)}$ 处沿负梯度方向作二阶泰勒展开, 得到

$$\begin{aligned} f(\mathbf{x}^{(k)} - \lambda \nabla f(\mathbf{x}^{(k)})) &\approx f(\mathbf{x}^{(k)}) - \nabla f(\mathbf{x}^{(k)})^T \lambda \nabla f(\mathbf{x}^{(k)}) + \\ &\quad \frac{1}{2} \lambda \nabla f(\mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) \lambda \nabla f(\mathbf{x}^{(k)}) \end{aligned}$$

关于步长 λ 求一阶微分并令其等于 0, 即可得到如下最优步长的计算公式

$$\lambda_k = \frac{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}{\nabla f(\mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})}$$

梯度法具有全局收敛性, 且为线性收敛。实际数值计算中, 梯度法在开始迭代时效果较好, 能够快速逼近最优解。但当迭代点接近最优解时, 算法会出现明显的迭代扭摆现象, 收敛速度显著放缓, 如图 3.4 所示。




图 3.4 梯度法迭代路径

下面对此现象给出简要分析。设 $f(\mathbf{x})$ 在点 $\mathbf{x}$ 处沿方向 $\mathbf{d}$ 的一阶泰勒展开式为

$$f(\mathbf{x} + \lambda \mathbf{d}) = f(\mathbf{x}) + \lambda \nabla f(\mathbf{x})^T \mathbf{d} + o(\lambda \|\mathbf{d}\|)$$

当迭代点 $\mathbf{x}$ 距离最优解 $\mathbf{x}^*$ 较远时, 线性项远大于高阶无穷小项, 算法具有较快的下降速度。当迭代点趋近于 $\mathbf{x}^*$ 时, 此时线性项与高阶无穷小项同阶, 线性近似的有效性显著降低, 进而导致迭代出现扭摆现象。

例 3.4 用梯度法求解无约束优化问题

$$\min f(\mathbf{x}) = x_1^2 + 5x_2^2$$

的最优解。取允许误差 $\varepsilon = 0.7$ 。

解. 目标函数的梯度与海森矩阵分别为

$$\nabla f(\mathbf{x}) = \begin{pmatrix} 2x_1 \\ 10x_2 \end{pmatrix}, \quad \nabla^2 f(\mathbf{x}) = \begin{pmatrix} 2 & 0 \\ 0 & 10 \end{pmatrix}$$

选取初始点 $\mathbf{x}^{(0)} = (2, 1)^T$, 计算得

$$\nabla f(\mathbf{x}^{(0)}) = \begin{pmatrix} 4 \\ 10 \end{pmatrix}, \quad \|\nabla f(\mathbf{x}^{(0)})\|^2 = 116 > \varepsilon$$

不满足收敛条件, 须继续迭代。由于 $f(\mathbf{x})$ 为二次函数, 当 $k = 0$ 时, 代入计算最优步长 (保留小数点后两位数字)

$$\lambda_0 = \frac{\begin{pmatrix} 4 & 10 \end{pmatrix} \begin{pmatrix} 4 \\ 10 \end{pmatrix}}{\begin{pmatrix} 4 & 10 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 10 \end{pmatrix} \begin{pmatrix} 4 \\ 10 \end{pmatrix}} = \frac{116}{1\ 032} \approx 0.11$$

更新迭代点

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - \lambda_0 \nabla f(\mathbf{x}^{(0)}) \approx \begin{pmatrix} 1.55 \\ -0.12 \end{pmatrix}$$

此时, 计算得

$$\nabla f(\mathbf{x}^{(1)}) \approx \begin{pmatrix} 3.10 \\ -1.20 \end{pmatrix}, \quad \|\nabla f(\mathbf{x}^{(1)})\|^2 \approx 11.05 > \varepsilon$$

仍未满足终止条件, 故继续按上述过程迭代, 直至满足

$$\|\nabla f(\mathbf{x}^{(k)})\|^2 \leq \varepsilon$$

时停止迭代。理论上, 该函数为严格凸二次函数, 其全局最优解为 $\mathbf{x}^* = (0, 0)^T$ 。

3.3.2 牛顿法

牛顿法通过有效利用目标函数的二阶微分信息, 收敛速度显著优于梯度法。考虑二次函数

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{B}^T \mathbf{x} + c$$

其中 $\mathbf{A}$ 为 $n \times n$ 对称正定矩阵, $c \in \mathbb{R}$ 。设该函数的最优解为 $\mathbf{x}^*$, 由无约束优化问题的一阶必要条件可得

$$\nabla f(\mathbf{x}^*) = \mathbf{A}\mathbf{x}^* + \mathbf{B} = \mathbf{0} \quad (3.9)$$

整理得 $\mathbf{A}\mathbf{x}^* = -\mathbf{B}$ 。另外, 任取初始点 $\mathbf{x}^{(0)} \in \mathbb{R}^n$, 函数在该点的一阶微分为 $\nabla f(\mathbf{x}^{(0)}) = \mathbf{A}\mathbf{x}^{(0)} + \mathbf{B}$ 。将式 (3.9) 代入上式消去 $\mathbf{B}$ 得

$$\nabla f(\mathbf{x}^{(0)}) = \mathbf{A}\mathbf{x}^{(0)} - \mathbf{A}\mathbf{x}^*$$

进一步整理, 求出最优解为 $\mathbf{x}^* = \mathbf{x}^{(0)} - \mathbf{A}^{-1}\nabla f(\mathbf{x}^{(0)})$ 。这表明, 关于对称正定二次函数, 从任意初始点 $\mathbf{x}^{(0)}$ 出发, 沿牛顿方向 $-\mathbf{A}^{-1}\nabla f(\mathbf{x}^{(0)})$ 、以 1 为步长迭代一步, 即可到达函数的最优解, 这就是牛顿法的魅力所在。

例 3.5 用牛顿法求解无约束优化问题

$$f(\mathbf{x}) = x_1^2 + 5x_2^2$$

的最优解。取允许误差 $\varepsilon = 0.7$ 。

解. 选取初始点 $\mathbf{x}^{(0)} = (2, 1)^T$, 梯度为

$$\nabla f(\mathbf{x}^{(0)}) = (4, 10)^T$$

二次函数 $f(\mathbf{x})$ 对应的海森矩阵及其逆矩阵分别为

$$\mathbf{A} = \begin{pmatrix} 2 & 0 \\ 0 & 10 \end{pmatrix}, \quad \mathbf{A}^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1/10 \end{pmatrix}$$

根据牛顿迭代公式计算

$$\begin{aligned} \mathbf{x}^* &= \mathbf{x}^{(0)} - \mathbf{A}^{-1}\nabla f(\mathbf{x}^{(0)}) \\ &= \begin{pmatrix} 2 \\ 1 \end{pmatrix} - \begin{pmatrix} 1/2 & 0 \\ 0 & 1/10 \end{pmatrix} \begin{pmatrix} 4 \\ 10 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \end{aligned}$$

经验证, $\mathbf{x}^*$ 为函数 $f(\mathbf{x})$ 的最优解。

考虑一般 n 元实函数 $f(\mathbf{x})$, 若该函数二阶连续可微, 则在 $\mathbf{x}^{(k)}$ 处二阶泰勒展开对其进行逼近, 即

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \nabla^2 f(\mathbf{x}^{(k)}) \Delta \mathbf{x}$$

其中, $\Delta \mathbf{x} = \mathbf{x} - \mathbf{x}^{(k)}$ 。逼近函数的最优解应满足无约束优化问题的一阶必要条件, 因此

$$\nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) \Delta \mathbf{x} = \mathbf{0}$$

若海森矩阵 $\nabla^2 f(\mathbf{x}^{(k)})$ 可逆, 对上式进行整理, 解得

$$\mathbf{x} = \mathbf{x}^{(k)} - (\nabla^2 f(\mathbf{x}^{(k)}))^{-1} \nabla f(\mathbf{x}^{(k)})$$

为求 $f(\mathbf{x})$ 的最优解, 选取方向 $-(\nabla^2 f(\mathbf{x}^{(k)}))^{-1} \nabla f(\mathbf{x}^{(k)})$ 作为搜索方向 (牛顿方向), 并按照以下迭代公式进行计算

$$\begin{cases} \mathbf{p}^{(k)} = -(\nabla^2 f(\mathbf{x}^{(k)}))^{-1} \nabla f(\mathbf{x}^{(k)}) \\ \lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \end{cases}$$

这就是阻尼牛顿法, 也称为广义牛顿法, 可用于求解非正定二次函数的最优化问题。

3.4 约束优化问题

考虑约束优化问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) \geq 0, \quad i = 1, 2, \dots, m \end{aligned} \quad (3.10)$$

上述问题直接求解往往存在较大的难度, 一种自然的思路是将其转化为无约束问题来求解。其中, 最具代表性的是罚函数法与障碍函数法。

3.4.1 罚函数法

罚函数法, 又称外点罚, 通过对违反约束的点施加足够大的惩罚, 使其对应的目标函数值显著增大, 从而引导迭代点逐步向可行域收敛, 最终逼近原约束问题的最优解。为度量约束 $g_i(\mathbf{x}) \geq 0$ 的违反程度, 考虑惩罚函数

$$\phi(t) = \begin{cases} 0, & \text{当 } t \geq 0 \\ t^2, & \text{当 } t < 0 \end{cases}$$

将问题 (3.10) 中的不等式约束转化为 $\phi(g_i(\mathbf{x}))$, 其等价于 $(\min(0, g_i(\mathbf{x})))^2$ 。取充分大的 $M > 0$, 约束优化问题 (3.10) 可转化为无约束形式

$$P(\mathbf{x}, M) = f(\mathbf{x}) + M \sum_{i=1}^m (\min(0, g_i(\mathbf{x})))^2$$

不难验证, 当迭代点不满足约束条件时, 由于 M 取值极大, 惩罚项会显著增大。这类方法称为罚函数法, M 称为罚因子。具体迭代步骤如下:

- (1) 选取初始罚因子 $M_1 > 0$, 允许误差 $\varepsilon > 0$, 令 $k = 1$ 。

(2) 求解无约束优化问题

$$\mathbf{x}^{(k)} = \arg \min_{\mathbf{x}} P(\mathbf{x}, M)$$

(3) 若存在某一不等式约束, 有 $-g_i(\mathbf{x}^{(k)}) > \varepsilon$ 则更新罚因子 $M_{k+1} > M_k$, 返回步骤 (2)。否则, 停止迭代。

例 3.6 用罚函数法求解约束优化问题

$$\begin{aligned} \min \quad & f(x) = \left(x - \frac{1}{2}\right)^2 \\ \text{s.t.} \quad & x \leq 0 \end{aligned}$$

的最优解。

解. 首先将约束 $x \leq 0$ 改写为

$$g(x) = -x \geq 0$$

取充分大的 $M > 0$, 构造罚函数

$$\begin{aligned} P(x, M) &= f(x) + M(\min(0, g(x)))^2 \\ &= \left(x - \frac{1}{2}\right)^2 + M(\min(0, -x))^2 \end{aligned}$$

当 $x > 0$ 时, $\min(0, -x) = -x$, 于是

$$P(x, M) = \left(x - \frac{1}{2}\right)^2 + Mx^2$$

对固定罚因子 M , 计算一阶微分并令其为零, 有

$$\frac{\partial P(x, M)}{\partial x} = 2\left(x - \frac{1}{2}\right) + 2Mx = 0$$

求解可得罚函数的最优解为

$$x(M) = \frac{1}{2(1+M)}$$

如图 3.5 所示, 当 $M = 0$ 时, $x(M) = \frac{1}{2}$; 当 $M = 1$ 时, $x(M) = \frac{1}{4}$; 当 $M = 10$ 时, $x(M) = \frac{1}{22}$; 当 $M \rightarrow \infty$ 时, $x(M) \rightarrow 0$ 。由此可见, 随着罚因子 M 的增大, 罚函数问题的最小点逐步逼近原优化问题的最优解, 这正是罚函数法的基本思想。

3.4.2 障碍函数法

与罚函数法允许迭代点位于可行域外不同, 障碍函数法要求整个迭代过程始终保持在可行域内部, 因此又称为内点罚。考虑约束优化问题 (3.10), 构造倒数型障碍函数 $\frac{1}{g_i(\mathbf{x})}$ 与对数型障碍函数 $\ln g_i(\mathbf{x})$, 得到无约束优化问题

$$P(\mathbf{x}, r_k) = f(\mathbf{x}) + r_k \sum_{i=1}^m \frac{1}{g_i(\mathbf{x})}$$




图 3.5 罚函数法求解

与

$$P(\mathbf{x}, r_k) = f(\mathbf{x}) - r_k \sum_{i=1}^m \ln g_i(\mathbf{x})$$

其中, $r_k > 0$ 称为障碍因子, $P(\mathbf{x}, r_k)$ 称为障碍函数。具体迭代步骤如下:

- (1) 选取初始障碍因子 $r_1 > 0$, 允许误差 $\varepsilon > 0$, 令 $k = 1$ 。
- (2) 构建障碍函数, 障碍项可根据求解需求选择倒数型函数或对数型函数。
- (3) 求解无约束优化问题

$$\mathbf{x}^{(k)} = \arg \min_{\mathbf{x}} P(\mathbf{x}, r_k)$$

- (4) 若采用倒数型障碍项, 检查是否满足

$$r_k \sum_{i=1}^m \frac{1}{g_i(\mathbf{x}^{(k)})} \leq \varepsilon$$

若采用对数型障碍项, 检查是否满足

$$\left| r_k \sum_{i=1}^m \ln(g_i(\mathbf{x}^{(k)})) \right| \leq \varepsilon$$

若满足, 得到原约束优化问题的最优解 $\mathbf{x}^{(k)}$, 停止迭代。否则, 取 $r_{k+1} < r_k$, 返回步骤 (3)。

例 3.7 用障碍函数法求解约束优化问题

$$\begin{aligned} \min \quad & f(x) = x - 2 \\ \text{s.t.} \quad & x \geq 0 \end{aligned}$$

的最优解。

解. 采用倒数型障碍项, 构造障碍函数

$$P(x, r_k) = x - 2 + \frac{r_k}{x}$$

对于固定的障碍因子 r_k ，求一阶微分并令其为零，有

$$\frac{\partial P(x, r_k)}{\partial x} = 1 - \frac{r_k}{x^2} = 0$$

求解可得 $x = \pm\sqrt{r_k}$ 。结合约束条件 $x \geq 0$ ，舍去负根，得障碍问题的最优解为

$$x = \sqrt{r_k}$$

图 3.6 展示了 $r_k = 1, 0.1, 0.01$ 时障碍函数的图像。由此可见，随着障碍因子 $r_k \rightarrow 0$ ，障碍函数的极小点逐渐逼近原问题的最优解。




图 3.6 障碍函数求解

3.5 应用案例

3.5.1 问题描述

电力经济调度是现代电力系统运行管理中的重要问题，其基本任务是在满足系统负荷需求及机组运行约束的条件下，合理分配各发电机组的输出功率，使总发电成本达到最小。由于发电机组的燃料成本函数通常可表示为输出功率的二次函数，因此电力经济调度问题属于典型的非线性规划范畴。

例 3.8 某区域电力系统包含三台并网发电机组，须共同承担系统总负荷 300 MW。各发电机组发电成本函数及出力上、下限如表 3.1 所示。试确定各发电机组最优出力 x_1, x_2, x_3 ，使发电总成本最小。

表 3.1 发电机组技术参数

机组编号	成本函数	出力下限/MW	出力上限/MW
1	$0.01x_1^2 + 2x_1 + 100$	50	200
2	$0.015x_2^2 + 1.5x_2 + 120$	30	150
3	$0.02x_3^2 + x_3 + 80$	20	100

3.5.2 模型建立

设三台发电机组的出力为决策变量 $\mathbf{x} = (x_1, x_2, x_3)^T$ ，发电总成本为各发电机组成本之和，则目标函数为

$$\min f(\mathbf{x}) = 0.01x_1^2 + 0.015x_2^2 + 0.02x_3^2 + 2x_1 + 1.5x_2 + x_3 + 300$$

系统运行须满足功率平衡约束，即 $x_1 + x_2 + x_3 = 300$ 。同时，各发电机组出力须满足技术上、下限约束

$$50 \leq x_1 \leq 200, 30 \leq x_2 \leq 150, 20 \leq x_3 \leq 100$$

综上，该电力经济调度问题可表示为非线性规划模型

$$\begin{aligned} \min f(\mathbf{x}) &= 0.01x_1^2 + 0.015x_2^2 + 0.02x_3^2 + 2x_1 + 1.5x_2 + x_3 + 300 \\ \text{s.t.} \quad &\begin{cases} x_1 + x_2 + x_3 = 300 \\ 50 \leq x_1 \leq 200 \\ 30 \leq x_2 \leq 150 \\ 20 \leq x_3 \leq 100 \end{cases} \end{aligned}$$

3.5.3 算法设计

采用罚函数法进行求解。将不等式约束表示为

$$\begin{aligned} g_1 &= x_1 - 50, g_2 = 200 - x_1, g_3 = x_2 - 30 \\ g_4 &= 150 - x_2, g_5 = x_3 - 20, g_6 = 100 - x_3 \end{aligned}$$

构造二次罚函数

$$P(\mathbf{x}, M) = f(\mathbf{x}) + M \left((x_1 + x_2 + x_3 - 300)^2 + \sum_{i=1}^6 (\max(0, -g_i(\mathbf{x})))^2 \right)$$

计算梯度，可得

$$\nabla P(\mathbf{x}, M) = \nabla f(\mathbf{x}) + 2M \left((x_1 + x_2 + x_3 - 300) + \sum_{i=1}^6 \max(0, -g_i(\mathbf{x})) \nabla(-g_i(\mathbf{x})) \right)$$

其中

$$\nabla f(\mathbf{x}) = (0.02x_1 + 2, 0.03x_2 + 1.5, 0.04x_3 + 1)^T$$

选取初始点 $\mathbf{x}^{(0)} = (100, 100, 100)^T$ ，给定初始罚因子 $M_0 = 1$ 、放大系数 $\beta = 5$ 、迭代步长 $\alpha = 0.01$ ，以及收敛精度 $\epsilon = 10^{-4}$ 。迭代过程如表 3.2 所示。

表 3.2 罚函数法迭代过程

迭代	罚因子	x_1 / MW	x_2 / MW	x_3 / MW	总成本/元
0	1	100.00	100.00	100.00	1 200.00
1	5	119.03	96.02	84.51	1 189.43
2	25	119.19	96.13	84.60	1 190.96
3	125	119.22	96.15	84.61	1 191.27
4	625	119.23	96.15	84.61	1 191.33
5	3 125	119.23	96.15	84.62	1 191.34

随着罚因子不断增大，迭代点逐步趋近可行域，同时目标函数单调下降并趋于稳定。算法最终收敛至最优解 $\mathbf{x}^* = (119.23, 96.15, 84.62)^T$ ，对应的最优值为 $f(\mathbf{x}^*) = 1\,191.34$ 。

3.5.4 结果分析

为验证最优解的可行性与合理性，现对约束条件逐一进行检验。首先，考虑功率平衡约束，有 $119.23 + 96.15 + 84.62 = 300$ 。可见其满足系统总负荷需求。进一步考查各发电机组的出力约束，可以得到

$$50 \leq 119.23 \leq 200, \quad 30 \leq 96.15 \leq 150, \quad 20 \leq 84.62 \leq 100$$

因此，该解满足所有等式约束与不等式约束，为原问题的最优解。需要说明的是，罚函数法的收敛速度与罚因子的更新策略密切相关，读者可分别取 $\beta = 1, 10$ 进行数值分析。此外，表 3.3 给出了几种经典非线性规划算法的主要特点。

表 3.3 几种经典非线性规划算法对比

方法	优点	缺点
梯度法	简单易实现	收敛速度慢
牛顿法	收敛速度快	须计算海森矩阵
罚函数法	无须可行初始点	须调整罚因子
障碍函数法	数值稳定性好	须可行初始点