



上海大学

SHANGHAI UNIVERSITY

本科毕业论文（设计）

UNDERGRADUATE THESIS (PROJECT)

题 目	面向具身操作的视觉-语言-动作 模型研究
学 院	机电工程与自动化
专 业	自动化
学 号	22121204
学生姓名	曹佳豪
指导教师	修贤超
起讫日期	2025.12.29 ~ 2026.5.22



姓 名: 曹佳豪

学号: 22121204

论文题目: 面向具身操作的视觉-语言-动作模型研究

原创性声明

本人声明: 所呈交的论文是本人在指导教师指导下进行的研究工作。除了文中特别加以标注和致谢的地方外, 论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签名: _____ 日期: _____

本论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定。即: 学校有权保留论文及送交论文复印件, 允许论文被查阅和借阅; 学校可以公布论文的全部或部分内容。

(保密的论文在解密后应遵守此规定)

签名: _____ 指导教师签名: _____ 日期: _____



上海大学

SHANGHAI UNIVERSITY

本科毕业论文（设计）

UNDERGRADUATE THESIS (PROJECT)

面向具身操作的视觉-语言-动作
模型研究

学 院	机电工程与自动化
专 业	自动化
学 号	22121204
学生姓名	曹佳豪
指导教师	修贤超
起讫日期	2025.12.29 ~ 2026.5.22

摘 要

近年来, 具身智能作为人工智能系统与物理环境交互的重要方向, 逐渐受到学术界和产业界的关注。传统机器人控制系统多采用模块化设计, 通常将视觉感知、任务规划和底层控制分别实现, 容易出现感知结果与任务目标衔接不紧、语言指令难以直接落实到具体动作, 以及系统在新场景下适应能力不足等问题。视觉-语言-动作 (Vision-Language-Action, VLA) 模型将自然语言指令、视觉观测和机器人动作统一建模, 为机器人端到端控制提供了新的实现思路。然而, 现有 VLA 模型在真实部署中仍面临两个主要问题: 一是离散动作建模容易带来推理延迟和动作不连续, 影响高频控制任务的执行稳定性; 二是大规模模型对显存和算力要求较高, 难以直接部署到低成本桌面机械臂等轻量化硬件平台。围绕上述问题, 本文以面向具身操作的 VLA 模型为研究对象, 分析其连续动作生成机制, 并开展本地微调训练与实机部署验证。具体研究内容如下:

- (1) 针对离散化动作生成在复杂物理操作中可能造成的控制延迟和动作不平滑问题, 本文分析了连续标准化流 (Continuous Normalizing Flow, CNF) 与流匹配 (Flow Matching, FM) 的理论基础, 说明其在连续动作分布建模中的作用。在此基础上, 本文对 π_0 与 SmolVLA 模型的网络结构、动作专家网络、注意力机制和动作块生成方式进行了对比, 分析二者在模型规模、动作连续性、推理效率和部署条件方面的差异。通过对层跳过、交替注意力和异步推理调度等方法的讨论, 进一步说明轻量化 VLA 模型如何在有限算力条件下降低推理开销, 并提高机器人连续控制任务中的动作平滑性。
- (2) 针对算力受限条件下 VLA 模型部署困难的问题, 本文基于本地采集的多模态遥操作数据集, 采用低秩适配 (Low-Rank Adaptation, LoRA) 方法对模型进行参数高效微调, 使模型能够适应本地实验环境和目标物体。随后, 基于 SO-101 六自由度桌面机械臂, 完成了模型推理输出与机械臂控制接口之间的连接, 构建了从语言指令输入、视觉观测获取、动作推理到机械臂执行的闭环系统。通过对橘子、香蕉和樱桃三类水果进行实机抓取测试, 验证了系统在简单桌面操作任务中的执行能力。实验结果表明, 经过本地微调后的模型能够根据给定的自然语言指令识别目标物体, 并驱动机械臂完成相应抓取动作, 说明该方法在低成本机械臂平台上的部署具有一定可行性。

关键词: 具身智能; 视觉-语言-动作模型; 流匹配; LeRobot 框架; 低秩适配

ABSTRACT

In recent years, embodied intelligence has gradually attracted attention from both academia and industry as an important direction for enabling artificial intelligence systems to interact with the physical environment. Traditional robot control systems usually adopt a modular design, in which visual perception, task planning, and low-level control are implemented separately. This design may lead to weak coupling between perception results and task objectives, indirect mapping from language instructions to concrete actions, and limited adaptability in new scenarios. Vision-Language-Action (VLA) models provide a new approach for end-to-end robot control by jointly modeling natural language instructions, visual observations, and robot actions. However, existing VLA models still face two main challenges in real-world deployment. First, discrete action modeling may introduce inference latency and action discontinuity, which affects the execution stability of high-frequency control tasks. Second, large-scale models require considerable memory and computational resources, making them difficult to deploy directly on lightweight hardware platforms such as low-cost desktop robotic arms. To address these issues, this thesis focuses on VLA models for embodied manipulation, analyzes their continuous action generation mechanisms, and conducts local fine-tuning and real-robot deployment verification. The main research contents are as follows:

- (1) To address the control latency and unsmooth motion that may be caused by discretized action generation in complex physical manipulation tasks, this thesis analyzes the theoretical foundations of Continuous Normalizing Flow (CNF) and Flow Matching (FM), and explains their roles in continuous action distribution modeling. On this basis, the network structures, action expert modules, attention mechanisms, and action chunk generation methods of π_0 and SmolVLA are compared. Their differences in model scale, action continuity, inference efficiency, and deployment conditions are further analyzed. By discussing layer skipping, alternating attention, and asynchronous inference scheduling, this thesis explains how lightweight VLA models can reduce inference overhead under limited computational resources and improve motion smoothness in continuous robot control tasks.
- (2) To address the deployment challenges of VLA models under limited computational resources, this thesis adopts Low-Rank Adaptation (LoRA) for parameter-efficient fine-tuning based on a locally collected multimodal teleoperation dataset, so that the model

can better adapt to the local experimental environment and target objects. Then, based on the SO-101 six-degree-of-freedom desktop robotic arm, the connection between model inference outputs and the robotic arm control interface is completed, and a closed-loop system is constructed from language instruction input, visual observation acquisition, action inference, to robotic arm execution. Real-robot grasping tests on three types of fruits, including oranges, bananas, and cherries, are conducted to verify the execution capability of the system in simple desktop manipulation tasks. The experimental results show that the locally fine-tuned model can identify target objects according to given natural language instructions and drive the robotic arm to complete corresponding grasping actions, indicating that the proposed method has certain feasibility for deployment on low-cost robotic arm platforms.

Keywords: Embodied Intelligence; Vision-Language-Action Model; Flow Matching; LeRobot Framework; Low-Rank Adaptation

目 录

摘 要	I
ABSTRACT	II
第一章 绪论	1
1.1 课题背景及研究意义	1
1.2 国内外研究现状	3
1.2.1 传统机器人策略学习方法	3
1.2.2 视觉-语言-动作模型的发展趋势	4
1.3 主要内容与结构安排	7
第二章 具身操作模型的基础	9
2.1 具身操作的理论基础	9
2.1.1 具身智能与离身智能	9
2.1.2 感知—认知—行动闭环	10
2.1.3 具身操作任务的技术要求	11
2.2 多模态建模基础	12
2.2.1 Transformer 注意力机制	12
2.2.2 动作表征及解码方式	14
2.3 本章小结	15
第三章 π_0 和 SmolVLA 模型分析	16
3.1 流匹配动作生成方法	16
3.1.1 连续标准化流和边际向量场	16
3.1.2 条件流匹配推导	17
3.1.3 最优传输路径	18
3.2 π_0 模型结构	19
3.2.1 视觉语言基座和状态映射	20
3.2.2 注意力掩码和采样策略	20
3.2.3 硬件对齐和训练策略	22
3.3 SmolVLA 模型结构	22
3.3.1 感知编码及特征压缩	23
3.3.2 动作专家注意力设计	24
3.3.3 异步推理调度	25

3.4	模型复杂度和部署对比	26
3.5	本章小结	27
第四章	系统训练和实机验证	28
4.1	实验环境和数据采集	28
4.1.1	计算环境和框架配置	28
4.1.2	SO-101 机械臂平台	29
4.1.3	LeRobot 数据流和控制调度	30
4.1.4	遥操作数据采集	31
4.1.5	数据封装和时序对齐	32
4.2	模型微调和训练记录	33
4.2.1	LoRA 微调方法	33
4.2.2	训练过程和权重保存	34
4.2.3	训练曲线分析	35
4.3	LIBERO 仿真测试	37
4.3.1	仿真平台和任务建模	37
4.3.2	环境初始化和权重加载	38
4.3.3	仿真结果和分析	38
4.4	实机部署和抓取测试	39
4.4.1	逆运动学和通信接口	39
4.4.2	实机抓取结果和误差分析	40
4.5	本章小结	42
第五章	总结与展望	43
5.1	总结	43
5.2	展望	44
插图索引		46
表格索引		47
参考文献		48
致 谢		51

第一章 绪论

1.1 课题背景及研究意义

近年来,人工智能技术正在从以文本、图像和语音处理为主的离身智能,逐步走向与物理世界直接交互的具身智能。所谓具身智能,是指智能体不仅能够在数据空间中进行模式识别和语义推理,还能够依托机器人、移动平台或仿真体等载体,在真实或虚拟环境中形成“感知—认知—决策—执行—反馈”的闭环。与传统人工智能主要依赖静态数据集学习不同,具身智能强调智能体与环境之间的持续交互,强调动作对环境的改变以及环境反馈对后续决策的影响。因此,具身智能被认为是人工智能从“理解世界”迈向“改造世界”的关键方向^[1-8]。国内外关于大模型驱动具身智能的研究进一步指出,机器人形态、智能制造和多模态智能体正在成为该方向的重要落点^[9-16]。近期综述还从具身大模型、仿生机器人与计算机视觉未来趋势等角度扩展了这一研究脉络^[17,18]。如图 1.1 所示,具身智能系统通过感知、决策与执行形成持续闭环。




图 1.1 具身智能系统的“感知-决策-执行”闭环交互逻辑图

在具身智能的众多研究对象中,机器人操作任务具有典型代表性。机械臂需要在复杂环境中识别目标物体,理解任务意图,规划运动路径,并通过末端执行器完成抓取、放置、推拉、装配等物理操作。这类任务看似简单,实则同时包含视觉感知、语言理解、空间推理、运动学约束和接触动力学等多个层面的困难。例如,对于桌面抓取任务,机器人不仅要判断目标物体的位置,还要根据物体的几何形状、摆放姿态、材质和周围障碍物选择合适的抓取方式。若任务以自然语言形式给出,系统还必须将“抓取橘子”“拿起香蕉”等语义指令与视觉画面中的具体对象对齐,进

而转换为底层电机可执行的动作序列。

传统机器人操作系统通常采用模块化架构。系统被划分为视觉检测、位姿估计、任务规划、轨迹规划和底层控制等模块，每个模块由不同算法独立完成，再通过人工设计的接口串联起来。这种结构在结构化工业场景中具有较好的可解释性和稳定性，但在开放环境下存在明显不足。首先，模块之间的信息传递常常依赖有限的中间表示，例如边界框、关键点或目标位姿，这会造成语义信息和上下文信息的损失。其次，不同模块的优化目标并不完全一致，感知模块追求识别准确率，规划模块追求几何可达性，控制模块追求轨迹稳定性，系统整体很难形成统一的任务目标。最后，模块化系统对场景变化较为敏感，一旦目标类别、光照条件、物体摆放方式或任务语言发生变化，就需要重新设计规则或重新训练局部模型，工程维护成本较高。传统机器人操作方法在结构化任务中仍具有重要价值，相关机器人技能学习、操作模型和神经网络控制研究为后续端到端策略学习奠定了基础^[19-21]。

随着大语言模型和视觉语言模型的快速发展，人工智能系统在语义理解、多模态对齐和开放集泛化方面取得了显著进展。以 Transformer^[22] 为核心的基础模型能够在大规模数据上学习统一表示，并通过上下文建模获得较强的泛化能力。这一技术趋势为机器人操作系统带来了新的研究范式，即视觉-语言-动作模型 (Vision-Language-Action, VLA)^[23-27]。VLA 模型尝试将自然语言指令、视觉观测和机器人动作统一到同一建模框架中，使机器人能够直接根据图像和文本输入预测可执行动作，从而减少人工设计的中间模块和规则。对于具身操作任务而言，VLA 模型的价值不仅在于提升识别能力，更在于把高层语义意图与底层连续控制建立直接联系。如图 1.2 所示，端到端 VLA 模型将传统模块化链路压缩为统一的多模态动作生成框架。




图 1.2 传统模块化机器人系统与端到端 VLA 模型架构对比图

本课题以面向具身操作的视觉-语言-动作模型为研究对象，关注其底层生成机

理、轻量化部署方式以及真实机械臂系统中的工程实现。选择这一方向具有明确的理论意义和应用价值。从理论层面看，VLA 模型涉及多模态表示学习、动作生成、流匹配、模仿学习和机器人控制等交叉问题，能够帮助理解大模型如何从互联网语义知识迁移到物理操作任务。从工程层面看，桌面机械臂和开源具身框架的成熟降低了实验门槛，使研究者能够在有限硬件条件下验证端到端具身模型的真实可用性。若能在低成本平台上打通从模型推理到机械臂执行的闭环，将为教育、科研、轻工业自动化和家庭服务等场景提供有益参考。

1.2 国内外研究现状

1.2.1 传统机器人策略学习方法

在 VLA 模型兴起之前，机器人操作主要依赖传统感知规划控制方法、强化学习和模仿学习。传统方法通常先利用视觉算法检测目标物体，再进行位姿估计和路径规划，最后由控制器驱动机械臂执行。这类方法在工业自动化中应用广泛，适合目标明确、环境结构稳定、物体形态规则的场景^[19-21]。其优点是系统结构清晰、可调试性强、安全边界容易设置；不足之处在于各模块之间依赖人工设计的接口，语言语义、视觉感知和底层动作之间难以形成统一表示。当目标类别、光照条件、物体摆放方式或任务语言发生变化时，系统往往需要重新设计规则或调整局部算法，工程维护成本较高。相关机器人操作技能学习、视觉表征和多模态感知研究也反映了这一局限^[7,28]。

强化学习为机器人操作提供了通过试错获得策略的思路。智能体在环境中执行动作，根据奖励信号优化策略，从而学习抓取、推拉或避障等行为。该方法能够在一定程度上减少人工规则设计，但真实机器人强化学习通常面临样本效率低、奖励设计困难、试错成本高和安全风险大等问题。仿真环境可以缓解数据采集成本，但仿真到现实之间仍存在动力学差异、视觉差异和接触模型误差，导致策略迁移效果不稳定^[19,20,29,30]。

模仿学习通过专家演示数据训练策略，避免了大量无效试错。行为克隆方法将机器人控制建模为监督学习问题，直接学习从观测到动作的映射。该方法实现简单，适合数据质量较高的特定任务，但容易受到分布偏移影响。当机器人执行过程中偏离专家轨迹时，模型可能遇到训练集中未出现的状态，进而产生错误动作。为缓解这一问题，后续研究引入数据增强、交互式数据收集、通用视觉表征和扩散策略等方法，提高策略对多模态动作分布的建模能力^[4,7,28,31,32]。

为了更清楚地比较不同机器人操作方法的特点，表 1.1 对传统方法、强化学习、模仿学习和 VLA 模型的优缺点进行了归纳。

表 1.1 传统机器人操作方法与 VLA 模型的优缺点对比

方法类别	主要优点	主要不足	适用场景
传统感知规划控制方法	系统结构清晰，可解释性较强；安全边界和控制约束容易设置；在工业场景中稳定性较好。	模块之间依赖人工接口，容易产生误差累积；对开放语义任务和非结构化环境适应能力不足。	工业抓取、装配、固定流程搬运等规则明确的任务。
强化学习方法	能够通过环境交互学习策略，减少人工规则设计；适合复杂控制策略。	样本效率低，奖励函数设计困难；机器人试错成本高，仿真到现实迁移存在误差。	仿真训练、特定控制任务优化、策略探索类任务。
模仿学习方法	可以利用专家演示数据训练，避免大量无效试错；实现方式相对直接。	对数据质量和覆盖范围依赖强；执行过程中偏离专家轨迹时会出现分布偏移。	数据充足、任务流程相对固定的抓取和操作任务。
VLA 模型	能够统一建模视觉、语言和动作；具备较好的语义理解能力和跨任务迁移潜力。	模型规模和算力需求较高；连续动作生成、实时控制和安全仍需要进一步优化。	开放式桌面操作、多任务抓取、人机协作、自然语言交互控制等场景。

总体来看，传统方法和早期策略学习为机器人操作奠定了重要基础，但它们通常缺乏对自然语言和开放语义的直接建模能力，也难以充分利用大规模多模态数据中蕴含的常识知识。随着基础模型的发展，将视觉语言模型与机器人控制结合成为新的研究趋势。

1.2.2 视觉-语言-动作模型的发展趋势

视觉-语言-动作（Vision-Language-Action, VLA）模型的基本思想，是将视觉观测、自然语言指令和机器人动作纳入统一的建模框架中。在输入端，模型接收来自相机的 RGB 图像、机器人自身状态以及用户给出的任务指令；在输出端，模型生成关节角度、末端位姿、夹爪开合状态或一段未来动作序列。与传统模块化系统相比，VLA 模型不再将视觉检测、语言理解、任务规划和底层控制完全分开处理，而是尝试直接学习从多模态输入到机器人动作之间的映射关系。

从机器人操作任务的角度看，VLA 模型的研究价值主要体现在以下几个方面。首先，VLA 模型能够将自然语言中的目标、属性和动作意图与图像中的具体对象进行对齐。例如，当用户输入“抓取橘子”或“将香蕉放到指定位置”时，模型需要同时理解语言中的目标类别和动作意图，并在视觉画面中找到对应物体。其次，VLA

模型可以减少传统模块化系统中的误差传递问题。传统方法通常依赖目标检测、位姿估计、路径规划和运动控制等多个模块，前一级模块的误差会影响后续决策，而端到端 VLA 模型则通过统一训练目标直接优化最终动作输出。最后，VLA 模型有助于提升跨任务和跨场景泛化能力。由于模型通常以大规模视觉语言预训练模型为基础，因此能够利用互联网数据中学习到的语义知识，并结合机器人操作数据学习物理动作规律。

近年来，RT-1、RT-2、OpenVLA、SmolVLA、Octo、PaLM-E 等模型相继提出，推动了 VLA 研究的快速发展^[12,33-37]。相关综述也从模型演进、动作表征和前沿探索等角度，对该方向的技术路线进行了梳理^[10,23-25,27,38,39]。总体来看，VLA 模型正在从早期的离散动作 Token 预测，逐渐转向连续动作生成、开源复现和轻量化部署。离散动作方式便于复用语言模型结构和训练目标，但在桌面机械臂等连续控制任务中，容易带来推理延迟、动作量化误差和轨迹不平滑等问题。尤其是在抓取、移动和放置等操作过程中，末端执行器需要连续调整位置、姿态和夹爪开合状态，动作生成的平滑性会直接影响实机执行效果。因此，如何在保持视觉语言理解能力的同时，提高动作连续性和控制稳定性，成为 VLA 模型真实部署中需要重点解决的问题。如图 1.3 所示，VLA 模型正沿着动作表示改进、连续控制和低成本部署等方向持续发展。




图 1.3 VLA 模型发展时间线^[25]

在代表性模型中，OpenVLA 是较有影响力的开源 VLA 模型之一。早期部分 VLA 模型并未完全公开训练代码、模型权重和数据处理流程，研究者难以在本地平台上复现和二次开发。OpenVLA 面向开源通用机器人控制策略，基于大规模机器人操作数据进行训练，并提供了较完整的模型权重和训练工具链，为 VLA 模型在不同机器

人平台上的微调和部署提供了参考^[35]。因此，OpenVLA 不仅是一个具体模型，也为后续开源 VLA 模型的训练、微调和工程部署提供了较清晰的技术范式。

如图 1.4 所示，OpenVLA 的输入包括图像观测和自然语言任务指令。图像首先分别经过 DinoV2 和 SigLIP 两个视觉编码器进行特征提取。其中，DinoV2 更侧重于保留图像中的空间结构和局部几何信息，有助于模型判断目标物体与机械臂末端之间的位置关系；SigLIP 则更侧重于视觉语义对齐，有助于模型理解图像中物体类别与语言指令之间的对应关系^[40,41]。随后，两路视觉特征经过 MLP Projector 映射到语言模型可以处理的嵌入空间，并与经过 Llama Tokenizer 编码后的文本指令共同输入 Llama 2 7B 主干网络。模型在输出端生成动作 Token，再通过 Action De-Tokenizer 将离散 Token 还原为机器人可执行的动作量。




图 1.4 OpenVLA 模型结构示意图^[35]

从动作表示方式来看，OpenVLA 将机器人控制动作表示为语言模型词表中的离散 Token。其输出动作通常可以表示为 7 维机器人动作，包括末端位置变化量、末端姿态变化量以及夹爪开合量。这种处理方式的优点是可将机器人动作预测问题转化为类似语言模型中的下一个 Token 预测问题，从而复用已有大语言模型的训练范式和推理框架。对于大规模预训练模型而言，这种设计降低了 VLA 模型构建的复杂度，也使机器人动作能够与图像、语言共同进入统一的序列建模空间。

不过，OpenVLA 的离散动作表示也存在一定局限。机器人动作本质上是连续物理量，机械臂末端在空间中的位移、姿态变化和夹爪开合都需要保持平滑。当连续动作被划分为有限数量的离散区间后，动作精度会受到离散粒度的影响。如果离散区间过粗，机械臂可能出现抖动、定位不准或动作不连续；如果离散区间过细，则会增加动作 Token 的数量和模型预测难度。同时，自回归 Token 预测方式在生成较长动作序列时具有一定串行性，可能影响高频控制任务中的实时性。因此，OpenVLA 更适合作为一种开源、可复现、便于微调的 VLA 基础模型，而在高频连续控制和灵巧操作任务中，还需要进一步结合动作平滑、轨迹插值或连续动作生成方法。

综合来看, OpenVLA 的重要意义在于推动 VLA 模型从封闭研究走向开源复现。它提供了较完整的模型结构、训练思路和部署参考, 使研究者能够在已有基础上针对不同机器人平台进行二次开发。对于低成本桌面机械臂平台而言, OpenVLA 的开源特性具有较强参考价值, 但其模型规模和离散动作表示也说明, VLA 模型在本地算力受限条件下仍需要进一步轻量化和动作连续性优化。

在此基础上, 后续章节将进一步分析 π_0 与 SmolVLA 两类模型。 π_0 更关注连续动作生成、动作块预测和跨机器人形态控制; SmolVLA 则更强调低成本机器人平台上的模型规模、推理效率和本地部署可行性。第一章仅以 OpenVLA 作为开源 VLA 模型的代表进行说明, 后文将在模型结构章节中分别讨论 SmolVLA 与 π_0 的动作生成机制和部署特点。

1.3 主要内容与结构安排

本文围绕面向具身操作的视觉-语言-动作 (Vision-Language-Action, VLA) 模型展开研究。论文以具身操作理论、多模态建模、连续动作生成和机器人实机部署为主线, 结合 SO-101 桌面机械臂、LeRobot 开源框架和 LIBERO 仿真平台, 分析 VLA 模型在低成本机械臂平台上的训练、推理和控制流程。本文重点关注两个问题: 一是 VLA 模型如何将视觉观测、语言指令和机器人状态转化为连续动作; 二是在本地算力和硬件条件有限的情况下, 如何完成模型微调、仿真测试和实机抓取验证。全文结构安排如下。

第一章为绪论。本章首先介绍具身智能和机器人操作任务的发展背景, 说明传统机器人系统在开放场景和自然语言交互方面存在的不足。随后, 对传统机器人策略学习方法和 VLA 模型的发展情况进行梳理, 并以 OpenVLA 这一开源 VLA 模型为代表, 分析其模型结构、动作表示方式和开源复现价值, 说明当前 VLA 模型在多模态输入、动作 Token 化和本地微调部署方面的发展趋势。最后, 给出本文的研究内容和章节安排。

第二章介绍具身操作模型的基础。本章首先说明具身智能与离身智能的区别, 分析感知—认知—行动闭环以及具身操作任务对多模态感知、实时控制和物理语义落地的要求。随后, 介绍 Transformer 注意力机制和机器人动作表征方式, 说明视觉、语言、机器人状态和动作如何进入统一的序列建模框架。本章内容主要为后续 SmolVLA 与 π_0 模型分析提供理论基础。

第三章围绕 π_0 与 SmolVLA 模型展开分析。本章首先介绍连续标准化流和流匹配方法, 说明其在连续动作生成中的作用。随后, 分别分析 π_0 和 SmolVLA 的模型结构、动作专家网络、注意力机制和动作块生成方式, 并比较二者在模型规模、动作

连续性、推理效率和部署条件方面的差异。本章还结合后续实验需求，说明为什么轻量化模型和连续动作生成机制更适合低成本桌面机械臂平台。

第四章介绍系统训练与实机部署验证过程。本章首先说明实验所用的软件环境、硬件平台和 SO-101 机械臂结构，并介绍 LeRobot 框架中的数据流和控制调度方式。随后，基于主从遥操作方式采集水果抓取任务数据，并对图像、机器人状态、动作标签和语言指令进行封装和时序对齐。在模型训练部分，采用 LoRA 方法完成参数高效微调，并对训练过程中的损失变化和模型保存结果进行记录。在仿真部分，利用 LIBERO 环境对模型推理和环境交互流程进行测试；在实机部分，完成模型输出、机械臂控制接口和底层执行之间的连接，并通过橘子、香蕉和樱桃等目标物体的抓取实验，对系统的闭环执行效果进行验证和分析。

第五章为总结与展望。本章对全文工作进行归纳，说明本文在模型分析、训练流程搭建和实机部署验证方面完成的主要内容。同时，结合实验过程中遇到的问题，总结当前系统在数据规模、推理速度、抓取稳定性和泛化能力方面的不足，并对后续可能的改进方向进行说明。

为了更直观地展示本文的章节关系，论文整体结构如图 1.5 所示。



图 1.5 论文主要内容与章节安排

第二章 具身操作模型的基础

视觉-语言-动作 (Vision-Language-Action, VLA) 模型面向的不是单一的图像识别、语言理解或轨迹规划问题,而是具有物理交互属性的具身操作任务。对于机器人系统而言,模型需要同时处理视觉观测、自然语言指令、机器人本体状态和控制动作,并将高层语义目标转化为底层可执行动作。因此,在分析 π_0 和 SmolVLA 等模型结构之前,有必要先说明具身智能的基本内涵、具身操作中的闭环机制,以及多模态建模和动作表征方式。本章首先介绍具身操作相关的理论基础,随后说明 Transformer 注意力机制和动作表征方法,为后续模型分析和实机部署提供基础。

2.1 具身操作的理论基础

具身智能 (Embodied Intelligence) 强调智能体并不是只在抽象符号空间中完成推理,而是依托具体身体,在真实或仿真环境中通过感知、决策和行动进行持续交互。对于机器人而言,身体并不是简单的执行外壳,而是感知环境、约束动作和形成经验的重要载体。机械臂的关节数量、末端执行器结构、相机安装位置和控制频率,都会影响系统能够观察什么、能够执行什么动作以及能否稳定完成任务。

在本文研究的桌面机械臂抓取任务中,具身智能具体表现为:系统通过环境相机获取桌面图像,通过机械臂状态获取自身关节和夹爪信息,通过 VLA 模型理解语言指令和目标物体,并将模型输出转化为机械臂可以执行的动作。机械臂执行动作后,目标物体位置、夹爪状态和桌面环境发生变化,新的观测结果又会反馈给模型,形成下一轮控制依据。因此,VLA 模型不是孤立运行的神经网络,而是嵌入在机器人感知、决策和执行链路中的动作生成模块。

2.1.1 具身智能与离身智能

具身智能和离身智能 (Disembodied Intelligence) 代表了人工智能研究中的两种不同范式。离身智能主要面向文本、图像、语音等数字信息处理任务,典型形式包括大语言模型和视觉语言模型。这类模型能够完成文本生成、图像理解和语义推理等任务,但通常不直接作用于物理世界。具身智能则以物理载体为前提,需要通过传感器获取环境信息,通过执行器输出动作,并根据环境反馈不断调整行为。

因此,具身智能的核心不只是“理解信息”,而是“在环境中行动”。对于机器人操作任务而言,系统不仅要识别目标物体,还要理解目标物体与机械臂、夹爪和任务指令之间的关系。例如,“抓取橘子并放入盘中”并不只是一个语言理解问题,还

涉及目标定位、夹爪接近、闭合抓取、物体转移和释放等连续动作过程。VLA 模型的作用，正是将语言语义、视觉目标和机器人动作联系起来，使自然语言指令能够落到真实物理操作中。

传统机器人系统通常采用模块化架构，将视觉感知、任务规划、轨迹规划和底层控制分开实现。这种方式在结构化工业场景中具有较好的稳定性，但在开放场景和自然语言交互任务中容易出现语义割裂和误差累积。相比之下，VLA 模型尝试在统一框架中建模视觉、语言、状态和动作之间的关系，为端到端具身操作提供了一种新的实现路径。

2.1.2 感知—认知—行动闭环

具身操作系统的基本运行机制可以概括为“感知—认知—行动”闭环。感知模块负责从外部环境和机器人本体中获取信息，包括图像、关节状态、夹爪状态以及其他传感器反馈；认知模块负责理解任务目标、识别目标物体、判断当前任务阶段并生成动作策略；行动模块则负责将模型输出转化为机械臂控制指令，通过执行器作用于外部环境。行动改变环境后，新的环境状态再次被感知模块捕捉，由此形成持续循环。

从功能分工看，具身智能体可以理解为感知体、认知体和行为体的协同系统。感知体将多模态传感器数据转化为模型可以处理的结构化表示；认知体基于感知结果和任务指令进行推理、规划和动作生成；行为体将认知体输出的动作转化为底层控制量，并通过机械臂或夹爪作用于外部世界。对于本文的 VLA 抓取系统而言，环境相机和机械臂状态构成感知输入，VLA 模型承担认知与动作生成作用，SO-101 机械臂和夹爪则构成行为输出端。

具身认知理论中的 4E 框架也可以用于解释这一过程。具身性说明机器人认知受到机械臂结构、夹爪形式和传感器布局的影响；嵌入性说明机器人行为发生在具体桌面环境中，需要考虑光照、遮挡、物体摆放和空间约束；生成性说明机器人通过动作改变自身视角和物体状态，并在新的反馈中继续调整动作；扩展性则说明仿真平台、数据集和控制框架也可以成为具身系统能力的一部分。由此可见，VLA 模型的训练和部署并不是纯粹的软件问题，而是模型、数据、硬件和环境共同作用的结果。

为了说明 4E 认知框架与本文 VLA 机械臂抓取任务之间的关系，图 2.1 给出了对应关系。其中，SO-101 机械臂、夹爪和环境相机体现具身性；桌面、水果、盘子和光照体现嵌入性；机械臂动作改变目标位置和相机观测，体现生成性；LeRobot、LIBERO 和本地数据集则体现扩展性。从图 2.1 可以看出，本文的 VLA 机械臂抓取系统并不是单纯的软件推理模型，而是由感知输入、模型推理、动作执行和环境反馈共同构成的具身操作系统。4E 认知框架从身体结构、环境约束、行动反馈和外部

工具四个角度解释了该系统的工作机制，也为后续模型分析提供了理论基础。




图 2.1 4E 认知框架在 VLA 机械臂抓取任务中的对应关系

2.1.3 具身操作任务的技术要求

面向真实机械臂的具身操作任务，对模型和系统提出了多方面要求。首先，系统需要具备多模态感知能力。在桌面抓取任务中，视觉图像用于描述目标物体和环境布局，机器人状态用于描述当前关节和夹爪状态，语言指令用于表达任务目标。模型只有将这些异构信息统一到同一表示空间中，才能生成与当前场景匹配的动作。其次，系统还需要具备实时闭环控制能力。物理环境具有连续变化和不确定性，机械臂执行过程中可能受到摩擦、机械间隙、视觉噪声和控制延迟等因素影响。如果模型推理延迟过高，或相邻动作之间跳变较大，就可能造成机械臂抖动、目标偏离或抓取失败。因此，VLA 模型中的动作块预测、连续动作生成和异步推理机制，对于提高实机控制稳定性具有重要意义。

此外，系统需要具备物理语义落地能力。传统视觉语言模型可以识别“橘子”“香蕉”等目标，也可以描述图像内容，但具身操作模型必须进一步理解这些目标在物理世界中的可操作含义。例如，模型不仅要判断橘子在哪里，还要生成夹爪如何接近、何时闭合、如何移动到盘子上方以及何时释放等动作。也就是说，VLA 模型需要将语言符号、视觉对象和机器人动作建立直接联系，使语义能够在物理任务中执行。综上，具身操作模型不仅需要多模态语义理解能力，还需要面向物理世界的动作生成和闭环控制能力。本文后续分析的 π_0 与 SmolVLA 模型，正是在这一背景下，通过动作专家网络、流匹配连续动作生成和推理调度机制，尝试解决 VLA 模型在真实机器人操作中的动作连续性、部署成本和实时性问题。

2.2 多模态建模基础

VLA 模型需要同时处理图像、语言、机器人状态和动作等多种信息，因此其网络结构不仅要具备多模态特征融合能力，还要能够将高维感知信息转换为机器人可以执行的动作指令。Transformer 架构为这类模型提供了统一的序列建模方式，而动作表征方式直接影响模型输出能否满足机器人控制中的连续性和实时性要求。本节先介绍 Transformer 中的注意力机制，再说明机器人动作在 VLA 模型中的常见表示方法，为后续分析 π_0 和 SmoIVLA 的模型结构作铺垫。

2.2.1 Transformer 注意力机制


Transformer 最初用于序列建模任务，其主要特点是利用自注意力 (Self-Attention) 机制建立序列内部不同位置之间的依赖关系^[22]。和传统循环结构不同，Transformer 不需要按照时间顺序逐步处理输入，而是可以并行计算不同标记之间的相关性，因此更适合处理长序列和多模态输入。在 VLA 模型中，图像块、语言标记、机器人状态和历史动作都可以被转换为统一维度的向量序列，再通过注意力机制进行交互。

在多模态具身操作任务中，模型需要同时处理视觉信息、语言信息和机器人本体状态。视觉信息通常用于描述目标物体、背景和空间关系；语言信息用于表达任务目标；机器人状态则记录关节角、末端位姿和夹爪状态等物理量。Transformer 的优势在于，它能够在统一的特征空间中建模这些信息之间的关系。例如，语言指令中的“橘子”需要和图像中的水果区域对应，指令中的“抓取”需要进一步影响机械臂末端的运动方向和夹爪动作。

传统特征提取方法在处理这类异构输入时存在一定局限。卷积神经网络 (Convolutional Neural Network, CNN) 擅长提取图像局部纹理和空间特征，但在建立远距离目标关系时通常需要堆叠较深网络。循环神经网络 (Recurrent Neural Network, RNN) 及长短期记忆网络 (Long Short-Term Memory, LSTM) 适合处理时间序列，但计算过程存在顺序依赖，难以充分利用图形处理器 (Graphics Processing Unit, GPU) 的并行能力。相比之下，Transformer 通过注意力矩阵直接计算任意两个标记之间的相关性，在处理视觉、语言和状态混合序列时具有较好的灵活性。

如图 2.2 所示，Transformer 主要由多头注意力层、前馈神经网络层和归一化结构组成。输入序列首先经过词嵌入或线性投影得到统一维度的特征向量，同时叠加位置编码 (Positional Encoding) 以保留输入顺序。随后，特征进入多头注意力层进行全局信息交互，再经过前馈神经网络进行非线性变换。残差连接和层归一化则用于改善深层网络训练的稳定性。

在注意力计算中，输入特征会分别映射为查询矩阵 Q 、键矩阵 K 和值矩阵 V 。缩

图 2.2 Transformer 架构示意图^[22]

放点积注意力的计算形式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (2.1)$$

其中, d_k 为键向量维度。除以 $\sqrt{d_k}$ 的作用是缩放点积结果, 避免数值过大导致 Softmax 函数进入梯度饱和区, 从而提高训练稳定性。

为了让模型能够从不同表示子空间中提取信息, Transformer 进一步采用多头注意力机制 (Multi-Head Attention, MHA)。其计算过程可写为：

$$\begin{aligned} \text{head}_i &= \text{Attention}\left(QW_i^Q, KW_i^K, VW_i^V\right), \\ \text{MultiHead}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O. \end{aligned} \quad (2.2)$$

其中, h 表示注意力头的数量, W_i^Q 、 W_i^K 、 W_i^V 和 W^O 为可学习的权重矩阵。不同注意力头可以分别关注图像区域、语言关键词、机器人状态等不同信息, 从而增强模型对多模态上下文的表达能力。

注意力层输出后, 结果会进入前馈神经网络 (Feed-Forward Network, FFN)。FFN

通常由两层线性变换和一个非线性激活函数组成，可表示为：

$$\text{FFN}(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2. \quad (2.3)$$

在实际模型中，激活函数也常使用高斯误差线性单元（Gaussian Error Linear Unit, GELU）。通过注意力层和 FFN 的交替堆叠，Transformer 能够逐层融合视觉、语言和状态信息，为后续动作生成提供上下文表示。

2.2.2 动作表征及解码方式

在机器人控制中，动作通常表现为连续物理量。以桌面机械臂为例，模型输出可能包括末端执行器在三维空间中的位置变化、姿态变化以及夹爪开合状态。若直接使用回归网络预测这些连续值，模型实现较为简单，但在复杂操作任务中容易出现动作均值化问题。例如，同一目标物体可能存在多种合理抓取轨迹，单一回归输出难以完整表示这些多模态动作分布。




图 2.3 连续动作空间离散化

为了使机器人动作能够适配序列模型，部分 VLA 模型将连续动作离散化为动作标记（Action Token）。如图 2.3 所示，动作离散化的基本思路是将连续控制空间划分为若干区间，每个区间对应一个离散标记，从而将机器人动作预测转化为类似语言模型中的下一个标记预测问题，并复用大语言模型中的自回归解码和交叉熵训练目标。不同动作离散化方式会影响模型的动作精度和训练难度，其在实现复杂度、动作精度和适用场景上也存在差异。表 2.1 对几种常见动作离散化方法进行了对比。

当动作被转换为离散标记后，VLA 模型可以采用自回归解码（Autoregressive Decoding）方式生成动作序列。模型在每一步根据图像、语言、状态以及已经生成的动作标记，预测下一个动作标记的概率分布。推理时可以采用贪心搜索、Top-k 采样或

表 2.1 常见动作离散化方法对比

方法	基本思想	优点	不足
均匀离散化	将连续动作空间按照固定间隔划分为若干区间，每个区间对应一个动作标记。	实现简单，便于和语言模型词表、分类头结合。	当动作分布不均匀时，部分区间利用率较低，细微动作表达精度有限。
基于聚类的离散化	根据专家演示数据中的动作分布，使用聚类方法提取代表性动作中心。	更符合实际动作分布，能够提高常见动作区域的表示效率。	聚类数量较难确定，可能增加模型预测难度，并影响动作空间连续性。
残差向量量化	使用多级量化器逐步编码动作及其残差，提高动作标记的信息密度。	适合高维动作和长序列控制任务，能够在较小词表下提升表示精度。	结构相对复杂，训练和解码过程更难调试。

温度采样等方式生成结果。动作标记生成后，再通过反离散化过程还原为连续控制量，并下发给机器人执行。

这种方法的优势在于能够充分利用大语言模型成熟的训练和推理框架，但也存在一定问题。机器人控制通常要求动作连续、平滑且实时更新，离散动作标记可能带来量化误差；自回归生成方式还会增加推理时延。因此，后续 VLA 模型开始引入扩散模型和流匹配等连续动作生成机制，以提高动作平滑性和控制实时性。

2.3 本章小结

本章主要介绍了 VLA 模型研究所需的具身操作基础和多模态建模方法。首先，从具身智能的概念出发，说明了具身智能与离身智能的区别，并结合感知—认知—行动闭环分析了机器人操作任务的基本运行机制。对于本文研究的 SO-101 桌面机械臂抓取任务而言，VLA 模型并不是孤立的推理网络，而是连接视觉观测、语言指令、机器人状态和底层动作控制的关键模块。

随后，本章从具身操作任务出发，分析了多模态感知、实时闭环控制和物理语义落地等技术要求。机器人不仅需要识别目标物体，还需要理解目标在物理空间中的可操作含义，并根据机械臂状态和环境反馈生成连续动作。最后，本章介绍了 Transformer 注意力机制和动作表征方式，说明视觉、语言、状态和动作如何进入统一的序列建模框架。这些内容为后续分析 π_0 和 SmolVLA 模型的动作生成机制和部署特点提供了理论基础。

第三章 π_0 和 SmolVLA 模型分析

视觉-语言-动作 (Vision-Language-Action, VLA) 模型需要将高维视觉观测、自然语言指令和机器人本体状态转化为可执行的连续动作。传统自回归动作生成方法便于复用语言模型结构,但在高频控制任务中容易受到推理延迟、动作离散误差和轨迹不平滑等问题影响。为缓解上述问题,近年来的 VLA 模型开始采用流匹配 (Flow Matching) 生成连续动作块,并结合动作专家网络提高控制稳定性。本章首先介绍连续标准化流、条件流匹配和最优传输路径等动作生成基础,然后先分析 π_0 模型在通用机器人控制和跨硬件形态泛化方面的结构特点,再分析 SmolVLA 面向低成本平台的轻量化设计、注意力结构和异步推理方式,最后结合 SO-101 桌面机械臂部署需求,对两类模型的复杂度和适用场景进行比较。

3.1 流匹配动作生成方法

在分析 π_0 和 SmolVLA 的模型结构之前,需要先说明二者共同涉及的连续动作生成思想。早期 VLA 模型通常将机器人动作离散化为动作 Token,再按照类似语言模型的方式逐步预测。这种方法可以继承大语言模型成熟的训练方式,但机器人动作本身是连续物理量,机械臂末端位置、姿态和夹爪开合都需要保持平滑。如果模型每一步都依赖离散 Token 的自回归预测,不仅会引入量化误差,也会增加动作生成过程中的串行延迟。

流匹配方法的出发点是直接在连续动作空间中建模动作分布^[42]。它不再把动作看作有限类别,而是学习一个从简单噪声分布到真实专家动作分布的连续变换过程。对于机械臂抓取、放置、整理和轨迹跟随等任务而言,这种方式更适合表达连续动作的多模态分布,也能在较少采样步数下生成未来一段时间内的动作块。因此,流匹配逐渐成为新一代 VLA 模型动作专家网络中的重要生成机制。

3.1.1 连续标准化流和边际向量场

在机器人模仿学习中,模型通常需要从专家演示数据中学习动作分布。设真实专家动作数据分布为 $q(x_1)$,其中 x_1 表示专家轨迹中的动作样本。这个动作分布通常具有较强的多模态特征。例如,对于同一个目标物体,机械臂可能从左侧接近,也可能从右侧接近;对于同一个抓取目标,夹爪可能选择不同角度完成闭合。因此,简单的均值回归往往无法准确表达真实动作数据中的多种可能轨迹。

连续标准化流 (Continuous Normalizing Flows, CNFs^[42]) 提供了一种从简单分布

到复杂分布的连续映射方式。它通常以标准高斯分布 $\mathcal{N}(0, I)$ 作为初始分布 p_0 ，再通过一个随时间变化的向量场将样本逐步变换到目标数据分布 p_1 。在这一框架下，模型不需要一次性直接预测复杂动作，而是学习如何将一个随机噪声样本沿着合适的方向移动，使其最终落在真实动作分布附近。

从数学形式上看，CNFs 通过时间变量 $t \in [0, 1]$ 定义连续流 ϕ_t 。样本在时间 t 下的位置由常微分方程控制：

$$\frac{d}{dt}\phi_t(x) = v_t(\phi_t(x)), \quad \phi_0(x) = x. \quad (3.1)$$

其中， $\phi_t(x)$ 表示样本从初始状态出发后在时间 t 的位置， v_t 是控制样本移动方向和速度的向量场。在深度学习实现中， v_t 通常由带参数的神经网络 $v_t(x; \theta)$ 表示。训练过程的目标，就是使网络预测出的向量场能够引导样本从噪声分布逐步接近真实动作分布。

如果已知完整的目标概率路径 $p_t(x)$ 以及对应的边际向量场 $u_t(x)$ ，则可以直接通过均方误差训练网络拟合该向量场。理想的流匹配目标函数可以写为：

$$\mathcal{L}_{FM}(\theta) = \mathbb{E}_{t, p_t(x)} [\|v_t(x) - u_t(x)\|^2]. \quad (3.2)$$

其中， t 通常从 $[0, 1]$ 区间采样， x 来自中间分布 $p_t(x)$ 。该目标函数表达了一个直观思想：在每一个中间时刻，神经网络都应预测出样本应该移动的方向。

不过，在机器人操作任务中，完整的概率路径 $p_t(x)$ 和边际向量场 $u_t(x)$ 通常无法直接获得。真实数据集只包含有限条专家演示轨迹，也就是若干离散的图像、状态和动作序列。模型可以看到专家在某些状态下采取了什么动作，但无法直接知道整个动作分布从噪声到真实数据之间的全局演化路径。因此，直接优化式 (3.2) 在实际工程中较难实现，需要引入更容易采样和计算的条件流匹配方法。

3.1.2 条件流匹配推导

条件流匹配 (Conditional Flow Matching, CFM) 的基本思想，是不再直接拟合未知的全局概率路径，而是针对每个真实动作样本 x_1 构造一条条件概率路径 $p_t(x|x_1)$ 。这样，模型训练时只需要学习如何把一个噪声样本逐步变换到某个具体专家动作样本附近，而不需要显式求解完整数据分布的全局向量场。

给定真实动作样本 $x_1 \sim q(x_1)$ ，可以人为构造一条从噪声到动作样本的条件路径。在起点 $t = 0$ 时，样本来自标准高斯噪声；在终点 $t = 1$ 时，样本接近真实动作 x_1 。由于这条路径是围绕单个数据样本构造的，因此对应的条件向量场 $u_t(x|x_1)$ 可以写出解析形式或通过简单计算得到。

理论上，边际向量场可以由所有条件向量场加权积分得到：

$$u_t(x) = \int u_t(x|x_1) \frac{p_t(x|x_1)q(x_1)}{p_t(x)} dx_1. \quad (3.3)$$

该式说明，全局向量场可以看作所有样本条件向量场的加权结果。由此可以将原本难以直接优化的全局流匹配目标，转化为条件流匹配目标：

$$\mathcal{L}_{CFM}(\theta) = \mathbb{E}_{t,q(x_1),p_t(x|x_1)} [\|v_t(x) - u_t(x|x_1)\|^2]. \quad (3.4)$$

在式 (3.4) 中，训练样本来自三个部分：首先从数据集中采样真实动作 x_1 ，然后采样时间步 t ，最后根据条件路径 $p_t(x|x_1)$ 得到中间带噪样本 x 。网络输入带噪动作、时间步和观测条件，输出对应的向量场。相比直接拟合未知的全局向量场，CFM 的训练目标更容易实现，也更适合机器人示范数据这种离散轨迹数据。

在 VLA 模型中，条件信息通常不仅包括当前动作样本，还包括视觉观测、语言指令和机器人状态。也就是说，动作专家网络学习的并不是无条件动作分布，而是条件动作分布 $p(A_t|o_t)$ 。其中 o_t 表示当前观测，包括图像、语言任务和本体状态； A_t 表示未来一段时间内的动作块。通过这种方式，模型能够根据当前任务语义和物理状态生成对应的连续动作序列。

3.1.3 最优传输路径

在条件流匹配框架下，概率路径的构造方式会直接影响模型训练难度和采样效率。传统扩散模型通常通过逐步加噪和逐步去噪来生成样本，由于其概率路径往往较为弯曲，推理阶段需要较多网络前向计算步数才能得到高质量样本。对于图像生成任务而言，这种计算开销通常可以接受；但对于机器人控制而言，过多采样步数会带来明显延迟，影响闭环控制频率。为提高采样效率，流匹配方法常结合最优传输 (Optimal Transport, OT) 思想构造更加平直的概率路径。最优传输可以理解为在初始噪声分布和目标动作分布之间寻找代价较低的质量移动方式，使样本从噪声移动到真实动作时尽可能沿平滑方向变化。对于机器人动作生成而言，较平直的路径意味着网络更容易学习向量场，推理时也可以使用较少的积分步数得到可用动作块。图 3.1 给出了扩散模型去噪轨迹和最优传输流匹配轨迹的对比。

在最优传输条件流匹配 (Optimal Transport Conditional Flow Matching, OT-CFM) 中，常采用线性高斯路径来表示中间分布。其均值和标准差可以写为：

$$\mu_t(x) = tx_1, \quad \sigma_t(x) = 1 - (1 - \sigma_{\min})t. \quad (3.5)$$




图 3.1 扩散模型和最优传输流匹配去噪轨迹对比

在该路径下，对应的条件向量场具有相对简单的闭式形式：


$$u_t(x|x_1) = \frac{x_1 - (1 - \sigma_{\min})x}{1 - (1 - \sigma_{\min})t}. \quad (3.6)$$

与传统扩散模型相比，OT-CFM 的采样轨迹更接近直线，网络学习的向量场变化也更加平滑。推理时，模型可以使用较少的欧拉积分步数生成动作序列，从而降低计算延迟。对于机械臂控制而言，这一点非常重要：如果动作生成需要过多采样步数，控制系统会出现明显滞后；而如果能在少数积分步内得到连续动作块，底层控制器就可以更稳定地执行模型输出。因此，流匹配方法在 VLA 模型中的意义不仅是数学形式上的生成模型替换，更直接影响机器人系统的控制频率和运动平滑性。 π_0 和 SmolVLA 都采用了类似的连续动作块生成思想，只是在模型规模、注意力结构和部署方式上做出了不同取舍。

3.2 π_0 模型结构

π_0 是面向通用机器人控制的 VLA 模型，目标是利用较大规模的视觉语言模型和机器人数据提升跨任务、跨硬件平台的操作能力。与 SmolVLA 更关注低成本部署不同， π_0 更强调跨机器人形态的泛化能力和连续动作生成能力。其整体结构如图 3.2 所示，模型以预训练视觉语言模型作为语义理解主干，同时增加动作专家网络用于处理机器人状态和连续动作。

从图 3.2 可以看出， π_0 的输入包括多视角图像、自然语言任务指令和机器人本体状态。预训练视觉语言模型负责提取图像和语言上下文，动作专家则在这些上下文条件下生成未来一段时间内的动作序列。由于不同机器人平台的自由度和动作空间并不相同， π_0 还需要通过状态和动作维度对齐方法，使单一模型能够适配单臂、双臂和移动操作机器人等不同硬件形态。

图 3.2 π_0 模型整体结构示意图^[43]

3.2.1 视觉语言基座和状态映射

π_0 采用预训练视觉语言模型作为基础，使模型能够利用互联网规模图像文本数据中学习到的视觉和语义知识。对于机器人操作任务而言，输入不仅包括图像和语言，还包括机器人自身的关节状态和末端执行器状态。因此， π_0 将当前观测定义为：

$$o_t = [I_t^1, \dots, I_t^n, l_t, q_t]. \quad (3.7)$$

其中， I_t^i 表示第 i 个相机视角下的图像， l_t 表示自然语言任务指令， q_t 表示机器人本体状态。

在输入处理时，图像由视觉编码器转化为视觉 Token，语言指令由分词器转化为文本 Token，机器人本体状态 q_t 则通过线性投影映射到与语言模型隐藏维度一致的特征空间。这样，视觉、语言和状态信息可以被组织为统一的序列输入到模型中。相比只使用图像和语言的视觉语言模型， π_0 进一步将机器人状态作为条件，使动作专家能够根据当前物理姿态生成更合适的控制动作。

在动作输出侧， π_0 并不直接使用语言模型的离散词表预测动作 Token，而是通过动作专家生成连续动作块。动作专家与视觉语言主干相连接，但主要负责处理机器人状态和动作分布。这样的结构保留了预训练视觉语言模型的语义理解能力，同时避免机器人动作生成完全依赖离散文本 Token。

这种结构对于跨任务操作具有一定优势。视觉语言模型可以提供目标识别、场景理解和任务语义解析能力，而动作专家则专注于将这些高层信息转化为连续控制指令。对于折叠、整理、放置等需要多步执行的任务，单纯的视觉识别并不足够，模型还需要根据当前机器人状态生成符合物理约束的动作轨迹。 π_0 正是通过视觉语言主干和动作专家分工协作来完成这一过程。

3.2.2 注意力掩码和采样策略

π_0 在处理多模态输入和动作去噪时，设计了块级因果注意力掩码（Blockwise Causal Attention Mask）。该设计的目的，是让不同类型 Token 按照合理的信息流顺序

交互，避免模型在训练或推理中提前读取不应出现的信息。由于输入序列中同时包含图像、语言、状态和动作，如果不进行注意力权限划分，模型可能在训练阶段形成不符合推理过程的信息依赖，影响实机部署时的稳定性。

如图 3.3 所示，输入序列可以划分为感知区块、本体状态区块和动作区块。感知区块主要包含图像和语言特征，本体状态区块包含机器人当前状态，动作区块包含加噪动作 Token。不同区块之间的可见关系由注意力掩码控制。

	感知 Key (I, L)	状态 Key (q)	动作 Key (A)
感知 Query	内部 双向	掩码 X	掩码 X
状态 Query	跨块 读取	内部 双向	掩码 X
动作 Query	跨块 读取	跨块 读取	内部 双向

图 3.3 π_0 模型块级因果注意力掩码结构

在这一结构中，感知区块内部可以进行双向注意力计算，用于充分融合图像和语言信息；状态区块可以读取感知区块信息，并结合机器人当前物理状态形成控制条件；动作区块可以读取感知和状态信息，同时在动作块内部进行双向交互。由于动作块需要整体保持连贯，动作 Token 之间的交互有助于生成更平滑的轨迹。

在采样阶段， π_0 同样采用流匹配方式生成动作。模型从随机噪声动作出发，经过若干步积分得到连续动作块。噪声时间步 $\tau \in [0, 1]$ 会作为额外条件输入模型，用于控制当前去噪阶段。训练时，模型并不只是平均学习所有噪声水平，而会对部分噪声区间进行更高比例采样，使网络更重视从高噪声状态恢复动作结构的能力。这样可以减少推理阶段所需的采样步数，并提高动作生成稳定性。

对于机器人控制而言，采样策略会直接影响动作质量。如果模型只在低噪声阶段训练充分，推理时从随机噪声出发可能难以快速找到合理动作方向；如果高噪声阶段训练较充分，模型可以更快确定动作分布的大致方向，再通过少量积分逐步细化动作。 π_0 的采样设计正是为了在动作质量和推理效率之间取得平衡。

3.2.3 硬件对齐和训练策略


π_0 面向多种机器人平台，因此需要处理不同自由度和不同动作空间之间的差异。双臂机器人、移动操作机器人和单臂机械臂的状态维度、动作维度和控制接口均不相同。若针对每种机器人单独设计网络输出层，模型难以形成统一的跨平台表示，也会增加训练和部署复杂度。为解决这一问题， π_0 采用统一维度的状态和动作表示方式，即统计训练数据中的最大动作维度，并将不同机器人平台的状态和动作统一填充到相同维度。对于自由度较少的机器人，多余维度使用零填充（Zero-padding）处理；对于缺失的相机视角，则可以使用占位输入或掩码方式补齐。这样，模型结构不需要随机器人硬件变化而频繁调整，神经网络也可以在训练过程中自动学习哪些维度对当前机器人有效，哪些维度属于填充项。对于单臂机械臂而言，其有效动作维度可能远小于统一动作空间；而对于双臂机器人或移动操作机器人，更多动作维度会被激活。通过统一输入输出格式， π_0 能够在同一框架下处理不同机器人形态的数据。

在训练策略上， π_0 通常采用预训练和后训练相结合的方式。第一阶段使用大规模、多机器人形态的操作数据进行预训练，使模型学习基本的物理交互规律和跨任务操作经验；第二阶段针对特定任务或特定机器人平台进行后训练或微调，使模型适应更具体的操作目标。相比从零开始训练，这种方式能够更好地利用已有数据，提高复杂任务的收敛速度和成功率^[44,45]。对于本文的实验平台而言， π_0 的整体规模和训练成本较高，不一定适合直接完整复现，但它在连续动作生成、动作专家设计和跨硬件对齐方面提供了重要参考。因此，本文后续更关注 SmolVLA 在低成本平台上的部署，同时仍将 π_0 作为理解流匹配动作生成和通用机器人控制思路的重要对照模型。

3.3 SmolVLA 模型结构

SmolVLA 是面向低成本机器人和本地部署场景设计的轻量化 VLA 模型。与依赖大规模服务器推理的通用模型不同，SmolVLA 更强调消费级设备、低成本机械臂和开源社区数据上的可运行性。其整体结构如图 3.4 所示，模型由紧凑型视觉语言模型和动作专家两部分组成：前者负责处理图像、语言和机器人状态，后者基于流匹配生成连续动作块。

从图 3.4 可以看出，SmolVLA 一方面利用社区数据集和低成本机器人平台降低数据与硬件门槛，另一方面通过视觉语言模型提取多模态特征，并将这些特征送入动作专家网络。动作专家内部交替使用交叉注意力和自注意力，使动作 Token 既能读取视觉语言上下文，又能保持动作块内部的时序连续性。该结构为后续的轻量化

图 3.4 SmolVLA 模型整体结构示意图^[36]

训练和本地推理提供了基础。

3.3.1 感知编码及特征压缩

SmolVLA 的感知部分主要用于从 RGB 图像、自然语言指令和机器人状态中提取多模态特征。为了降低部署成本, SmolVLA 选用紧凑型视觉语言模型作为主干, 而不是直接使用参数规模较大的通用 VLA 模型。视觉编码部分通常依赖 SigLIP (Sigmoid Loss for Language Image Pre-Training) 提取图像特征, 语言指令通过分词器转化为文本 Token, 机器人状态则通过线性层投影为与语言模型隐藏维度一致的状态 Token。

在图像输入处理方面, SmolVLA 并不追求过高分辨率和过长视觉序列。高分辨率图像会显著增加视觉 Token 数量, 而 Transformer 注意力计算复杂度随序列长度增加而快速上升。尤其是在多摄像头输入场景中, 如果每个视角都产生大量视觉 Token, 后续注意力计算会带来较高显存消耗和推理延迟。为减少计算负担, SmolVLA 对视觉 Token 数量进行了压缩, 将输入图像表示为更短的特征序列。这种做法虽然会牺牲部分细粒度纹理信息, 但可以明显降低显存占用, 更适合低成本机械臂平台。

与传统视觉语言模型常用的图像切片方式不同, SmolVLA 更关注机器人控制所需的时空关系和目标区域。对于桌面抓取任务, 模型通常并不需要完整保留图像中的每一个细节, 而是需要识别目标物体、机械臂末端、容器位置以及它们之间的相对关系。因此, 对视觉 Token 进行压缩并不会必然导致控制能力下降, 反而可以使模型更容易满足实时推理需求。

除了压缩视觉 Token, SmolVLA 还采用层跳过 (Layer Skipping) 策略减少视觉语言模型主干的计算量。对于桌面抓取任务而言, 模型更需要目标位置、物体类别

和空间关系等信息，而不一定需要完整的高层语言推理能力。视觉语言模型的中低层通常已经包含边缘、颜色、目标区域和空间布局等信息，深层网络更多偏向复杂语义推理。SmolVLA 因此在动作专家侧只使用视觉语言模型的部分中间层特征，避免所有层都参与推理。




图 3.5 SmolVLA 特征压缩和层跳过策略示意图

图 3.5 中，视觉图像和语言指令首先经过编码和投影，形成统一的多模态特征。随后，模型只保留对动作生成较有用的部分层输出，并将其送入动作专家。通过这种设计，SmolVLA 在保持基本语义理解能力的同时，减少了模型前向推理所需的计算量。对于 SO-101 这类低成本桌面机械臂而言，这种结构更容易在本地完成训练和推理。

3.3.2 动作专家注意力设计

SmolVLA 的动作专家网络用于生成未来一段时间内的动作块 $A_t = (a_t, a_{t+1}, \dots, a_{t+n})$ 。动作专家不是简单地逐步输出单个动作，而是在当前观测条件下预测一段连续动作序列。这样做可以降低模型推理频率，并减小神经网络延迟对底层控制频率的影响。

在注意力结构上，SmolVLA 动作专家交替使用交叉注意力 (Cross-Attention, CA) 和自注意力 (Self-Attention, SA)。在交叉注意力层中，动作 Token 作为查询向量，从视觉语言模型输出的上下文特征中读取任务和环境信息。也就是说，动作专家通过 CA 层获取“要抓什么”“目标在哪里”“当前机械臂处于什么状态”等条件信息。在自注意力层中，动作 Token 之间进行时序交互，用于保持动作块内部的连续性。与只使用单一注意力结构相比，交替结构能够同时利用视觉语言条件和动作序列内部关系。

这种设计对于机器人动作生成较为重要。若动作专家只依赖视觉语言条件，而忽略动作块内部关系，则相邻动作之间可能缺乏连续性；若只强调动作之间的自注意力，而缺少对图像和语言上下文的读取，则模型可能无法准确根据任务目标调整轨迹。CA 和 SA 的交替结构在一定程度上平衡了任务条件读取和动作时序平滑。

动作专家的训练建立在流匹配目标之上。设当前观测条件为 o_t ，真实动作块为

A_t , 噪声为 ϵ , 则带噪动作可以表示为:

$$A_t^\tau = \tau A_t + (1 - \tau)\epsilon. \quad (3.8)$$

模型学习预测从带噪动作到真实动作的向量场, 其训练损失可写为:

$$\mathcal{L}^\tau(\theta) = \mathbb{E}_{p(A_t|o_t), q(A_t^\tau|A_t)} \left[\left\| v_\theta(A_t^\tau, o_t) - u(A_t^\tau|A_t) \right\|^2 \right]. \quad (3.9)$$

其中, v_θ 表示动作专家网络预测的向量场, $u(A_t^\tau|A_t)$ 表示目标条件向量场。通过这一训练过程, 模型可以从随机噪声中逐步生成平滑动作块。

相比普通回归损失, 流匹配损失能够更好地表达复杂动作分布。对于同一语言指令和视觉目标, 专家演示可能包含多条可行轨迹。若使用简单回归, 模型容易学习到不同轨迹的平均值, 导致生成动作不自然; 而流匹配通过建模从噪声到动作分布的连续变换, 可以在一定程度上保留动作分布的多样性。

3.3.3 异步推理调度

在真实机器人控制中, 模型推理速度和底层控制频率往往不一致。机械臂底层控制通常需要较高频率更新, 而 VLA 模型前向推理可能受到模型参数量、图像处理、显存传输和设备性能影响。如果采用同步推理方式, 系统通常需要等待当前动作块执行完毕后, 再采集新的观测并进行下一次模型推理。这种方式实现简单, 但在模型推理较慢时容易造成动作间断, 导致机械臂运动出现停顿。

SmolVLA 采用异步推理调度来缓解这一问题。其基本思想是将动作执行和模型推理解耦: 机器人客户端在执行已有动作队列的同时, 后台策略服务器可以根据新的观测提前预测下一段动作块。当新的动作块返回后, 系统再将其与当前剩余动作进行融合或替换, 使控制指令保持连续更新。

设动作块长度为 n , 当前队列剩余动作比例为 $|A_t|/n$, 系统设置阈值 $g \in [0, 1]$ 。当剩余比例低于阈值时, 客户端触发新的异步推理请求。若服务端单次推理和通信延迟期望为 $\mathbb{E}[l_s]$, 底层控制周期为 Δt , 为了避免动作队列耗尽, 阈值可近似满足:

$$g \geq \frac{\mathbb{E}[l_s]/\Delta t}{n}. \quad (3.10)$$

当 g 过小时, 系统容易退化为等待式同步推理, 机器人可能在动作队列耗尽后出现停顿; 当 g 过大时, 模型会频繁接收新观测并重复计算, 增加硬件负担。因此, 实际部署时需要根据模型推理速度、网络通信延迟和控制频率选择合适的阈值。对于低成本桌面机械臂而言, 异步推理可以在有限算力条件下提高控制连贯性, 是 SmolVLA 适合本地部署的重要原因之一。

此外，异步推理还可以提高系统对环境变化的响应能力。若物体位置在执行过程中出现轻微偏移，或者机械臂实际运动与预测轨迹之间存在误差，系统可以通过新观测更新动作队列，而不必等完整动作块执行结束。这种机制对于桌面抓取任务较为实用，因为低成本舵机机械臂的执行精度有限，闭环更新能够在一定程度上弥补模型预测和硬件执行之间的误差。

3.4 模型复杂度和部署对比

π_0 和 SmolVLA 都使用连续动作生成思想，但二者面向的部署条件和任务目标不同。 π_0 更关注跨机器人平台泛化和复杂操作任务，SmolVLA 则更关注低成本硬件、本地推理和实时响应。表 3.1 对二者进行对比。

表 3.1 π_0 和 SmolVLA 模型架构及部署特性对比

对比维度	π_0 模型	SmolVLA 模型
参数规模	约 33 亿参数，模型规模较大。	约 4.5 亿参数，模型更加轻量。
感知主干	采用预训练视觉语言模型，强调语义理解和泛化能力。	采用紧凑型视觉语言模型，强调低成本推理。
动作生成方式	动作专家结合流匹配方法，生成连续动作块。	动作专家结合流匹配方法，生成连续动作块。
注意力结构	采用块级因果注意力掩码，支持多模态区块交互。	采用交叉注意力和自注意力交替结构，控制计算开销。
硬件适配方式	通过统一维度和零填充方式，适配多种机器人形态。	更适合固定低成本机械臂和本地部署。
推理调度	更依赖较强算力完成连续动作采样。	强调异步推理，减少动作执行等待。
适用场景	适用于长程操作、跨平台控制和复杂灵巧任务。	适用于桌面抓取、放置、分类等中短程任务。

从模型规模和控制方式看， π_0 的参数量更大，对算力要求更高，但其跨机器人形态训练和更强的视觉语言主干，有助于提升复杂任务和多平台任务中的泛化能力。相比之下，SmolVLA 的参数量更小，更适合在消费级 GPU 或低成本边缘设备上部署，对于本科实验平台或普通实验室环境而言，也更容易完成本地微调和实机测试。在动作生成方面，二者都采用连续动作块生成方式，能够减少离散动作 Token 带来的量化误差。其中， π_0 更强调通用动作建模能力，通过统一状态和动作维度适配不同机器人平台，适合更复杂和更长时序的操作任务；SmolVLA 则进一步通过异步推

理调度降低模型延迟对执行过程的影响，使其更适合实时性要求较高但任务相对较短的桌面抓取场景。

从实验可行性看，SmolVLA 与本文后续平台更加匹配。SO-101 桌面机械臂属于低成本、开放式硬件平台，任务主要集中在水果目标抓取和简单桌面操作。该类任务对模型的要求主要体现在目标识别、动作连续性和本地推理稳定性上，而不是复杂长程规划或跨机器人形态泛化。因此，采用轻量化模型更有利于完成数据采集、模型微调和实机部署闭环。不过， π_0 仍然具有重要参考意义，它展示了连续动作生成模型在更大规模机器人数据和多形态硬件平台上的扩展方式，也说明未来 VLA 模型需要在语义理解、动作生成和硬件适配之间建立更统一的框架。对于本文而言， π_0 更适合作为连续动作生成和通用机器人控制路线的对照参考，而 SmolVLA 更适合作为实际部署对象。

3.5 本章小结

本章围绕 π_0 和 SmolVLA 两类 VLA 模型进行了分析。首先介绍了连续标准化流、条件流匹配和最优传输路径，说明连续动作块生成相较离散动作 Token 预测在平滑性和推理效率上的优势。随后，分析了 π_0 的视觉语言基座、状态映射、块级因果注意力掩码、硬件维度对齐和训练策略，说明其在通用机器人控制和跨硬件平台泛化方面的特点。接着，分析了 SmolVLA 的感知特征压缩、层跳过策略、动作专家结构和异步推理调度，说明其适合低成本机械臂平台部署的原因。最后，从模型规模、动作生成、推理调度和适用场景等方面比较了两种模型，为第四章开展 SO-101 机械臂数据采集、模型微调和实机抓取验证提供依据。

第四章 系统训练和实机验证

前文已经对 π_0 与 SmolVLA 模型的结构、动作生成方式及部署特点进行了分析。本章围绕 SO-101 桌面机械臂平台，介绍从实验环境搭建、遥操作数据采集、模型微调训练到仿真测试和实机抓取验证的完整流程。相比纯软件环境，真实机械臂系统需要同时处理图像采集、关节状态读取、动作解码、逆运动学求解和底层通信等问题，模型输出也会受到相机噪声、机械臂传动误差和执行延迟的影响。因此，本章重点说明如何基于 LeRobot 框架完成本地数据集构建和 LoRA 微调，并通过 LIBERO 仿真环境和真实水果抓取实验验证系统的可行性。

4.1 实验环境和数据采集

视觉-语言-动作 (VLA) 模型在具体场景中的表现，与本地数据质量和硬件控制链路密切相关。通用视觉语言模型虽然具备较强的语义理解能力，但并不了解本文实验桌面的光照条件、相机视角、SO-101 机械臂的运动范围以及水果目标的具体外观。因此，在进行模型微调前，需要先完成软硬件环境配置、机械臂平台搭建和本地遥操作数据采集。本节主要介绍实验平台的基础配置、SO-101 机械臂结构以及数据采集和封装流程。

4.1.1 计算环境和框架配置

模型训练和推理在本地工作站上完成。由于 VLA 模型在前向传播和反向传播过程中需要处理图像、语言和动作序列，对显存容量和计算带宽有一定要求，因此实验环境需要配置对应的深度学习框架和加速库。工作站安装了 CUDA 计算平台和 cuDNN 深度神经网络加速库，并使用 PyTorch 作为模型训练和推理的基础框架。具体实验环境如表 4.1 所示。

在软件框架方面，本文接入 LeRobot 开源框架来组织数据采集和模型训练流程。该框架能够对机器人状态、相机图像、动作标签和语言指令进行统一管理，减少从零编写硬件接口和数据格式转换程序的工作量。通过配置相机驱动、机械臂通信接口和数据保存路径，系统可以将遥操作过程中产生的多模态数据直接保存为后续训练所需的格式。这样，实验流程能够从物理数据采集自然过渡到模型微调和推理部署。

表 4.1 实验环境

实验环境	描述
操作系统	Ubuntu 22.04 LTS
CPU	Intel(R) Xeon(R) Gold 6230R CPU @ 2.10GHz
显卡	NVIDIA GeForce RTX 3090
编程语言	Python 3.10
核心依赖	PyTorch, torchvision, numpy, opencv-python
具身与仿真环境	lerobot, mujoco, wandb, peft
计算加速	CUDA 12.9, cuDNN


4.1.2 SO-101 机械臂平台

确定计算环境后,需要搭建真实机械臂执行平台。本文选用 SO-101 桌面级机械臂作为物理执行端。SO-101 属于串联关节型机械臂,本体具有 6 个自由度 (6-DoF),末端配备一个平行开合夹爪。机械臂整体由多个旋转关节串联构成,包括基座水平旋转、肩部俯仰、肘部俯仰以及手腕姿态调节等关节。对于桌面抓取任务而言,六自由度结构能够满足末端执行器在三维空间中的位置和姿态调整需求。

在底层驱动方面,SO-101 使用总线伺服电机。该类电机不仅能够接收上位机下发的目标角度指令,还能回传当前关节角度、运动速度和电机状态等信息。与只能单向接收脉冲信号的普通舵机相比,总线电机的双向通信能力更适合机器人学习实验。系统可以在采集专家动作的同时记录机械臂真实执行状态,也可以在实机推理阶段根据状态反馈进行限幅和安全控制。



(a) 主控端机械臂



(b) 从动端机械臂

图 4.1 SO-101 主从遥操作硬件平台

如图 4.1 所示,主从遥操作系统由主控端和从动端两部分组成。主控端用于采集操作员的示教动作,从动端负责在桌面环境中执行实际抓取任务。通过这种方式,操作员可以利用较自然的手臂运动完成示教,而系统则同步记录从动机械臂的视觉观测、关节状态和动作指令。

此外，SO-101 控制板支持串口通信协议，便于 Python 程序直接接入控制链路。实验中，上位机通过串口向各关节电机发送目标角度，并读取电机反馈状态。该接口为后续将模型输出动作转化为机械臂底层控制指令提供了基础。

4.1.3 LeRobot 数据流和控制调度

在完成 SO-101 机械臂平台搭建后，本文采用 LeRobot 框架组织遥操作数据采集、模型训练和实机推理流程。LeRobot 是面向真实机器人学习任务的开源框架，能够将相机图像、机器人状态、动作指令和语言标签整理为统一的数据格式，并与 PyTorch 训练代码和机器人硬件接口相连接^[31]。因此，LeRobot 在本文中并不是单纯的软件依赖，而是连接数据采集、模型微调和实机部署的重要工程链路。

在实机数据采集和推理过程中，LeRobot 主要承担三方面作用。第一，它负责从环境相机和机械臂接口中读取观测数据，包括 RGB 图像、关节角、夹具状态等信息；第二，它将不同来源的数据封装为模型可以读取的张量格式，使图像、状态和语言指令能够共同输入 VLA 模型；第三，它负责将模型输出的动作转换为机械臂控制接口可以接收的指令，并在执行后继续记录新的状态反馈。通过这一流程，系统能够形成从感知采集、模型推理、动作解码到机械臂执行的闭环链路。

如图 4.2 所示，LeRobot 数据流可以分为传感器采集、数据预处理、策略模型推理、动作解码、机械臂执行和状态反馈等环节。相机和关节编码器负责提供环境观测与本体状态，数据预处理模块将原始信息整理为模型输入，VLA 策略模型根据当前观测输出动作块，动作解码模块再将其转化为机械臂可以执行的控制指令。机械臂执行后产生新的图像和状态反馈，并进入下一轮推理。




图 4.2 LeRobot 框架中的数据流和控制调度示意图

在实机推理阶段，模型输出的动作通常不能直接作用于电机，而需要经过运动学转换和安全约束处理。若模型输出为末端执行器位姿变化量，系统需要通过逆运动学（Inverse Kinematics, IK）将其转换为各关节角度；若模型输出为关节空间动作，也需要进行关节角限幅、速度限制和平滑滤波。对于低成本桌面机械臂而言，底层

控制精度、通信频率和机械间隙都会影响最终执行效果，因此 LeRobot 数据流与机械臂控制接口之间的稳定连接，是后续实机抓取实验能够顺利完成的基础。

4.1.4 遥操作数据采集

VLA 模型的本地微调需要依赖高质量专家示范数据。为了获得更接近真实任务的动作轨迹，本文搭建了基于“主-从 (Leader-Follower)”结构的遥操作数据采集平台。相比键盘或手柄控制，主从遥操作能够更自然地表达机械臂末端在空间中的移动过程，也能减少人工控制方式带来的不连续动作^[17,46]。在数据录制过程中，从动端 SO-101 机械臂固定在桌面工作区内，负责执行抓取任务；操作员移动主控端机械臂，系统实时读取主控端关节状态，并将其映射为从动端目标动作。从动端执行动作的同时，系统保存环境相机图像、夹爪相机图像、机械臂状态、动作指令和任务语言标签，为后续 VLA 模型微调提供多模态训练样本。

如图 4.3 所示，本文搭建了基于 SO-101 的桌面遥操作数据采集工作台。工作台包含主从机械臂、目标水果、环境相机、夹爪相机和上位机控制程序。环境相机布置在桌面外侧，用于记录机械臂、桌面环境和目标物体之间的整体空间关系；夹爪相机安装在末端执行器附近，用于记录夹爪接近目标时的局部细节。两路视觉信息与关节状态和动作指令共同构成后续模型训练所需的多模态数据。






图 4.3 基于 SO-101 的桌面遥操作数据采集工作台

为了进一步说明双相机输入的作用，本文从数据采集视频中截取了同一时刻的环境相机和夹爪相机画面，如图 4.4 所示。环境相机提供全局空间信息，有助于模

型判断目标物体与机械臂之间的相对位置；夹爪相机提供末端附近的局部视觉细节，有助于模型在接近和夹取阶段观察目标物体边缘、夹爪开合状态以及接触情况。两路相机画面在采集时与机械臂关节状态和动作指令进行时间对齐，从而保证训练样本中的图像、状态和动作标签对应同一操作时刻。



(a) 环境相机画面



(b) 夹爪相机画面

图 4.4 遥操作数据采集中的双相机画面

一次完整的专家示范通常包括目标搜索、末端靠近、姿态调整、夹爪闭合和物体抬升等阶段。系统以固定控制频率为每一帧数据打上时间戳，在记录动作指令的同时，同步保存两路 RGB 图像和底层电机反馈的关节状态。采集完成后，系统剔除明显失败、遮挡严重或通信异常的数据片段，保留有效轨迹作为后续模型微调数据。

4.1.5 数据封装和时序对齐

VLA 模型的训练依赖多模态示范数据。一次完整的机器人操作演示通常被保存为一个回合 (Episode)，其中包含图像观测、机器人本体状态、动作标签和任务语言描述。本文通过 LeRobot 框架将遥操作过程中采集到的多源数据整理为统一格式，使其能够直接用于后续模型微调。

在数据字段上，本文采集的数据主要包括四类信息。第一类是图像观测 (Image)，即环境相机采集到的 RGB 图像，用于提供桌面目标物体、机械臂位置和周围环境布局等视觉信息。第二类是机器人状态 (State)，包括机械臂关节角、夹爪开合状态等本体信息，用于描述机器人当前物理状态。第三类是动作标签 (Action)，即遥操作过程中专家在当前观测下给出的控制指令，是模型训练时需要拟合的目标。第四类是语言指令 (Language Instruction)，用于描述当前操作任务，例如“抓取橘子”“将香蕉放入盘中”等，使模型能够学习语言目标与动作序列之间的对应关系。

由于图像、关节状态和控制动作的采样频率并不完全一致，若直接按照原始采样顺序拼接，容易出现图像观测、机器人状态和动作标签不对应的问题。为此，本文

在数据整理阶段进行了多模态时序对齐。具体而言，以统一时间轴为基准，对图像帧、关节状态和动作指令进行匹配；对于连续的关节角和末端位姿数据，可采用线性插值方式进行重采样；对于缺失帧或异常帧，则进行剔除或跳过处理。

时序对齐的目的，是保证模型在训练时看到的图像和状态能够对应专家在相近时刻给出的动作。如果图像滞后或动作标签提前，模型可能学习到错误的输入输出关系，进而影响实机控制效果。因此，在数据封装过程中，需要同时关注数据字段是否完整、时间戳是否连续、动作频率是否稳定以及语言标签是否与任务内容一致。

经过上述处理后，原始遥操作数据被整理为可用于模型微调的数据集。该数据集不仅记录了机械臂完成水果抓取任务时的视觉观测和动作轨迹，也保留了对应的语言任务描述，为后续基于 LoRA 的模型微调提供了训练基础。

4.2 模型微调和训练记录

通用 VLA 模型虽然具备一定的视觉语言理解能力，但要在本文搭建的 SO-101 桌面抓取平台上稳定执行任务，仍需要利用本地数据进行适配。由于全参数微调会带来较高显存占用和较长训练时间，本文采用参数高效微调方法，在尽量保留预训练模型通用能力的同时，使模型学习本地机械臂的动作分布和实验场景特征。本节介绍 LoRA 微调方法、训练配置和训练曲线分析。

4.2.1 LoRA 微调方法

在工程实施阶段，系统调用 LeRobot 的训练流水线脚本，将序列化后的本地数据集与预训练基座模型进行绑定。由于 VLA 模型通常包含大量参数，如果直接对全部权重进行端到端微调，不仅需要较大的显存空间，还会显著增加训练时间。本文所使用的本地计算平台虽然能够完成模型推理和小规模训练，但受限于 RTX 3090 显卡的显存容量，难以承担全参数微调带来的计算压力。因此，本文采用低秩自适应 (Low-Rank Adaptation, LoRA) 方法进行参数高效微调^[47]。

LoRA 的基本思想是冻结原始预训练模型中的主干权重，只在部分线性层旁边增加少量可训练参数。对于原始权重矩阵 $W_0 \in \mathbb{R}^{d \times k}$ ，全参数微调需要直接更新 W_0 中的全部参数；而 LoRA 将权重更新量表示为两个低秩矩阵的乘积：

$$W = W_0 + \Delta W = W_0 + BA, \quad (4.1)$$

其中， $A \in \mathbb{R}^{r \times k}$ ， $B \in \mathbb{R}^{d \times r}$ ， r 为远小于 d 和 k 的低秩维度。训练过程中，原始权重 W_0 保持冻结，只更新矩阵 A 和 B 。这样，模型能够在保留预训练知识的同时，用较少参数学习本地任务中的新特征。

在 VLA 模型中, LoRA 通常被加入到 Transformer 的注意力投影层或前馈网络层中。对于本文的抓取任务而言, 预训练模型已经具备基本的视觉识别、语言理解和空间表征能力, 需要重点适配的是 SO-101 机械臂的动作分布、实验桌面环境以及橘子、香蕉和樱桃等目标物体的局部视觉特征。因此, 采用 LoRA 微调可以避免破坏模型已有的通用表征能力, 同时降低本地训练的显存占用和过拟合风险。

模型训练目标仍然建立在流匹配动作生成框架之上。网络接收当前观测特征 o_t 和加噪动作块 A_t^τ , 并预测去噪方向。其损失函数可表示为:

$$\mathcal{L}(\theta) = \mathbb{E}_{t \sim \mathcal{U}(0,1), \epsilon \sim \mathcal{N}(0,I)} \left[\left\| \epsilon - v_\theta(A_t^\tau, o_t, \tau) \right\|_2^2 \right]. \quad (4.2)$$

其中, ϵ 为注入动作块的高斯噪声, v_θ 为模型预测的向量场, τ 为去噪时间步。训练过程的目标是让模型根据当前视觉观测、语言指令和机器人状态, 逐步恢复出接近专家示范的连续动作块。

在优化器设置上, 本文采用 AdamW 优化器进行参数更新。AdamW 在梯度下降的基础上引入权重衰减, 有助于抑制小规模本地数据集训练时可能出现的过拟合。学习率调度采用线性预热和余弦退火相结合的方式: 训练初期学习率逐步升高, 避免模型更新过快导致梯度不稳定; 训练后期学习率平滑下降, 使模型逐渐收敛。动作块长度设置为 50, 使模型能够一次预测未来一段时间内的动作序列, 从而提高机械臂运动的连贯性。

4.2.2 训练过程和权重保存

模型训练过程中, 系统通过 WandB 平台记录损失、学习率、梯度范数和单步更新时间等指标。训练数据来自前一节采集的 SO-101 遥操作数据集, 输入包括多视角图像、机器人状态、语言指令和专家动作标签。训练脚本按照 batch 读取数据, 并将图像和状态张量送入模型, 动作专家根据当前观测预测连续动作块。在训练初期, 模型需要快速适应本地数据的动作分布, 因此损失值通常下降较快; 随着训练步数增加, 模型逐渐从学习宏观运动规律转向学习更细节的动作调整, 例如夹爪接近目标时的姿态变化、不同水果对应的抓取角度以及抬升阶段的动作平滑性。当验证集损失趋于稳定后, 系统保存对应权重检查点 (Checkpoints), 用于后续仿真和实机推理。权重保存时, 系统主要保留 LoRA 增量参数和必要的模型配置文件, 从而减少模型文件体积, 并便于在推理阶段快速加载。与保存完整模型相比, 仅保存 LoRA 权重更适合多任务实验, 因为不同任务可以对应不同增量权重, 而共享同一个预训练基座模型。

4.2.3 训练曲线分析

将桌面遥操作数据集送入模型后,本文对 SmolVLA 动作专家网络进行 LoRA 微调训练。训练过程中,系统通过 WandB 平台记录损失、学习率、梯度范数和单步更新时间等指标,用于判断模型是否稳定收敛。下面分别对四类训练曲线进行分析。

训练损失曲线如图 4.5 所示。损失值在训练初期下降较快,说明模型较快学习到遥操作数据中的基础运动规律,例如机械臂向目标靠近、调整末端姿态以及闭合夹爪等动作模式。随着训练步数增加,损失下降速度逐渐放缓,并在后期趋于平稳。这表明模型基本适应了本地数据集中的动作分布,没有出现明显发散现象。



图 4.5 SmolVLA 微调训练损失曲线

其次,学习率调度曲线如图 4.6 所示。训练采用线性预热和余弦退火相结合的调度策略。在训练初期,学习率从较小值逐步升高,使模型能够平稳进入参数更新阶段;随后学习率按照余弦曲线逐渐下降,使模型在训练后期以较小步长进行细化更新。这种调度方式能够在保证训练速度的同时,降低后期震荡风险。



图 4.6 SmolVLA 微调学习率调度曲线

再次，梯度范数变化如图 4.7 所示。训练初期由于学习率逐步升高，梯度范数出现一定波动；进入稳定训练阶段后，梯度范数逐渐降低并保持在较小范围内波动。这说明反向传播过程较为稳定，没有出现明显的梯度爆炸或梯度消失问题。对于 LoRA 微调而言，梯度范数稳定也说明新增低秩参数能够较好地吸收本地数据带来的任务差异。




图 4.7 SmolVLA 微调梯度范数曲线

最后，单步更新时间如图 4.8 所示。曲线整体保持在较稳定范围内，说明训练过程中数据读取、前向推理、反向传播和参数更新之间没有出现明显阻塞。单步耗时的稳定性表明当前工作站能够支持本地数据集上的 LoRA 微调任务，也说明模型训练过程没有受到显存溢出或数据加载瓶颈的明显影响。



图 4.8 SmolVLA 微调单步更新时间曲线

综合图 4.5 至图 4.8 可以看出，模型训练过程整体较为稳定。损失函数能够持续下降并趋于收敛，学习率调度符合预期，梯度范数没有出现异常波动，单步训练

耗时也保持稳定。因此,本文保存训练后期表现较好的模型权重,并将其用于后续 LIBERO 仿真测试和真实 SO-101 机械臂抓取实验。

4.3 LIBERO 仿真测试

在真实机械臂上直接测试未充分验证的模型,可能会带来动作越界、夹爪误触或机械臂碰撞等风险。因此,在实机部署之前,本文先使用 LIBERO 仿真平台检查模型输入输出、动作解码和环境交互流程是否正常。LIBERO (Lifelong Robot Learning Benchmark) 提供了面向桌面操作任务的标准化仿真环境,能够从空间位置、物体类别、任务目标和长程执行等角度评估模型表现^[29]。对于本文而言,LIBERO 的主要作用不是替代真实机械臂实验,而是在实机部署前提供一个中间验证环境。

4.3.1 仿真平台和任务建模

从决策建模角度看,LIBERO 中的机器人任务可以表示为部分可观察马尔可夫决策过程 (Partially Observable Markov Decision Process, POMDP)。该过程通常用元组 $(S, A, P, R, \Omega, O, \gamma)$ 表示,其中 S 为真实环境状态空间, A 为动作空间, P 为状态转移概率, R 为奖励函数, Ω 为观测空间, O 为观测概率, γ 为折扣因子。由于 VLA 模型主要通过相机图像和机器人状态进行判断,无法直接获取完整物理世界状态,因此桌面操作任务更符合部分可观察条件下的决策问题。

LIBERO 平台包含多种桌面操作任务类型,可以从不同角度考察模型能力。空间泛化任务主要改变物体初始位置和空间布局,用于检验模型对三维空间关系和目标位置变化的适应能力;对象泛化任务保持任务形式相近,但更换目标物体的类别、外观或纹理,用于检验模型是否能够将语言目标与新的视觉特征对应起来;目标泛化任务在相似场景中改变自然语言任务目标,用于检验模型对指令语义和动作目标变化的理解能力;长程任务由多个基础操作步骤组成,更关注模型在较长时间执行中的上下文保持和误差累积问题。

LIBERO 的物理交互依托 MuJoCo 物理引擎实现。MuJoCo 的英文全称为 Multi-Joint dynamics with Contact,主要用于模拟多关节系统和接触动力学^[30]。在机器人操作任务中,机械臂和物体之间的接触、夹爪闭合、物体滑动和碰撞等现象都会影响最终任务结果。相比只判断末端执行器是否到达目标点的简化环境,基于物理引擎的仿真能够更接近真实操作过程。

在模型测试时,环境会根据机器人执行的动作更新机械臂和物体状态,并返回新的图像观测、机器人状态和任务完成信息。VLA 模型根据这些反馈继续预测下一步动作,从而形成闭环交互。对于抓取、放置和推拉等任务而言,状态反馈不仅包括

目标物体位置，还包括夹爪和物体之间的接触关系。若模型动作过大、方向错误或输出维度不匹配，环境状态会迅速偏离目标轨迹，最终导致任务失败。因此，LIBERO 仿真测试能够在一定程度上帮助发现模型加载、动作解码和环境接口中的问题。

本文使用 LIBERO 的目的主要有两个。第一，检查模型权重加载、输入输出维度和动作解码流程是否正确，避免直接在实机上暴露接口错误。第二，在相对统一的仿真环境中观察模型是否能够完成基本动作推理，为真实机械臂部署提供参考。需要说明的是，仿真结果并不能完全代表真实机械臂表现，真实环境中仍然存在相机噪声、机械臂间隙、摩擦差异和控制延迟等因素，因此本文最终仍以 SO-101 机械臂实机抓取结果作为主要验证依据。

4.3.2 环境初始化和权重加载

LIBERO 平台底层由 MuJoCo 物理引擎驱动，能够模拟机械臂和桌面物体之间的接触关系。在仿真初始化阶段，系统加载微调后保存的模型权重检查点，并构建对应的虚拟桌面环境。仿真环境会生成相机观测图像和机器人初始状态，随后将自然语言任务指令、视觉观测和状态信息一起送入模型推理管线。

在权重加载过程中，需要保证模型结构、动作维度和输入数据格式与训练阶段保持一致。如果图像尺寸、状态向量维度或动作解码方式发生不匹配，模型虽然能够加载权重，但输出动作可能无法被仿真环境正确执行。因此，本文在仿真阶段重点检查了模型输入输出维度、动作范围和执行频率等内容。

4.3.3 仿真结果和分析

在虚拟环境中，微调后的模型能够根据任务指令输出较平滑的动作块。实验对虚拟物体进行了多次随机初始位姿抓取测试，模型通过流匹配动作专家生成连续控制序列，并由仿真环境执行对应动作。相比未微调模型，微调后的模型在目标接近、夹爪闭合和放置阶段的动作更加稳定。

图 4.9 展示了本地微调模型在 LIBERO 仿真环境中的一段完整执行过程。图 4.9(a) 为仿真场景初始状态，目标物体和干扰物被随机放置在桌面上；图 4.9(b) 展示了机械臂根据模型输出向目标区域移动；图 4.9(c) 为末端夹爪接近目标并完成夹取；图 4.9(d) 展示了机械臂将目标物体移动到指定位置。

统计结果显示，系统在虚拟环境中的抓取成功率达到 88.5%。在多数测试中，机械臂能够根据目标位置生成合理趋近轨迹，并在夹爪闭合后完成物体移动。仿真结果说明，LoRA 微调后的模型能够学习到本地抓取任务中的基本动作规律，模型推理链路和动作解码流程也能够正常运行。不过，仿真环境中的光照、物体接触和电机响应仍较理想，因此还需要进一步开展实机测试。




图 4.9 LIBERO 仿真环境下的任务执行关键帧

4.4 实机部署和抓取测试

在仿真测试通过后，本文将微调模型部署到真实 SO-101 机械臂平台上进行闭环抓取验证。实机部署的关键在于将模型输出的动作张量转化为机械臂能够执行的底层控制指令，并在执行过程中处理机械臂运动学约束、角速度限制和通信延迟等问题。本节介绍实机控制数据流、逆运动学求解和水果抓取实验结果。

4.4.1 逆运动学和通信接口

模型输出的动作序列表示机械臂末端执行器的期望空间位置、姿态变化和夹爪动作。由于底层伺服电机只能接收关节角度控制指令，因此系统需要将模型输出的笛卡尔空间动作转换为各个关节的目标角度。图 4.10 展示了实机闭环控制的数据流转路径。

首先，控制程序接收模型输出的末端目标位姿，并调用针对 SO-101 连杆结构编写的逆运动学（Inverse Kinematics, IK）求解器。逆运动学求解器根据机械臂各连杆长度和关约束，将末端空间位姿转换为基座、肩部、肘部和腕部等关节的目标角




图 4.10 实机闭环控制数据流

度。如果某一目标位姿超出机械臂工作空间，系统会对其进行裁剪或限制，避免生成不可执行指令。

其次，系统对关节角度进行安全处理。真实机械臂存在通信延迟、传动间隙和电机响应滞后，如果直接下发未经处理的目标角度，可能导致关节出现突变或抖动。为此，系统在动作下发前加入平滑滤波和角速度限幅，使相邻控制周期之间的角度变化保持在合理范围内。对于夹爪动作，系统同样设置开合范围，避免夹爪过度闭合造成电机堵转。

最后，处理后的角度指令被格式化为电机通信协议对应的数据帧，并通过串口发送给底层总线伺服电机。电机接收指令后，由内部控制器完成位置闭环控制。与此同时，上位机持续读取电机回传状态，用于记录执行过程和判断是否存在异常动作。


4.4.2 实机抓取结果和误差分析

在真实实验室环境中，本文使用加载微调权重的控制系统，对桌面上的橘子、香蕉和樱桃进行了闭环抓取测试。考虑到夹爪相机画面中容易出现操作人员或无关背景信息，论文展示部分仅选用环境相机画面作为实机过程图。环境相机能够较完整地记录机械臂、桌面和目标物体之间的整体空间关系，也更适合用于展示机械臂从靠近目标到完成抓取的完整动作过程。


为了更直观地展示模型在真实机械臂上的执行过程，本文从环境相机视频中选取了四个关键帧，如图 4.11 所示。该过程覆盖了从目标识别与靠近、夹爪闭合抓取、移动到盘子并放置目标，到机械臂恢复原位的完整任务流程。考虑到夹爪相机画面中容易出现操作人员或无关背景信息，论文展示部分仅采用环境相机画面。

从图 4.11 可以看出，模型能够根据环境相机提供的桌面整体信息，控制机械臂完成目标水果识别、靠近、抓取、转移、放置以及恢复原位等动作。该过程说明微调后的模型不仅能够完成单次夹取动作，也能够较完整的桌面操作流程中保持动作连贯性。


在量化测试中，本文分别对三类水果进行了 50 次独立抓取实验。实验结果显示，形态较规则、尺寸较大的橘子抓取成功率为 82%；香蕉具有明显方向性，对末端姿态约束更强，抓取成功率为 76%；樱桃体积较小，在图像中占据像素较少，同时对夹爪定位精度要求较高，抓取成功率为 65%。整体结果表明，模型能够在多数情况




(a) 识别目标并靠近水果



(b) 夹爪对准并闭合抓取



(c) 移动到盘子并放入盘中



(d) 机械臂恢复原位

图 4.11 环境相机视角下的真实机械臂抓取与放置过程关键帧

下根据语言指令和视觉输入完成目标识别、接近、夹取和抬升动作，但不同目标物体的几何形态会明显影响最终抓取效果。

实机测试的整体成功率低于 LIBERO 仿真环境中的 88.5%，这一差异主要来自仿真到现实之间的差距。首先，真实相机图像会受到实验室光照、阴影、反光和镜头畸变影响，目标边界不如仿真图像清晰。特别是樱桃这类小目标，在环境相机画面中占据区域较小，容易受到背景颜色和桌面反光干扰，导致模型对目标中心位置的判断出现偏差。

其次，真实机械臂的运动执行并不完全等同于仿真环境。SO-101 机械臂在运动过程中存在齿轮间隙、连杆微小形变和电机响应滞后，夹爪闭合时也可能出现轻微偏移。这些误差在抓取橘子等较大物体时影响较小，但在抓取樱桃等小目标时会被明显放大。此外，真实物体表面的摩擦系数、重量分布和受力变形也难以完全通过仿真建模，因此模型在仿真中表现稳定，并不代表在实机中一定能够达到相同效果。

虽然实机成功率相比仿真有所下降，但模型在多数情况下能够根据语言指令识别目标物体，并生成合理的接近、夹取和抬升动作。实验结果说明，从遥操作数据采集、LoRA 微调到实机闭环控制的整体流程是可行的。对于低成本桌面机械臂平台而言，该结果也表明 VLA 模型可以通过少量本地数据适配具体任务，但后续仍需要在数据规模、视觉鲁棒性和底层控制精度方面继续改进。

4.5 本章小结

本章围绕 SO-101 桌面机械臂平台，介绍了从实验环境搭建、数据采集、模型微调到实机抓取测试的完整实现过程。首先，说明了深度学习计算环境、SO-101 机械臂平台以及 LeRobot 数据流和控制调度方式，明确了图像观测、机器人状态、语言指令和动作输出在系统中的流转关系。随后，基于主从遥操作方式采集了面向水果抓取任务的多模态示范数据，并通过数据封装和时序对齐形成可用于模型微调的数据集。

在模型训练部分，本文采用 LoRA 方法对 VLA 模型进行参数高效微调，在降低显存占用的同时，使模型能够适应本地桌面环境和 SO-101 机械臂的动作分布。训练过程中，损失、学习率、梯度范数和单步更新时间等指标整体保持稳定，说明模型微调过程具有一定收敛性。在实机部署之前，本文将 LIBERO 仿真平台作为中间验证环境，用于检查模型权重加载、动作解码和环境交互流程。最后，本文将微调后的模型部署到真实 SO-101 机械臂平台，通过逆运动学求解、动作限幅和平滑滤波完成底层控制，并在橘子、香蕉和樱桃等水果抓取任务中验证了系统执行能力。

实验结果表明，基于 LeRobot 数据链路、LoRA 微调和 SO-101 机械臂的实机部署流程能够完成基本的自然语言指令抓取任务。但同时，系统仍受到视觉噪声、机械臂控制精度、目标物体几何差异以及仿真到现实差距等因素影响，后续仍需要在数据规模、感知鲁棒性和底层安全控制方面进一步改进。

第五章 总结与展望

5.1 总结

本文围绕面向具身操作的视觉-语言-动作 (Vision-Language-Action, VLA) 模型展开研究, 重点关注 VLA 模型在低成本桌面机械臂平台上的训练、推理和实机部署问题。针对传统机器人系统中感知、语言理解和底层控制相对分离的问题, 本文结合 LeRobot 框架、LIBERO 仿真平台和 SO-101 桌面机械臂, 完成了从模型结构分析、数据采集、参数高效微调到实机抓取验证的实验流程。

在理论分析方面, 本文首先梳理了具身智能和 VLA 模型的发展背景, 说明了传统模块化机器人系统在开放场景和自然语言交互任务中的不足。随后, 围绕 Transformer 注意力机制、动作表征方式和连续动作生成方法进行了说明。针对机器人动作空间连续、高维且对实时性要求较高的特点, 本文对动作离散化和连续动作生成进行了比较, 并重点分析了连续标准化流、条件流匹配和最优传输路径在动作块生成中的作用。这些内容为后续理解 π_0 与 SmolVLA 模型的动作专家网络提供了理论基础。

在模型结构分析方面, 本文对 π_0 与 SmolVLA 两类代表性 VLA 模型进行了比较。SmolVLA 主要面向低成本机器人和本地部署场景, 通过视觉 Token 压缩、层跳过策略、动作专家网络和异步推理调度降低推理开销, 更适合在普通实验室或教学平台上进行实机验证。 π_0 则更加关注跨机器人形态的通用控制能力, 通过较大规模的视觉语言模型、动作专家网络和统一维度对齐方式, 提升模型在复杂任务和多平台场景下的适应能力。二者分别体现了轻量化本地部署和大规模通用控制两种不同的技术路线, 也为本文后续实验平台的选择提供了参考。

在工程实现方面, 本文基于 SO-101 桌面机械臂搭建了主从遥操作数据采集平台, 采集了面向水果抓取任务的多模态示范数据, 并将图像、机器人状态、动作指令和语言标签整理为可用于模型训练的数据格式。在训练阶段, 本文采用低秩自适应 (Low-Rank Adaptation, LoRA) 方法对模型进行参数高效微调, 在降低显存占用的同时, 使模型能够适应本地实验环境和 SO-101 机械臂的动作分布。训练曲线表明, 模型损失能够逐渐下降并趋于稳定, 学习率、梯度范数和单步更新时间等指标也保持在较合理范围内。

在部署验证方面, 本文先在 LIBERO 仿真环境中测试了模型权重加载、动作解码和环境交互流程, 随后将微调后的模型部署到真实 SO-101 机械臂上进行抓取实验。实机测试中, 系统能够根据自然语言指令和环境相机画面, 控制机械臂完成目标

水果接近、夹取、转移、放入盘中以及复位等动作。不同水果的抓取结果表明,该系统在规则形状和尺寸较大的目标上表现较好,而在体积较小或姿态约束较强的目标上仍存在一定失败率。总体来看,本文验证了在低成本桌面机械臂平台上进行 VLA 模型本地微调和实机闭环部署的可行性。

5.2 展望

虽然本文完成了从数据采集、模型微调到实机抓取验证的基本流程,但受限于实验条件、数据规模和硬件平台,当前系统仍存在一些不足,后续还需要进一步改进。

首先,数据集规模和场景覆盖范围仍然有限。本文采集的数据主要集中在固定桌面环境和少量水果目标上,虽然能够支持模型完成基本抓取任务,但还不足以覆盖复杂背景、不同光照、目标遮挡、物体姿态大幅变化等情况。当目标位置偏移较大、桌面背景变复杂或环境光照发生明显变化时,模型可能出现定位偏差,进而影响抓取动作的稳定性。后续可以增加遥操作数据采集时长,扩展目标物体种类和摆放方式,并引入不同光照和背景条件下的数据,以提高模型对真实环境变化的适应能力。

其次,当前实验评估仍以任务成功率和过程观察为主,量化指标还不够充分。本文对不同水果的抓取成功率进行了统计,但对末端轨迹误差、夹爪闭合误差、模型推理延迟、动作平滑度和控制周期稳定性等指标分析还不够细。后续可以建立更加完整的测试集和评价标准,例如记录每次抓取中的末端位置误差、动作块生成时间、关节速度变化和任务完成时间等数据,从而更准确地分析模型微调和控制策略对系统性能的影响。

再次,感知输入仍然存在局限。本文实机结果展示主要采用环境相机画面,系统虽然在采集和训练阶段可以使用多路视觉信息,但整体感知仍以 RGB 图像为主,缺少深度信息和触觉反馈。在目标被遮挡、物体颜色与背景接近或夹爪接触状态不明显时,仅依赖视觉图像容易造成判断误差。后续可以考虑引入 RGB-D 相机、腕部相机、力传感器或夹爪触觉传感器,使系统能够同时获取目标空间位置、距离信息和接触状态,从而提高抓取阶段的稳定性。

此外,底层控制和安全机制仍需加强。当前系统主要通过逆运动学求解、角速度限幅和平滑滤波来约束机械臂动作,但对于异常动作、潜在碰撞和模型输出越界等情况,仍缺少更完整的安全保护机制。若模型在某些未见过的状态下输出异常动作,机械臂仍可能出现不合理运动。后续可以在模型输出和电机控制之间加入安全检查模块,对末端工作空间、关节角度范围、速度变化和碰撞风险进行实时判断。当

检测到异常动作时，系统应能够自动停止、回退到安全位姿或提示人工接管。

最后，模型部署方式还可以进一步优化。SmolVLA 这类轻量化模型适合本地部署，但在复杂任务理解和长程操作方面仍有提升空间； π_0 这类大规模模型具有更强的通用性，但对算力和数据要求更高。后续可以尝试采用分层控制思路，让云端或高性能主机负责语言理解和长时序任务规划，让本地轻量化模型负责高频动作生成和实时控制。通过这种方式，可以在语义理解能力和底层控制实时性之间取得更好的平衡。

综上，本文完成了低成本桌面机械臂上 VLA 模型训练与部署的初步验证，但距离稳定、可靠、可推广的具身操作系统仍有一定距离。后续研究需要在数据扩展、多模态感知、量化评估和安全控制等方面继续完善，使 VLA 模型能够更好地适应真实机器人操作场景。

插图索引

图 1.1	具身智能系统的“感知-决策-执行”闭环交互逻辑图	1
图 1.2	传统模块化机器人系统与端到端 VLA 模型架构对比图	2
图 1.3	VLA 模型发展时间线 ^[25]	5
图 1.4	OpenVLA 模型结构示意图 ^[35]	6
图 1.5	论文主要内容与章节安排	8
图 2.1	4E 认知框架在 VLA 机械臂抓取任务中的对应关系	11
图 2.2	Transformer 架构示意图 ^[22]	13
图 2.3	连续动作空间离散化	14
图 3.1	扩散模型和最优传输流匹配去噪轨迹对比	19
图 3.2	π_0 模型整体结构示意图 ^[43]	20
图 3.3	π_0 模型块级因果注意力掩码结构	21
图 3.4	SmolVLA 模型整体结构示意图 ^[36]	23
图 3.5	SmolVLA 特征压缩和层跳过策略示意图	24
图 4.1	SO-101 主从遥操作硬件平台	29
图 4.2	LeRobot 框架中的数据流和控制调度示意图	30
图 4.3	基于 SO-101 的桌面遥操作数据采集工作台	31
图 4.4	遥操作数据采集中的双相机画面	32
图 4.5	SmolVLA 微调训练损失曲线	35
图 4.6	SmolVLA 微调学习率调度曲线	35
图 4.7	SmolVLA 微调梯度范数曲线	36
图 4.8	SmolVLA 微调单步更新时间曲线	36
图 4.9	LIBERO 仿真环境下的任务执行关键帧	39
图 4.10	实机闭环控制数据流	40
图 4.11	环境相机视角下的真实机械臂抓取与放置过程关键帧	41

表格索引

表 1.1 传统机器人操作方法与 VLA 模型的优缺点对比..... 4

表 2.1 常见动作离散化方法对比 15

表 3.1 π_0 和 SmolVLA 模型架构及部署特性对比 26

表 4.1 实验环境 29

参考文献

- [1] 白辰甲, 许华哲, 李学龙. 大模型驱动的具身智能: 发展与挑战 [J]. 中国科学: 信息科学, 2024, 54 (9): 2035–2082.
- [2] 王文晟, 谭宁, 黄凯, 等. 基于大模型的具身智能系统综述 [J]. 自动化学报, 2025, 51 (1): 1–19.
- [3] 赵博涛, 亢祖衡, 瞿晓阳. 基于多模态大模型的具身智能体研究进展与展望 [J]. 大数据, 2025, 11 (3): 108–138.
- [4] Chi C, Feng S, Du Y. Diffusion Policy: Visuomotor Policy Learning Via Action Diffusion [C]. In Robotics: Science and Systems (RSS), 2023.
- [5] 郑南宁, 杨勔, 姜维周, 等. 具身智能发展趋势与展望 [J]. 中国工程科学, 2026, 28 (2).
- [6] 沈甜雨, 陶子锐, 王亚东, 等. 具身智能研究的关键问题: 自主感知、行动与进化 [J]. 自动化学报, 2025, 51 (1): 43–71.
- [7] Nair S, Rajeswaran A, Kumar V. R3M: A Universal Visual Representation For Robot Manipulation [C]. In Proceedings of the Conference on Robot Learning, 2023: 892–909.
- [8] Reed S, Zolna K, Parisotto E, 等. A Generalist Agent [J]. arXiv preprint arXiv:2205.06175, 2022.
- [9] 曾凯, 王耀南, 谭浩然. AI 大模型驱动的具身智能人形机器人技术与展望 [J]. 中国科学: 信息科学, 2025, 55 (5): 967–992.
- [10] 张慧, 梁姝彤, 李明轩. 视觉—语言—动作模型综述: 从前史到前沿 [J]. 自动化学报, 2025, 51 (9): 1922–1950.
- [11] Feng Z. Multi-Agent Embodied AI: Advances And Future Directions [J]. arXiv preprint arXiv:2505.05108, 2025.
- [12] Octo Model Team. Octo: An Open-Source Generalist Robot Policy [C]. In Robotics: Science and Systems (RSS), 2024.
- [13] 高超, 杨莹, 陈世超, 等. 多模态模型驱动的具身智能研究综述 [J]. 智能感知工程, 2025, 2 (2): 1–12.
- [14] 陶永, 万嘉昊, 王田苗, 等. 构建具身智能新范式: 人形机器人技术现状及发展趋势综述 [J]. 机械工程学报, 2025, 61 (15): 121–147.
- [15] Shridhar M, Manuelli L, Fox D. CLIPort: What And Where Pathways For Robotic Manipulation [C]. In Proceedings of the Conference on Robot Learning, 2022.
- [16] Walke H R, Black K, Lee A, 等. BridgeData V2: A Dataset For Robot Learning At Scale [C]. In Proceedings of The 7th Conference on Robot Learning, 2023, 229: 1723–1736.
- [17] Zhao T Z, Kumar V, Levine S. Learning Fine-Grained Bimanual Manipulation With Low-Cost Hardware [C]. In Robotics: Science and Systems (RSS), 2023.
- [18] Jiang Y, Gupta A, Zhang Z. VIMA: General Robot Manipulation With Multimodal Prompts [C]. In Proceedings of the 40th International Conference on Machine Learning, 2023, 202: 14975–15022.
- [19] 刘乃军, 鲁涛, 蔡莹皓, 等. 机器人操作技能学习方法综述 [J]. 自动化学报, 2019, 45 (3): 458–470.

- [20] 秦方博, 徐德. 机器人操作技能模型综述 [J]. 自动化学报, 2019, 45 (8): 1401–1418.
- [21] 谢正泰, 樊佳亮, 刘梅, 等. 基于神经网络的机器人学习与控制: 回顾与展望 [J]. 信息与控制, 2023, 52 (1): 37–58.
- [22] Vaswani A, Shazeer N, Parmar N, 等. Attention Is All You Need [C]. In Advances in Neural Information Processing Systems, 2017, 30.
- [23] Guan W, Hu Q, Li A. Efficient Vision-Language-Action Models For Embodied Manipulation: A Systematic Survey [J]. arXiv preprint arXiv:2510.17111, 2025.
- [24] Muhayy U D M, Akram W, Saoud L S. Multimodal Fusion With Vision-Language-Action Models For Robotic Manipulation: A Systematic Review [J]. Information Fusion, 2026, 129: 104062.
- [25] 李浩然, 陈宇辉, 崔文博, 等. 面向具身操作的视觉-语言-动作模型综述 [J]. 自动化学报, 2026, 52 (1): 18–51.
- [26] 梁浩天. 基于“视觉-语言-动作”模型的机器人抓取与投掷技能学习 [D]. 上海: 东华大学, 2025.
- [27] 张谊科, 王耀南, 谢核. 具身智能中的视觉-语言-动作模型: 研究进展与前沿探索 [J]. 计算, 2025, 1 (5): 28–34.
- [28] Lynch C, Sermanet P. Language Conditioned Imitation Learning Over Unstructured Data [C]. In Robotics: Science and Systems, 2021.
- [29] Liu B, Zhu Y, Gao C. LIBERO: Benchmarking Knowledge Transfer For Lifelong Robot Learning [C]. In Advances in Neural Information Processing Systems (NeurIPS), 2023, 36: 44776–44791.
- [30] Todorov E, Erez T, Tassa Y. MuJoCo: A Physics Engine For Model-Based Control [C]. In 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2012: 5026–5033.
- [31] Cadene R, Alibert S, Soare A. LeRobot: State-Of-The-Art Machine Learning For Real-World Robotics In PyTorch. 2024. <https://github.com/huggingface/lerobot>.
- [32] Shridhar M, Manuelli L, Fox D. Perceiver-Actor: A Multi-Task Transformer For Robotic Manipulation [C]. In Proceedings of the Conference on Robot Learning, 2023: 785–799.
- [33] Brohan A, Brown N, Carbajal J. RT-1: Robotics Transformer For Real-World Control At Scale [J]. arXiv preprint arXiv:2212.06817, 2022.
- [34] Brohan A, Brown N, Carbajal J. RT-2: Vision-Language-Action Models Transfer Web Knowledge To Robotic Control [C]. In Conference on Robot Learning (CoRL), 2023: 2165–2183.
- [35] Kim M J, Pertsch K, Karamcheti S. OpenVLA: An Open-Source Vision-Language-Action Model [C]. In Conference on Robot Learning, 2025: 2679–2713.
- [36] Shukor M, Aubakirova D, Capuano F. SmolVLA: A Vision-Language-Action Model For Affordable And Efficient Robotics [J]. arXiv preprint arXiv:2506.01844, 2025.
- [37] Driess D, Xia F, Sajjadi M S M. PaLM-E: An Embodied Multimodal Language Model [C]. In International Conference on Machine Learning, 2023: 8469–8488.
- [38] 张文涛, 孙奥兰, 瞿晓阳. 面向具身智能的视觉-语言-动作模型动作表征和生成策略综述 [J]. 计算机应用, 2026: 1–14.
- [39] Physical Intelligence. $\pi_{0.5}$: A Vision-Language-Action Model With Open-World Generalization [J]. arXiv preprint arXiv:2504.16054, 2025.

- [40] Dosovitskiy A, Beyer L, Kolesnikov A. An Image Is Worth 16x16 Words: Transformers For Image Recognition At Scale [C]. In International Conference on Learning Representations (ICLR), 2021.
- [41] Zhai X, Mustafa B, Kolesnikov A. Sigmoid Loss For Language Image Pre-Training [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 11975–11986.
- [42] Lipman Y, Chen R T Q, Ben-Hamu H. Flow Matching For Generative Modeling [C]. In International Conference on Learning Representations (ICLR), 2023.
- [43] Black K, Brown N, Driess D. π_0 : A Vision-Language-Action Flow Model For General Robot Control [J]. arXiv preprint arXiv:2410.24164, 2024.
- [44] Padalkar A, Pooley A, Jain A. Open X-Embodiment: Robotic Learning Datasets And RT-X Models [C]. In 2024 IEEE International Conference on Robotics and Automation (ICRA), 2024: 6892–6903.
- [45] Khazatsky A, Pertsch K, Nair S. Droid: A Large-Scale In-The-Wild Robot Manipulation Dataset [J]. arXiv preprint arXiv:2403.12945, 2024.
- [46] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation With Low-Cost Whole-Body Teleoperation [J]. arXiv preprint arXiv:2401.02117, 2024.
- [47] Hu E J, Shen Y, Wallis P. LoRA: Low-Rank Adaptation Of Large Language Models [C]. In International Conference on Learning Representations (ICLR), 2022.

致 谢

行文至此，落笔为终。我的本科生涯与毕业论文工作也即将画上句点。回首这段充满挑战与成长的旅程，心中充满感激。在此，我谨向所有给予我指导、帮助与支持的师长、亲友，致以最诚挚的谢意。

首先，最衷心的感谢献给我的论文指导老师，修贤超老师。从论文的选题立意、框架构建，到研究方法、数据收集，再到反复的修改与最终定稿，他始终给予我悉心的指导和无私的帮助。修贤超老师严谨的治学态度、深厚的学术造诣、敏锐的洞察力以及谦和的为师风范，使我受益匪浅。每当研究陷入困境时，他的点拨总让我豁然开朗。在此，向修贤超老师致以最崇高的敬意和最真诚的感谢！

同时，诚挚感谢上海大学机自学院的各位授课老师与领导。感谢你们在四年本科生涯中的谆谆教诲，为我奠定了坚实的专业基础。感谢学院提供的良好学习与科研平台。

感谢我亲爱的同学们和朋友们。感谢各位学长学姐们在本科期间提供的各种帮助。感谢同组的同门，我从你们身上学到了很多。感谢我的室友及好友们，谢谢你们在生活中的陪伴与包容，在情绪低落时的鼓励与支持，你们的欢声笑语是我大学岁月中最温暖的阳光。

感谢我的父母及家人。你们是最坚实的后盾，始终无条件地支持我的每一个决定，给予我全然的信任与爱。你们的默默付出与无私奉献，是我求学路上最强大的动力源泉。养育之恩，无以为报，唯有不断前行，不负期望。

最后，向参与本论文评审和答辩的各位专家、老师致以谢意。感谢你们在百忙之中审阅本文并提出宝贵意见，使我能够进一步完善研究成果。

求学之路暂告段落，人生新章即将开启。我将怀揣所有的感激与收获，继续踏上征程。由于学识有限，文中难免存在疏漏与不足之处，恳请各位师长批评指正。

再次衷心感谢所有关心和帮助过我的人！

曹佳豪
上海大学
2026年5月8日

