

# 第三章 典型优化问题

修贤超

<https://xianchaoxiu.github.io>

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

# 凸优化问题

## ■ 标准形式的凸优化问题

$$\min_{x \in \mathbb{R}^n} f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$a_i^\top x = b_i, \quad i = 1, \dots, p$$

- $f_0, f_1, \dots, f_m$  为凸函数
- $a_i^\top x = b_i$  为线性等式约束

## ■ 经常写成

$$\min_{x \in \mathbb{R}^n} f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$Ax = b$$

# 应用举例

## ■ 考虑

$$\begin{aligned} \min_{x_1, x_2} \quad & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & f_1(x) = x_1/(1 + x_2^2) \leq 0 \\ & h_1(x) = (x_1 + x_2)^2 = 0 \end{aligned}$$

- $f_0$  为凸函数, 可行集  $\{(x_1, x_2) \mid x_1 = -x_2 \leq 0\}$  为凸集
  - $f_1$  非凸,  $h_1$  不是线性函数
- 不是凸问题, 但可转化为凸优化问题

$$\begin{aligned} \min_{x_1, x_2} \quad & x_1^2 + x_2^2 \\ \text{s.t.} \quad & x_1 \leq 0 \\ & x_1 + x_2 = 0 \end{aligned}$$

# 局部和全局极小

## ■ 凸优化问题的任意局部极小点都是全局最优

证明 设  $x$  是局部极小解,  $y$  是全局最优解且  $f_0(y) < f_0(x)$ . 存在  $R > 0$  使

$$z \text{ 可行}, \quad \|z - x\|_2 \leq R \quad \Rightarrow \quad f_0(z) \geq f_0(x)$$

考虑  $z = \theta y + (1 - \theta)x$  且  $\theta = R/(2\|y - x\|_2)$

- $\|y - x\|_2 > R$ , 则  $0 < \theta < 1/2$
- $z$  是两个可行点的凸组合, 则也可行
- $\|z - x\|_2 = R/2$ , 并且


$$f_0(z) \leq \theta f_0(x) + (1 - \theta)f_0(y) < f_0(x)$$

这与  $x$  是局部极小的假设矛盾

# 可微凸优化问题的最优性条件

- 设  $x$  是凸优化问题  $\min_{x \in X} f_0(x)$  的最优解当且仅当  $x$  可行且满足

$$\nabla f_0(x)^\top (y - x) \geq 0, \quad \forall y \in X$$



- 如果  $\nabla f_0(x)$  非零，它定义了可行集  $X$  在  $x$  处的支撑超平面

# 具体含义

## ■ 无约束优化 $x$ 是最优解当且仅当

$$x \in \text{dom } f_0, \quad \nabla f_0(x) = 0$$

## ■ 等式约束优化问题

$$\min f_0(x) \quad \text{s.t.} \quad Ax = b$$

$x$  是最优解当且仅当存在  $v$  使得

$$x \in \text{dom } f_0, \quad Ax = b, \quad \nabla f_0(x) + A^\top v = 0$$

## ■ 非负约束优化问题

$$\min f_0(x) \quad \text{s.t.} \quad x \geq 0$$

$x$  是最优解当且仅当

$$x \in \text{dom } f_0, \quad x \geq 0, \quad \begin{cases} \nabla f_0(x)_i \geq 0, & x_i = 0 \\ \nabla f_0(x)_i = 0, & x_i > 0 \end{cases}$$

# 线性规划基本形式

## ■ 线性规划问题的一般形式

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & Gx \leq e \end{aligned}$$

## ■ 线性规划问题的标准形式

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned}$$

## ■ 线性规划问题的不等式形式

$$\begin{aligned} \max_{y \in \mathbb{R}^n} \quad & b^\top y \\ \text{s.t.} \quad & A^\top y \leq c \end{aligned}$$

## 应用举例：基追踪问题

- 基追踪问题是压缩感知中的一个基本问题，可以写为

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- 对每个  $|x_i|$  引入一个新的变量  $z_i$ ，可以转化为

$$\begin{aligned} \min_{z \in \mathbb{R}^n} \quad & \sum_{i=1}^n z_i \\ \text{s.t.} \quad & Ax = b \\ & -z_i \leq x_i \leq z_i, \quad i = 1, \dots, n \end{aligned}$$

# 应用举例：数据拟合

## ■ 最小 $\ell_\infty$ 范数模型

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_\infty$$

## ■ 令 $t = \|Ax - b\|_\infty$ , 得到等价问题

$$\begin{aligned} & \min_{x \in \mathbb{R}^n, t \in \mathbb{R}} && t \\ & \text{s.t.} && \|Ax - b\|_\infty \leq t \end{aligned}$$

## ■ 利用 $\ell_\infty$ 范数的定义, 可以进一步写为

$$\begin{aligned} & \min_{x \in \mathbb{R}^n, t \in \mathbb{R}} && t \\ & \text{s.t.} && -t\mathbf{1} \leq Ax - b \leq t\mathbf{1} \end{aligned}$$

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

# 最小二乘问题

- 最小二乘问题的一般形式如下

$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^m r_i^2(x)$$

- 如果所有的  $r_i : \mathbb{R}^n \rightarrow \mathbb{R}$  都是线性函数，则称线性最小二乘问题，否则称为非线性最小二乘问题
- 如果噪声服从高斯分布，最小二乘问题的解对应于原问题的最大似然解
- 1801 年，24 岁的高斯计算出小行星的运动轨道

## 应用举例：线性最小二乘问题

- 线性最小二乘问题是回归分析中的一个基本模型，它可以表示为

$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^m (a_i^\top x - b_i)^2$$

- 记  $A = [a_1, a_2, \dots, a_m]^\top$ , 上式可以等价地写成

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- $x \in \mathbb{R}^n$  为其全局极小解当且仅当  $x$  满足

$$\nabla f(x) = A^\top(Ax - b) = 0$$

## 应用举例：数据插值

- 给定数据集  $\{a_i \in \mathbb{R}^p, b_i \in \mathbb{R}^q, i = 1, 2, \dots, m\}$ , 插值是求一个映射  $f$ , 使得

$$b_i = f(a_i), \quad i = 1, 2, \dots, m$$

- 利用线性函数  $f(a) = Xa + y$  逼近, 可以建立如下最小二乘问题

$$\min_{X \in \mathbb{R}^{q \times p}} \sum_{i=1}^m \|Xa_i + y - b_i\|^2$$

- 设  $\{\phi_i(a)\}_{i=1}^n (n \leq m)$  为插值空间的一组基, 数据插值可以写成

$$b_j = f(a_j) = \sum_{i=1}^n x_i \phi_i(a_j), \quad j = 1, 2, \dots, m$$

## 应用举例：数据插值

- 设非线性向量函数  $\phi_i(\theta) : \mathbb{R}^q \rightarrow \mathbb{R}^q$ , 并构造如下复合函数

$$f(\theta) = \phi_n(X_n\phi_{n-1}(X_{n-1}\cdots\phi_1(X_1\theta + y_1)\cdots + y_{n-1}) + y_n)$$

- 常用的有 ReLU, 即

$$\phi_i(\theta) = (\text{ReLU}(\theta_1), \text{ReLU}(\theta_2), \dots, \text{ReLU}(\theta_q))^\top, \quad i = 1, 2, \dots, n$$

$$\text{ReLU}(t) = \begin{cases} t, & t \geq 0 \\ 0, & \text{其他} \end{cases}$$

- 更多未知的非线性, 可能在更大的函数空间中得到一个更好的逼近

## 应用举例：带微分方程约束优化问题

- 当约束中含微分方程时，称为**带微分方程约束的优化问题**
- 考虑瓦斯油催化裂解生成气体和其他副产物的反应过程

$$\begin{cases} \dot{y}_1 = -(\theta_1 + \theta_3)y_1^2 \\ \dot{y}_2 = \theta_1y_1^2 - \theta_2y_2 \end{cases}$$

- 转化为最小二乘问题

$$\begin{aligned} \min_{\theta \in \mathbb{R}^3} \quad & \sum_{j=1}^n \|y(\tau_j; \theta) - z_j\|^2 \\ \text{s.t.} \quad & y(\tau; \theta) \text{满足上述方程组} \end{aligned}$$

其中  $z_j$  是在时刻  $\tau_j$  的  $y$  的测量值， $n$  为测量的时刻数量

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

## ■ 复合优化问题一般可以表示为

$$\min_{x \in \mathbb{R}^n} \psi(x) = f(x) + h(x)$$

- $f(x)$  是光滑函数, 如数据拟合项
- $h(x)$  可能是非光滑的, 如  $\ell_1$  范数正则项, 约束集合的示性函数

## ■ 常用的优化算法有

- 次梯度法
- 近似点梯度法
- Nesterov 加速法
- 交替方向乘子法

# 应用举例：信号处理

## ■ $\ell_1$ 范数正则化回归分析问题

$$\min_{x \in \mathbb{R}^n} \quad \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_1$$

## ■ 矩阵分离问题

$$\begin{aligned} \min_{X, S \in \mathbb{R}^{m \times n}} \quad & \|X\|_* + \mu \|S\|_1 \\ \text{s.t.} \quad & X + S = M \end{aligned}$$

## ■ 字典学习问题

$$\begin{aligned} \min_{X, D \in \mathbb{R}^{m \times n}} \quad & \frac{1}{2n} \|DX - A\|_F^2 + \lambda \|X\|_1 \\ \text{s.t.} \quad & \|D\|_F \leq 1 \end{aligned}$$

## 应用举例：图像去噪

- 图像去噪是指从一个带噪声的图像中恢复出不带噪声的原图
- 由全变差模型，去噪问题可表示为

$$\min_{x \in \mathbb{R}^{n \times n}} \quad \frac{1}{2} \|x - y\|_F^2 + \lambda \|x\|_{TV}$$



## 应用举例：盲反卷积

- 反卷积是从一个模糊的图像恢复出原来清晰的图像，也称为去模糊
- 反卷积问题的模型

$$y = a * x + \varepsilon$$

- 设噪声为高斯噪声，可转化为

$$\min_{a,x} \quad \frac{1}{2} \|y - a * x\|_2^2$$

- 设原始图像信号在小波变换下是稀疏的，进一步得到

$$\min_{a,x} \quad \frac{1}{2} \|y - a * x\|_2^2 + \|\lambda \odot (Wx)\|_1$$

其中  $W$  是小波框架， $\lambda = (\lambda_1, \lambda_2, \dots, \lambda_m)^\top$  用来控制稀疏度

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

# 随机优化问题

- 随机优化问题可以表示为

$$\min_{x \in \mathcal{X}} \mathbb{E}_{\xi}[F(x, \xi)] + h(x)$$

- $F(x, \xi)$  表示样本  $\xi$  上的损失或奖励
- $h(x)$  用来保证解的某种性质
- 设有  $N$  个样本  $\xi_1, \xi_2, \dots, \xi_N$ , 令  $f_i(x) = F(x, \xi_i)$ , 得到**经验风险极小化问题**

$$\min_{x \in \mathcal{X}} f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x) + h(x)$$

- 样本数  $N$  比较多, 可行域所在空间维数  $n$  比较大, 导致计算困难

## 应用举例：随机主成分分析

- 如果样本点  $\xi$  服从某个零均值分布  $\mathcal{D}$ , 则随机主成分分析可以写成

$$\max_{X \in \mathbb{R}^{p \times d}} \text{Tr}(X^\top A A^\top X) \quad \text{s.t.} \quad X^\top X = I$$

$\Downarrow$

$$\max_{X \in \mathbb{R}^{p \times d}} \text{Tr}(X^\top \mathbb{E}_{\xi \sim \mathcal{D}}[\xi \xi^\top] X) \quad \text{s.t.} \quad X^\top X = I$$

$\Downarrow$

$$\max_{X \in \mathbb{R}^{p \times d}} \frac{1}{N} \sum_{i=1}^N \text{Tr}(X^\top A_i A_i^\top X) \quad \text{s.t.} \quad X^\top X = I$$

## 应用举例：分布式鲁棒优化

- 为了提高深度学习预测器的泛化能力，考虑

$$\min_h \mathbb{E}_z[F(h, z)]$$

↓

$$\min_h \max_{\hat{z} \in \Gamma} \mathbb{E}_{\hat{z}}[F(h, \hat{z})]$$

- 集合  $\Gamma$  中随机变量的分布与真实数据的分布**在一定意义上**非常接近
- Wasserstein 距离**可以改变原来经验分布的支撑集

## Generative Adversarial Nets

---

Ian J. Goodfellow,<sup>\*</sup> Jean Pouget-Abadie,<sup>†</sup> Mehdi Mirza, Bing Xu, David Warde-Farley,  
Sherjil Ozair,<sup>†</sup> Aaron Courville, Yoshua Bengio<sup>§</sup>

The adversarial modeling framework is most straightforward to apply when the models are both multilayer perceptrons. To learn the generator's distribution  $p_g$  over data  $\mathbf{x}$ , we define a prior on input noise variables  $p_{\mathbf{z}}(\mathbf{z})$ , then represent a mapping to data space as  $G(\mathbf{z}; \theta_g)$ , where  $G$  is a differentiable function represented by a multilayer perceptron with parameters  $\theta_g$ . We also define a second multilayer perceptron  $D(\mathbf{x}; \theta_d)$  that outputs a single scalar.  $D(\mathbf{x})$  represents the probability that  $\mathbf{x}$  came from the data rather than  $p_g$ . We train  $D$  to maximize the probability of assigning the correct label to both training examples and samples from  $G$ . We simultaneously train  $G$  to minimize  $\log(1 - D(G(\mathbf{z})))$ . In other words,  $D$  and  $G$  play the following two-player minimax game with value function  $V(G, D)$ :

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]. \quad (1)$$

# 目录

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

# 半定规划

- 半定规划 (SDP) 是线性规划在矩阵空间中的一种推广
- 半定规划问题的标准形式

$$\begin{aligned} \min \quad & \langle C, X \rangle \\ \text{s.t.} \quad & \langle A_1, X \rangle = b_1 \\ & \dots \\ & \langle A_m, X \rangle = b_m \\ & X \succeq 0 \end{aligned}$$

- 对偶形式

$$\begin{aligned} \min \quad & -b^\top y \\ \text{s.t.} \quad & y_1 A_1 + y_2 A_2 + \dots + y_n A_n \preceq C \end{aligned}$$

# LP, SOCP 与 SDP 的比较

## ■ LP 与 SDP

$$\begin{array}{ll} \text{LP} & \min c^\top x \\ & \text{s.t. } Ax \leq b \end{array} \quad \begin{array}{ll} \text{SDP} & \min c^\top x \\ & \text{s.t. } \text{diag}(Ax - b) \preceq 0 \end{array}$$

## ■ SOCP 与 SDP

$$\begin{array}{ll} \text{SOCP} & \min f^\top x \\ & \text{s.t. } \|A_i x + b_i\|_2 \leq c^\top x + d_i, \quad i = 1, \dots, m \end{array}$$

$$\begin{array}{ll} \text{SDP} & \min f^\top x \\ & \text{s.t. } \begin{bmatrix} (c_i^\top x + d_i)I & A_i x + b_i \\ (A_i x + b_i)^\top & c_i^\top x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, m \end{array}$$

## 应用举例：二次约束二次规划问题的半定规划松弛

- 设  $A_i$  为  $n \times n$  对称矩阵，考虑二次约束二次规划问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & x^\top A_0 x + 2b_0^\top x + c_0 \\ \text{s.t.} \quad & x^\top A_i x + 2b_i^\top x + c_i \leq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

- 对任意  $x \in \mathbb{R}^n$  以及  $A \in \mathcal{S}^n$ , 有恒等式

$$x^\top A x = \text{Tr}(x^\top A x) = \text{Tr}(A x x^\top) = \langle A, x x^\top \rangle$$

- 原始问题等价于

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \langle A_0, X \rangle + 2b_0^\top x + c_0 \\ \text{s.t.} \quad & \langle A_i, X \rangle + 2b_i^\top x + c_i \leq 0, \quad i = 1, 2, \dots, m \\ & X = x x^\top \end{aligned}$$

# 应用举例：二次约束二次规划问题的半定规划松弛

## ■ 进一步地

$$\begin{aligned}x^\top A_i x + 2b_i^\top x + c_i &= \left\langle \begin{pmatrix} A_i & b_i \\ b_i^\top & c_i \end{pmatrix}, \begin{pmatrix} X & x \\ x^\top & 1 \end{pmatrix} \right\rangle \\&= \langle \overline{A}_i, \overline{X} \rangle, \quad i = 0, 1, \dots, m\end{aligned}$$

## ■ 半定规划松弛可以写成

$$\begin{aligned}\min \quad & \langle \overline{A}_0, \overline{X} \rangle \\ \text{s.t.} \quad & \langle \overline{A}_i, \overline{X} \rangle \leq 0, \quad i = 1, 2, \dots, m \\ & \overline{X} \succeq 0 \\ & \overline{X}_{n+1,n+1} = 1\end{aligned}$$

## ■ 约束 $X = xx^\top$ 松弛成半正定约束 $X \succeq xx^\top$ (等价于 $\overline{X} \succeq 0$ )

## 应用举例：最大割问题的半定规划松弛

- 最大割问题是找到节点集合  $V$  的一个子集  $S$  使得  $S$  与它的补集  $\bar{S}$  之间相连边的权重之和最大化
- 令  $x_j = 1, j \in S$  和  $x_j = -1, j \in \bar{S}$ , 则

$$\begin{aligned} \max \quad & \frac{1}{2} \sum_{i < j} (1 - x_i x_j) w_{ij} \\ \text{s.t.} \quad & x_j \in \{-1, 1\}, j = 1, 2, \dots, n \end{aligned}$$

- 只有当  $x_i$  与  $x_j$  不同时，目标函数中  $w_{ij}$  的系数非零
- 最大割问题是一个离散优化问题，很难在多项式时间内找到最优解

## 应用举例：最大割问题的半定规划松弛

- 令  $W = (w_{ij}) \in \mathcal{S}^n$ , 并定义  $C = -\frac{1}{4}(\text{diag}(W\mathbf{1}) - W)$ , 得到

$$\begin{aligned}\min \quad & x^\top C x \\ \text{s.t.} \quad & x_i^2 = 1, \quad i = 1, 2, \dots, n\end{aligned}$$

- 令  $X = xx^\top$ , 则最大割问题可以转化为

$$\begin{aligned}\min \quad & \langle C, X \rangle \\ \text{s.t.} \quad & X_{ii} = 1, \quad i = 1, 2, \dots, n \\ & X \succeq 0, \quad \text{rank}(X) = 1\end{aligned}$$

- $x_i^2 = 1$  意味着矩阵  $X$  对角线元素  $X_{ii} = 1$
- $X = xx^\top$  可以用约束  $X \succeq 0$  和  $\text{rank}(X) = 1$  等价刻画

# 应用举例：极小化最大特征值

- 极小化最大特征值问题可表示为

$$\min \quad \lambda_{\max}(A_0 + \sum_i x_i A_i)$$

- 由于  $\lambda_{\max}(A) \leq t \Leftrightarrow A \preceq tI$ , 则极小化最大特征值可以转化为

SDP 形式

$$\begin{aligned} \min \quad & z \\ \text{s.t.} \quad & zI - \sum_i x_i A_i \succeq A_0 \end{aligned}$$

对偶问题形式

$$\begin{aligned} \max \quad & \langle A_0, Y \rangle \\ \text{s.t.} \quad & \langle A_i, Y \rangle = 0 \\ & \langle I, Y \rangle = 1 \\ & Y \succeq 0 \end{aligned}$$

## 应用举例：极小化二范数问题

- 令  $A_i \in \mathbb{R}^{m \times n}$ , 极小化  $A(x) = A_0 + \sum_i x_i A_i$  的二范数

$$\min_x \|A(x)\|_2$$

- SDP 形式

$$\begin{aligned} & \min_{x,t} \quad t \\ \text{s.t.} \quad & \begin{pmatrix} tI & A(x) \\ A(x)^\top & tI \end{pmatrix} \succeq 0 \end{aligned}$$

- 约束形式来源于

$$\begin{aligned} \|A\|_2 \leq t & \Leftrightarrow A^\top A \preceq t^2 I, \quad t \geq 0 \\ & \Leftrightarrow \begin{pmatrix} tI & A(x) \\ A(x)^\top & tI \end{pmatrix} \succeq 0 \end{aligned}$$

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

# 矩阵优化的基本形式

## ■ 矩阵优化问题的形式

$$\min_{X \in \mathcal{X}} \psi(X)$$

- $\mathcal{X}$  为特定的矩阵空间
- $\psi(X) : \mathcal{X} \rightarrow \mathbb{R}$  为给定的函数，可能是非光滑的
- 和向量相比，矩阵有许多新的性质，如秩、特征值等
- 广泛地出现在组合数学、材料科学、机器学习和统计学等

# 矩阵优化的基本形式

## ■ 低秩矩阵恢复问题

$$\min_{X \in \mathbb{R}^{m \times n}} \quad \frac{1}{2} \|X - M\|_F^2 + \mu \|X\|_*$$

考虑函数  $h(X) = \|X\|_*$  的次微分

$$\partial h(X) = \{UV^\top + W \mid \|W\|_2 \leq 1, U^\top W = 0, WV = 0\}$$

## ■ 主成分分析问题

$$\min_{X \in \mathbb{R}^{p \times d}} \quad \psi(X) = -\text{Tr}(X^\top A A^\top X) \quad \text{s.t.} \quad X^\top X = I_d$$

考虑目标函数的微分

$$\nabla \psi(X) = -2A A^\top X$$

## 应用举例：非负矩阵分解

- 给定矩阵  $A = [a_1, a_2, \dots, a_n] \in \mathbb{R}^{d \times n}$ , 将其分解成非负基矩阵  $X \in \mathbb{R}^{d \times p}$  和非负系数矩阵  $Y \in \mathbb{R}^{p \times n}$  的乘积, 即

$$A = XY$$

- 由于观测含有噪声, 原始数据矩阵  $A$  和分解  $XY$  不会完全吻合, 应考虑

$$\begin{aligned} \min_{X \in \mathbb{R}^{d \times p}, Y \in \mathbb{R}^{p \times n}} \quad & \frac{1}{2} \|A - XY\|_F^2 \\ \text{s.t.} \quad & X \geq 0, Y \geq 0 \end{aligned}$$

- 本质上是将高维空间中的数据在一个低维空间中表示
- 和主成分分析模型类似, 但会得到比主成分分析模型更有实际意义的解

# 应用举例：非负矩阵分解

- 根据具体应用的不同，还可以考虑带正则项的非负矩阵分解模型

$$\begin{aligned} \min_{X \in \mathbb{R}^{d \times p}, Y \in \mathbb{R}^{p \times n}} \quad & \frac{1}{2} \|A - XY\|_F^2 + \alpha r_1(X) + \beta r_2(Y) \\ \text{s.t.} \quad & X \geq 0, \quad Y \geq 0 \end{aligned}$$

- $r_1(X)$  和  $r_2(Y)$  是正则项
- $\alpha, \beta > 0$  是用来权衡拟合项和正则项的正则化参数
- 如果基向量的线性无关性，取  $r_1(X) = \|X^\top X - I\|_F^2$
- 如果每一个观测值都可以用少数几个基向量来表示，取  $r_2(Y) = \|Y\|_1$

# 应用举例：非负矩阵分解

## Algorithms for non-negative matrix factorization

D Lee, HS Seung - Advances in neural information ..., 2000 - proceedings

... nonnegativity is a useful constraint for matrix factorization that can learn data [4, 5]. The nonnegative ... for learning the optimal nonnegative factor

☆ 保存 引用 被引用次数: 12260 相关文章 所有 36 个版本 »

## Learning the parts of objects by non-negative matrix fact

DD Lee, HS Seung - nature, 1999 - nature.com

... an algorithm for non-negative matrix factorization that is able to ... Non

distinguished from the ... When non-negative matrix factorization is imple

☆ 保存 引用 被引用次数: 16498 相关文章 所有 17 个版本

## 应用举例：相关系数矩阵估计

- 给定对称矩阵  $C \in \mathcal{S}^n$  和非负对称权重矩阵  $H \in \mathcal{S}^n$ , 求解一个秩小于等于  $p$  的相关系数矩阵  $X$ , 使得在结合了权重矩阵的某种度量下最小化

$$\begin{aligned} \min_{X \succeq 0} \quad & \frac{1}{2} \|H \odot (X - C)\|_F^2 \\ \text{s.t.} \quad & X_{ii} = 1, \quad i = 1, 2, \dots, n \\ & \text{rank}(X) \leq p \end{aligned}$$


- 将  $\text{rank}(X) \leq p$  表示为  $X = V^\top V$ , 其中  $V = [V_1, V_2, \dots, V_n] \in \mathbb{R}^{p \times n}$ , 得到

$$\begin{aligned} \min_{V \in \mathbb{R}^{p \times n}} \quad & \frac{1}{2} \|H \odot (V^\top V - C)\|_F^2 \\ \text{s.t.} \quad & \|V_i\|_2 = 1, \quad i = 1, 2, \dots, n \end{aligned}$$

- 3.1 线性规划
- 3.2 最小二乘问题
- 3.3 复合优化问题
- 3.4 随机优化问题
- 3.5 半定规划
- 3.6 矩阵优化
- 3.7 优化模型语言

# 优化软件发展



- 现代复杂管理系统决策的主要特点：数据驱动，规模超大，多因素制约，多目标优化
- 数据驱动的决策流程：数据-->规律-->决策
- 数学规划：基于数据驱动的决策，问题建模与求解的核心环节



智能决策中两个经典的关键科学问题：

- 1, 如何建模：将复杂决策问题翻译成简洁、有效的数学表达形式
- 2, 如何求解：快速、准确地求解数学模型

# 优化软件发展



## 线性规划

- 问题目标：在可行域寻找最优解
- 规模较大：常有数百万变量和约束
- 稀疏性质：大量的稀疏矩阵运算
- 数值问题：受计算机精度影响

## 整数规划

- 可行域是离散的点
- 是经典的“NP-完全”问题
- 复杂多样的问题结构
- 需要求解多个线性规划问题

## 二阶锥规划

## 凸二次规划

## 凸二次约束规划

.....

# 优化软件发展

## 数学理论门槛高

- 理论储备不足，基本理论框架由西方发展起来
- 求解计算模块的相关理论在国内基本空白状态
- 国内理论研究主要聚焦在数学规划在各个领域的定制化应用

## 软件工程难度大

- 数学规划的软件工程工作量巨大
- 线性5万行，整数规划百万行
- 相关的系统开发的理论研究国内极少
- 参照MATLAB

## 领域知识积累难

- Domain Knowledge欠缺
- 例：热启动的30种备选该如何从数千篇文献选取？
- 欧美积累了40多年
- 论文里不会提及，国外求解器也不会公布的不传之秘
- 只能自己一步步摸索，不断试错

## 技术创新迭代快

- 例如Gurobi研发组每年需要看3到500篇论文，但是只有5到7个技巧显著有用
- 需要自己观察与发展新的理论研究
- 更需要与新一代人工智能算法结合，软硬件结合，寻求“弯道超车”可能性

困难：投入大，周期长，工作很多时候是对欧美的追赶，很难产生论文

# 优化软件发展

## 世界著名数学规划求解器研发历程

- 1939年，苏联诺贝尔经济学奖获得者Leonid Kantorovich发明线性规划
- 1979年芝加哥大学的Charge 发布Lingo
- 1983年英国爱丁堡大学Ashford创办了XPRESS
- 1987年莱斯大学Bixby创办了CPLEX公司
- 2000年COIN-OR成立，并发布CLP和CBC
- 2005年德国ZIB发布了开源整数规划SCIP
- 2008年Cplex团队Bixby等离职创办GUROBI
- 2017年，上财发布中国第一个开源数学规划求解器LEAVES，2018年中科院 CMIP
- 2019年，杉数科技发布中国第一个专业数学规划求解器COPT，此后阿里，华为等纷纷入局
- 2021年至今，谷歌，ORACLE，微软纷纷开始组建自己的数学规划求解器团队

## 世界著名数学规划求解器一览表

GUROBI
CPLEX
XPRESS
SAS
CVX
IPOPT
Coin-OR
Baron
NEOS
CBC

美国

美国与英国三大求解器巨头，累计三十年以上研发历史和95%以上市场。线性，整数，非线性各个模块功能齐备

←世界最大商业统计软件（北卡）

←世界著名求解器建模平台(斯坦福大学)

←著名非线性规划开源软件(卡耐基梅隆)

←世界最好开源线性规划（多组织维护）

←世界最好非线性规划（多组织维护）

←世界最好整数规划(ZIB)

SCIP

SOPLEX

MOSEK

GLPK

德国

丹麦

俄罗斯

OPTV

华为

MDOPT

阿里

COPT

杉数

CMIIP

中科院

LEAVES

上财

中国

世界最大免费服务平台（威斯康星大学）

世界最好开源组织（多组织维护）

世界最好锥规划（MOSEK）

# 优化模型语言

- CVX 以 MATLAB 为基础的优化模型语言，求解凸优化问题
  - 快速构造和识别凸性
  - 调用已有软件包求解变形后的凸优化问题
  - 包括免费软件 SDPT3 和 SeDuMi 以及商业软件 Gurobi 和 MOSEK 等

The screenshot shows the homepage of the CVX Research website. The header features a blue navigation bar with the CVX logo on the left, followed by menu items: CVX, TFOCS, About us, News, CVX Forum, and links to Twitter and Google+. Below the header is a secondary navigation bar with Home, Download, Documentation, Examples, Support, Licensing, and Citing. The main content area has a white background and displays the following text:  
**CVX: Matlab Software for Disciplined Convex Programming**  
Version 2.2, January 2020, Build 1148  
A yellow callout box contains the text: "New: Professor Stephen Boyd recently recorded a video introduction to CVX for Stanford's convex optimization courses. [Click here to watch it.](#)" Another yellow callout box at the bottom contains the text: "CVX 3.0 beta: We've added some interesting new features for users and system administrators. [Give it a try!](#)"

## ■ 考虑优化问题

$$\begin{aligned} \min \quad & \|Ax - b\|_2 \\ \text{s.t.} \quad & Cx = d \\ & \|x\|_\infty \leq e \end{aligned}$$

```
1 m = 20; n = 10; p = 4;
2 A = randn(m,n); b = randn(m,1);
3 C = randn(p,n); d = randn(p,1); e = rand;
4 cvx_begin
5     variable x(n)
6     minimize( norm( A * x - b, 2 ) )
7     subject to
8         C * x == d
9         norm( x, Inf ) <= e
10    cvx_end
```

*Q&A*

*Thank you!*

感谢您的聆听和反馈