

# 第四章 最优性理论

修贤超

<https://xianchaoxiu.github.io>

- 4.1 最优化问题解的存在性
- 4.2 无约束可微问题的最优性理论
- 4.3 无约束不可微问题的最优性理论
- 4.4 对偶理论
- 4.5 一般约束优化问题的最优性理论
- 4.6 带约束凸优化问题的最优性理论
- 4.7 约束优化最优性理论应用实例

# 最优化问题解的存在性

## ■ 考虑优化问题

$$\begin{array}{ll}\min_{x \in \mathbb{R}^n} & f(x) \\ \text{s.t.} & x \in \mathcal{X}\end{array}$$

- 首先分析最优解的存在性, 然后考虑如何求出其最优解
- 回顾 Weierstrass 定理, 即定义在紧集上的连续函数一定存在最大 (最小) 值点
- 而在许多实际问题中, 定义域可能不是紧的, 目标函数也不一定连续

## 推广的 Weierstrass 定理

■ 若函数  $f: \mathcal{X} \rightarrow (-\infty, +\infty]$  适当且闭, 且以下条件中任意一个成立

□  $\text{dom } f = \{x \in \mathcal{X} : f(x) < +\infty\}$  是有界的

□ 存在一个常数  $\bar{\gamma}$  使得下水平集

$$C_{\bar{\gamma}} = \{x \in \mathcal{X} \mid f(x) \leq \bar{\gamma}\}$$

是非空且有界的

□  $f$  是强制的, 即对于任一满足  $\|x^k\| \rightarrow +\infty$  的点列  $\{x^k\} \subset \mathcal{X}$ , 都有

$$\lim_{k \rightarrow \infty} f(x^k) = +\infty,$$

则函数  $f$  的最小值点集  $\{x \in \mathcal{X} \mid f(x) \leq f(y), \forall y \in \mathcal{X}\}$  非空且紧

- 三个条件在本质上都是保证  $f(x)$  的最小值不能在无穷远处取到
- 定理仅要求  $f(x)$  为适当且闭的函数, 并不需要  $f(x)$  的连续性
- **例子** 当定义域不是有界闭集时, 对于强制函数  $f(x) = x^2$ ,  $x \in \mathcal{X} = \mathbb{R}$ , 其全局最优解一定存在
- **例子** 对于适当且闭的函数  $f(x) = e^{-x}$ ,  $x \in \mathcal{X} = \mathbb{R}$ , 不满足三个条件中任意一个, 因此不能断言其全局极小值点存在

- 4.1 最优化问题解的存在性
- 4.2 无约束可微问题的最优性理论
- 4.3 无约束不可微问题的最优性理论
- 4.4 对偶理论
- 4.5 一般约束优化问题的最优性理论
- 4.6 带约束凸优化问题的最优性理论
- 4.7 约束优化最优性理论应用实例

# 无约束可微问题的最优性理论

- 无约束可微优化问题通常表示为

$$\min_{x \in \mathbb{R}^n} f(x)$$

- 验证一个点是否为极小值点, 称其为最优性条件
  - 一阶最优性条件
  - 二阶最优性条件

# 下降方向

- 对于可微函数  $f$  和点  $x \in \mathbb{R}^n$ , 如果存在向量  $d$  满足

$$\nabla f(x)^\top d < 0$$

那么称  $d$  为  $f$  在点  $x$  处的一个下降方向

- 一阶最优性条件是利用梯度 (一阶) 信息来判断给定点的最优性
- 如果  $f$  在点  $x$  处存在一个下降方向  $d$ , 那么对于任意的  $T > 0$ , 存在  $t \in (0, T]$ , 使得

$$f(x + td) < f(x)$$

因此, 在局部最优点处不能有下降方向



# 一阶必要条件

- 假设  $f$  在全空间  $\mathbb{R}^n$  可微. 如果  $x^*$  是一个局部极小点, 那么

$$\nabla f(x^*) = 0$$

**证明** 任取  $v \in \mathbb{R}^n$ , 考虑  $f$  在点  $x = x^*$  处的泰勒展开

$$f(x^* + tv) = f(x^*) + tv^\top \nabla f(x^*) + o(t)$$

整理得

$$\frac{f(x^* + tv) - f(x^*)}{t} = v^\top \nabla f(x^*) + o(1)$$

根据  $x^*$  的最优性, 在上式中分别对  $t$  取点 0 处的左、右极限可知

$$\begin{aligned}\lim_{t \rightarrow 0^+} \frac{f(x^* + tv) - f(x^*)}{t} &= v^\top \nabla f(x^*) \geq 0 \\ \lim_{t \rightarrow 0^-} \frac{f(x^* + tv) - f(x^*)}{t} &= v^\top \nabla f(x^*) \leq 0\end{aligned}$$

即对任意的  $v$  有  $v^\top \nabla f(x^*) = 0$ , 由  $v$  的任意性知  $\nabla f(x^*) = 0$

## 二阶最优性条件

- 称满足  $\nabla f(x) = 0$  的点  $x$  为  $f$  的稳定点 (或驻点、临界点)
- 对于  $f(x) = x^3$ , 满足  $f'(x) = 0$  的点为  $x^* = 0$ , 但其不是局部最优解, 因此仅仅是必要条件, 还需要加一些额外的限制条件, 才能保证最优解的充分性
- 假设  $f$  在点  $x$  的一个开邻域内是二阶连续可微的, 考虑

$$f(x + d) = f(x) + \nabla f(x)^\top d + \frac{1}{2}d^\top \nabla^2 f(x)d + o(\|d\|^2)$$

- 当一阶必要条件满足时, 简化为

$$f(x + d) = f(x) + \frac{1}{2}d^\top \nabla^2 f(x)d + o(\|d\|^2)$$

## 二阶最优性条件

- 假设  $f$  在点  $x$  的一个开邻域内是二阶连续可微的, 则以下最优性条件成立

- **二阶必要条件** 若  $x^*$  是  $f$  的一个局部极小点, 则

$$\nabla f(x^*) = 0, \nabla^2 f(x^*) \succeq 0$$

- **二阶充分条件** 若满足

$$\nabla f(x^*) = 0, \nabla^2 f(x^*) \succ 0$$

则  $x^*$  是  $f$  的一个局部极小点

- 对于给定点的全局最优性判断还需要借助实际问题的性质

## 二阶最优性条件

- **必要性** 若  $\nabla^2 f(x^*)$  有负的特征值  $\lambda_- < 0$ , 设  $\nabla^2 f(x^*)d = \lambda_- d$ , 则

$$\frac{f(x^* + d) - f(x^*)}{\|d\|^2} = \frac{1}{2} \frac{d^\top}{\|d\|} \nabla^2 f(x^*) \frac{d}{\|d\|} + o(1) = \frac{1}{2} \lambda_- + o(1)$$

当  $\|d\|$  充分小时,  $f(x^* + d) < f(x^*)$ , 这和点  $x^*$  的最优性矛盾

- **充分性** 由  $\nabla f(x^*) = 0$  时的二阶展开,

$$\frac{f(x^* + d) - f(x^*)}{\|d\|^2} = \frac{d^\top \nabla^2 f(x^*) d + o(\|d\|^2)}{\|d\|^2} \geq \frac{1}{2} \lambda_{\min} + o(1).$$

当  $\|d\|$  充分小时有  $f(x^* + d) \geq f(x^*)$ , 即二阶充分条件成立

# 实例：实数情形的相位恢复

## ■ 考虑

$$\min_{x \in \mathbb{R}^n} f(x) = \sum_{i=1}^m r_i^2(x)$$

其中  $r_i(x) = (a_i^\top x)^2 - b_i^2, i = 1, 2, \dots, m$

## ■ 计算梯度和的海瑟矩阵

$$\nabla f(x) = 2 \sum_{i=1}^m r_i(x) \nabla r_i(x) = 4 \sum_{i=1}^m ((a_i^\top x)^2 - b_i^2) (a_i^\top x) a_i$$

$$\nabla^2 f(x) = \sum_{i=1}^m (12(a_i^\top x)^2 - 4b_i^2) a_i a_i^\top$$

- 4.1 最优化问题解的存在性
- 4.2 无约束可微问题的最优性理论
- 4.3 无约束不可微问题的最优性理论
- 4.4 对偶理论
- 4.5 一般约束优化问题的最优性理论
- 4.6 带约束凸优化问题的最优性理论
- 4.7 约束优化最优性理论应用实例

# 无约束不可微问题的最优性理论

- 仍考虑问题

$$\min_{x \in \mathbb{R}^n} f(x)$$

- $f(x)$  是不可微函数, 例如  $\|x\|_1$
- 目标函数可能不存在梯度和海瑟矩阵

# 凸优化问题一阶充要条件

- 假设  $f$  是适当且凸的函数, 则  $x^*$  为全局极小点当且仅当  $0 \in \partial f(x^*)$

□ **必要性** 因为  $x^*$  为全局极小点, 所以

$$f(y) \geq f(x^*) = f(x^*) + 0^\top (y - x^*), \quad \forall y \in \mathbb{R}^n$$

因此  $0 \in \partial f(x^*)$

□ **充分性** 如果  $0 \in \partial f(x^*)$ , 那么根据次梯度的定义

$$f(y) \geq f(x^*) + 0^\top (y - x^*) = f(x^*), \quad \forall y \in \mathbb{R}^n$$

因而  $x^*$  为一个全局极小点



# 复合优化问题的一阶必要条件

- 考虑一般复合优化问题

$$\min_{x \in \mathbb{R}^n} \quad \psi(x) = f(x) + h(x)$$

其中  $f$  为光滑函数 (可能非凸),  $h$  为凸函数 (可能非光滑)

- **定理 4.5** 令  $x^*$  为复合优化问题的一个局部极小点, 那么

$$-\nabla f(x^*) \in \partial h(x^*)$$

其中  $\partial h(x^*)$  为凸函数  $h$  在点  $x^*$  处的次梯度集合

- 由于目标函数可能是整体非凸的, 因此一般没有一阶充分条件

## 实例: $\ell_1$ 范数优化问题

### ■ 考虑

$$\min_{x \in \mathbb{R}^n} \quad \psi(x) = f(x) + \mu \|x\|_1$$

### ■ $\|x\|_1$ 不是可微的, 但可以计算其次微分

$$\partial_i \|x\|_1 = \begin{cases} \{1\}, & x_i > 0 \\ [-1, 1], & x_i = 0 \\ \{-1\}, & x_i < 0 \end{cases}$$

### ■ 若 $x^*$ 是局部最优解, 则 $-\nabla f(x^*) \in \mu \partial \|x^*\|_1$ , 即

$$\nabla_i f(x^*) = \begin{cases} -\mu, & x_i^* > 0 \\ a \in [-\mu, \mu], & x_i^* = 0 \\ \mu, & x_i^* < 0 \end{cases}$$

- 4.1 最优化问题解的存在性
- 4.2 无约束可微问题的最优性理论
- 4.3 无约束不可微问题的最优性理论
- 4.4 对偶理论
- 4.5 一般约束优化问题的最优性理论
- 4.6 带约束凸优化问题的最优性理论
- 4.7 约束优化最优性理论应用实例

## ■ 一般的约束优化问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & c_i(x) \leq 0, \quad i \in \mathcal{I} \\ & c_i(x) = 0, \quad i \in \mathcal{E} \end{aligned}$$

## ■ 可行域定义为

$$\mathcal{X} = \{x \in \mathbb{R}^n \mid c_i(x) \leq 0, \quad i \in \mathcal{I} \text{ 且 } c_i(x) = 0, \quad i \in \mathcal{E}\}$$

- 通过将  $\mathcal{X}$  的示性函数加到目标函数中可以得到无约束优化问题, 但是转化后问题的目标函数是不连续的、不可微的以及不是有限的

# 拉格朗日函数

- 拉格朗日函数  $L : \mathbb{R}^n \times \mathbb{R}_+^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$L(x, \lambda, \nu) = f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) + \sum_{i \in \mathcal{E}} \nu_i c_i(x)$$

- $\lambda_i$  为第  $i$  个不等式约束对应的拉格朗日乘子
- $\nu_i$  为第  $i$  个等式约束对应的拉格朗日乘子

- 拉格朗日对偶函数  $g : \mathbb{R}_+^m \times \mathbb{R}^p \rightarrow [-\infty, +\infty)$

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu) \\ &= \inf_{x \in \mathbb{R}^n} (f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) + \sum_{i \in \mathcal{E}} \nu_i c_i(x)) \end{aligned}$$

# 拉格朗日对偶函数

■ **引理 4.1** 若  $\lambda \geq 0$ , 则  $g(\lambda, \nu) \leq p^*$

**证明** 若  $\tilde{x} \in \mathcal{X}$ , 则

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) \leq L(\tilde{x}, \lambda, \nu) \leq f(\tilde{x})$$

对  $\tilde{x}$  取下界得

$$g(\lambda, \nu) \leq \inf_{\tilde{x} \in \mathcal{X}} f(\tilde{x}) = p^*$$

# 拉格朗日对偶问题

## ■ 拉格朗日对偶问题

$$\max_{\lambda \geq 0, \nu} g(\lambda, \nu) = \max_{\lambda \geq 0, \nu} \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu)$$

- 称  $\lambda$  和  $\nu$  为对偶变量, 设最优值为  $q^*$
- $q^*$  为  $p^*$  的最优下界, 称  $p^* - q^*$  为对偶间隙
- 拉格朗日对偶问题是一个凸优化问题
- $g = \{(\lambda, \nu) \mid \lambda \geq 0, g(\lambda, \nu) > -\infty\}$ , 称其元素为对偶可行解

例子 标准形式线性规划及其对偶

$$\begin{array}{ll} \min & c^\top x \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{array} \qquad \begin{array}{ll} \max & -b^\top \nu \\ \text{s.t.} & A^\top \nu + c \geq 0 \end{array}$$

# 弱对偶性与强对偶性

## ■ 弱对偶性 $d^* \leq p^*$

- 对凸问题与非凸问题都成立
- 可导出复杂问题的非平凡下界, 例如, SDP 问题

$$\begin{aligned} \max \quad & -\mathbf{1}^\top \nu \\ \text{s.t.} \quad & W + \text{diag}(\nu) \succeq 0 \end{aligned}$$

给出了二路划分问题的一个下界

$$\min \quad x^\top W x \quad \text{s.t.} \quad x_i^2 = 1, \quad i = 1, \dots, n$$

## ■ 强对偶性 $d^* = p^*$

- 对一般问题而言通常不成立
- (通常) 对凸问题成立
- 称保证凸问题强对偶性成立的条件为约束品性



# 适当锥与广义不等式

## ■ 称满足如下条件的锥 $K$ 为适当锥

- $K$  是凸锥
- $K$  是闭集
- $K$  是实心的 (solid), 即  $\text{int } K \neq \emptyset$
- $K$  是尖的 (pointed), 即对任意非零向量  $x$ , 若  $x \in K$ , 则  $-x \notin K$

## ■ 适当锥 $K$ 可以诱导出广义不等式, 它定义了全空间上的偏序关系

$$x \preceq_K y \Leftrightarrow y - x \in K$$

## ■ 当 $K = \mathbb{R}_+^n$ 时, $x \preceq_K y$ 是我们之前经常使用的记号 $x \leq y$


## ■ 当 $K = \mathcal{S}_+^n$ 时, $X \preceq_K Y$ 表示 $Y - X \succeq 0$ , 即 $Y - X$ 是半正定矩阵

# 对偶锥与拉格朗日乘子

- 令  $K$  为全空间  $\Omega$  的子集, 称集合

$$K^* = \{y \in \Omega \mid \langle x, y \rangle \geq 0, \forall x \in K\}$$

为其对偶锥



- 假设非负锥  $K = \mathbb{R}_+^n, \Omega = \mathbb{R}^n$ , 定义  $\langle x, y \rangle = x^\top y$ , 那么  $K^* = \mathbb{R}_+^n$
- 假设半正定锥  $K = \mathcal{S}_+^n, \Omega = \mathcal{S}^n$ , 定义

$$\langle X, Y \rangle = \text{Tr}(XY^\top)$$

可以证明

$$\langle X, Y \rangle \geq 0, \forall X \in \mathcal{S}_+^n \quad \Leftrightarrow \quad Y \in \mathcal{S}_+^n$$

即半正定锥的对偶锥仍为半正定锥

- 称满足  $K = K^*$  的锥  $K$  为**自对偶锥**

# 广义不等式约束优化问题拉格朗日函数的构造

## ■ 广义不等式约束优化问题

$$\begin{array}{ll}\min_{x \in \mathbb{R}^n} & f(x) \\ \text{s.t.} & c_i(x) \preceq_{K_i} 0, \quad i \in \mathcal{I} \\ & c_i(x) = 0, \quad i \in \mathcal{E}\end{array}$$

## ■ 拉格朗日函数

$$L(x, \lambda, \nu) = f(x) + \sum_{i \in \mathcal{I}} c_i(x) \lambda_i + \sum_{i \in \mathcal{E}} \nu_i c_i(x), \quad \lambda_i \in K_i^*, \nu_i \in \mathbb{R}$$

■ 容易验证  $L(x, \lambda, \nu) \leq f(x), \forall x \in \mathcal{X}, \lambda_i \in K_i^*, \nu_i \in \mathbb{R}$

■ 对偶函数  $g(\lambda, \nu) = \inf_{x \in \mathbb{R}^n} L(x, \lambda, \nu)$ , 对偶问题为

$$\max_{\lambda_i \in K_i^*, \nu_i \in \mathbb{R}} g(\lambda, \nu)$$

# 实例：线性规划问题的对偶

## ■ 考虑线性规划问题

$$\begin{array}{ll}\min_x & c^\top x \\ \text{s.t.} & Ax = b \\ & x \geq 0\end{array}$$

## ■ 拉格朗日函数

$$L(x, s, \nu) = c^\top x + \nu^\top (Ax - b) - s^\top x = -b^\top \nu + (A^\top \nu - s + c)^\top x$$

## ■ 对偶函数

$$g(s, \nu) = \inf_x L(x, s, \nu) = \begin{cases} -b^\top \nu, & A^\top \nu - s + c = 0 \\ -\infty, & \text{其他} \end{cases}$$

# 实例：线性规划问题的对偶

## ■ 对偶问题

$$\begin{array}{ll} \max_{s, \nu} & -b^\top \nu \\ \text{s.t.} & A^\top \nu - s + c = 0 \\ & s \geq 0 \end{array} \quad y \stackrel{-}{=} -\nu \quad \Leftrightarrow \quad \begin{array}{ll} \max_{s, y} & b^\top y \\ \text{s.t.} & A^\top y + s = c \\ & s \geq 0 \end{array}$$

## ■ 若保留约束 $x \geq 0$ , 则拉格朗日函数为

$$L(x, y) = c^\top x - y^\top (Ax - b) = b^\top y + (c - A^\top y)^\top x$$

## ■ 对偶问题需要将 $x \geq 0$ 添加到约束里

$$\max_y \{ \inf_x b^\top y + (c - A^\top y)^\top x \quad \text{s.t.} \quad x \geq 0 \} \Rightarrow \begin{array}{ll} \max_y & b^\top y \\ \text{s.t.} & A^\top y \leq c \end{array}$$

## 实例：线性规划问题的对偶

- 将  $\max b^\top y$  改写为  $\min -b^\top y$ , 对偶问题的拉格朗日函数为

$$L(y, x) = -b^\top y + x^\top (A^\top y - c) = -c^\top x + (Ax - b)^\top y$$

- 得到对偶函数

$$g(x) = \inf_y L(y, x) = \begin{cases} -c^\top x, & Ax = b \\ -\infty, & \text{其他} \end{cases}$$

- 相应的对偶问题是

$$\begin{aligned} \max_x \quad & -c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned}$$

- 该问题与原始问题完全等价, 表明线性规划问题与其对偶问题互为对偶

## 实例: $\ell_1$ 正则化问题的对偶

### ■ 考虑

$$\min_{x \in \mathbb{R}^n} \quad \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1$$

### ■ 令 $r = Ax - b$ , 问题等价于

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|r\|^2 + \mu \|x\|_1 \\ \text{s.t.} \quad & r = Ax - b \end{aligned}$$

### ■ 拉格朗日函数

$$\begin{aligned} L(x, r, \lambda) &= \frac{1}{2} \|r\|^2 + \mu \|x\|_1 - \langle \lambda, Ax - b - r \rangle \\ &= \frac{1}{2} \|r\|^2 + \lambda^\top r + \mu \|x\|_1 - (A^\top \lambda)^\top x + b^\top \lambda \end{aligned}$$



## 实例: $\ell_1$ 正则化问题的对偶

### ■ 对偶函数

$$g(\lambda) = \inf_{x,r} L(x,r,\lambda) = \begin{cases} b^\top \lambda - \frac{1}{2} \|\lambda\|^2, & \|A^\top \lambda\|_\infty \leq \mu \\ -\infty, & \text{其他} \end{cases}$$

### ■ 对偶问题

$$\begin{aligned} \max_{\lambda} \quad & b^\top \lambda - \frac{1}{2} \|\lambda\|^2 \\ \text{s.t.} \quad & \|A^\top \lambda\|_\infty \leq \mu \end{aligned}$$

# 实例：半定规划问题的对偶问题

## ■ 考虑

$$\begin{aligned} \min_{X \in \mathcal{S}^n} \quad & \langle C, X \rangle \\ \text{s.t.} \quad & \langle A_i, X \rangle = b_i, \quad i = 1, 2, \dots, m \\ & X \succeq 0 \end{aligned}$$

## ■ 拉格朗日函数

$$L(X, y, S) = \langle C, X \rangle - \sum_{i=1}^m y_i (\langle A_i, X \rangle - b_i) - \langle S, X \rangle, \quad S \succeq 0$$

# 半定规划对偶问题的对偶问题

## ■ 对偶函数

$$g(y, S) = \inf_X L(X, y, S) = \begin{cases} b^\top y, & \sum_{i=1}^m y_i A_i - C + S = 0 \\ -\infty, & \text{其他} \end{cases}$$

## ■ 对偶问题

$$\begin{aligned} \min_{y \in \mathbb{R}^m} \quad & -b^\top y \\ \text{s.t.} \quad & \sum_{i=1}^m y_i A_i - C + S = 0 \\ & S \succeq 0 \end{aligned}$$

*Q&A*

*Thank you!*

感谢您的聆听和反馈