

第六章 约束优化算法

修贤超

<https://xianchaoxiu.github.io>

■ 6.1 罚函数法

■ 6.2 增广拉格朗日函数法

约束优化问题

■ 考虑约束优化问题

$$\begin{array}{ll}\min_{x \in \mathbb{R}^n} & f(x) \\ \text{s.t.} & x \in \mathcal{X}\end{array}$$

■ 相比于无约束问题的困难

- x 不能随便取值, 梯度下降法所得点不一定在可行域内
- 最优解处目标函数的梯度不一定为零向量

■ 将约束优化问题转化为无约束优化问题处理

- 罚函数法
- 增广拉格朗日函数法

等式约束的二次罚函数法

- 考虑仅包含等式约束的约束优化问题

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i \in \mathcal{E} \end{aligned}$$

- **定义 6.1** 定义二次罚函数为

$$P_E(x, \sigma) = f(x) + \frac{1}{2}\sigma \sum_{i \in \mathcal{E}} c_i^2(x)$$

其中等式右端第二项称为**罚函数**, $\sigma > 0$ 称为**罚因子**

- 对不满足约束的点进行惩罚, 被称为**外点罚函数**



例 6.1

■ 考虑优化问题

$$\begin{array}{ll}\min & x + \sqrt{3}y \\ \text{s.t.} & x^2 + y^2 = 1\end{array}$$

■ 容易求得最优解为 $(-\frac{1}{2}, -\frac{\sqrt{3}}{2})^\top$

■ 考虑二次罚函数 $P_E(x, y, \sigma) = x + \sqrt{3}y + \frac{\sigma}{2}(x^2 + y^2 - 1)^2$



例 6.2

- 考虑优化问题

$$\begin{array}{ll}\min & -x^2 + 2y^2 \\ \text{s.t.} & x = 1\end{array}$$

- 容易求得最优解为 $(1, 0)^\top$, 然而考虑罚函数

$$P_E(x, y, \sigma) = -x^2 + 2y^2 + \frac{\sigma}{2}(x - 1)^2$$

- 对任意的 $\sigma \leq 2$, 罚函数无下界

二次罚函数算法

算法 6.1 二次罚函数法

```
1 给定  $\sigma_1 > 0, x_0, k \leftarrow 1$ . 罚因子增长系数  $\rho > 1$   
2 while 未达到收敛准则 do  
3 以  $x^k$  为初始点, 求解  $x^{k+1} = \arg \min_x P_E(x, \sigma_k)$   
4 选取  $\sigma^{k+1} = \rho \sigma_k$   
5  $k \leftarrow k + 1$   
6 end while
```

=====

- σ_k 增长过快会使子问题求解困难, σ_k 增长过慢则会增加迭代次数
- 检测到迭代点发散就应该立即终止迭代并增大罚因子
- 为保证收敛, 子问题求解误差需要趋于零

分析 KKT 条件

■ 原问题的 KKT 条件

$$\begin{aligned}\nabla f(x^*) - \sum_{i \in \mathcal{E}} \lambda_i^* \nabla c_i(x^*) &= 0 \\ c_i(x^*) &= 0, \quad \forall i \in \mathcal{E}\end{aligned}$$

■ 添加罚函数项问题的 KKT 条件

$$\nabla f(x) + \sum_{i \in \mathcal{E}} \sigma c_i(x) \nabla c_i(x) = 0$$

■ 假设两个问题收敛到同一点, 对比 KKT 条件式成立

$$\sigma c_i(x) \approx -\lambda_i^*, \quad \forall i \in \mathcal{E}$$

■ 为使约束 $c_i(x) = 0$ 成立, 需要 $\sigma \rightarrow \infty$

- 考虑罚函数 $P_E(x, \sigma)$ 的海瑟矩阵

$$\nabla_{xx}^2 P_E(x, \sigma) = \nabla^2 f(x) + \sum_{i \in \mathcal{E}} \sigma c_i(x) \nabla^2 c_i(x) + \sigma \nabla c(x) \nabla c(x)^\top$$

\Downarrow

$$\nabla_{xx}^2 P_E(x, \sigma) \approx \nabla_{xx}^2 L(x, \lambda^*) + \sigma \nabla c(x) \nabla c(x)^\top$$

- $\nabla_{xx}^2 P_E(x, \sigma)$ 条件数越来越大, 子问题的难度也会相应地增加
- 在实际应用中, 不可能令罚因子趋于正无穷

收敛性分析

■ **定理 6.1** 设 x^{k+1} 是 $P_E(x, \sigma_k)$ 的全局极小解, σ_k 单调上升趋于无穷, 则 x^k 的每个极限点 x^* 都是原问题的全局极小解

证明 设 \bar{x} 为原问题的极小解. 由 x^{k+1} 为 $P_E(x, \sigma_k)$ 的极小解, 得 $P_E(x^{k+1}, \sigma_k) \leq P_E(\bar{x}, \sigma_k)$, 即

$$f(x^{k+1}) + \frac{\sigma_k}{2} \sum_{i \in \mathcal{E}} c_i^2(x^{k+1}) \leq f(\bar{x}) + \frac{\sigma_k}{2} \sum_{i \in \mathcal{E}} c_i^2(\bar{x}) = f(\bar{x})$$

\Downarrow

$$\sum_{i \in \mathcal{E}} c_i^2(x^{k+1}) \leq \frac{2}{\sigma_k} (f(\bar{x}) - f(x^{k+1}))$$

设 x^* 是 x^k 的一个极限点, 令 $k \rightarrow \infty$, 得 $\sum_{i \in \mathcal{E}} c_i^2(x^*) = 0$. 易知 x^* 为原问题的可行解, 又 $f(x^{k+1}) \leq f(\bar{x})$, 取极限得 $f(x^*) \leq f(\bar{x})$, 故 x^* 为全局极小解

收敛性分析

- **定理 6.2** 设 $f(x)$ 与 $c_i(x)$ ($i \in \mathcal{E}$) 连续可微, 正数序列 $\varepsilon_k \rightarrow 0$, $\sigma_k \rightarrow +\infty$. 子问题的解 x^{k+1} 满足

$$\|\nabla_x P_E(x^{k+1}, \sigma_k)\| \leq \varepsilon_k$$

而对 x^k 的任何极限点 x^* , 都有 $\{\nabla c_i(x^*), i \in \mathcal{E}\}$ 线性无关, 则 x^* 是等式约束最优化问题的 KKT 点, 且

$$\lim_{k \rightarrow \infty} (-\sigma_k c_i(x^{k+1})) = \lambda_i^*, \quad \forall i \in \mathcal{E}$$

其中 λ_i^* 是约束 $c_i(x^*) = 0$ 对应的拉格朗日乘子

- 精确求解 \Rightarrow 精度需要越来越高

一般约束问题的二次罚函数法

■ 考虑一般约束问题

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & c_i(x) = 0, \quad i \in \mathcal{E} \\ & c_i(x) \leq 0, \quad i \in \mathcal{I}\end{array}$$

■ 定义二次罚函数

$$P(x, \sigma) = f(x) + \frac{1}{2}\sigma \left[\sum_{i \in \mathcal{E}} c_i^2(x) + \sum_{i \in \mathcal{I}} \tilde{c}_i^2(x) \right]$$

其中 $\tilde{c}_i(x) = \max\{c_i(x), 0\}$

二次罚函数法的优缺点

■ 优点

- 将约束优化问题转化为无约束优化问题
- 二次罚函数形式简洁直观广泛使用

■ 缺点

- 需要 $\sigma \rightarrow \infty$, 导致海瑟矩阵条件数过大
- 对于不等式约束的问题可能不存在二次可微性质, 光滑性降低
- 不精确, 与原问题最优解存在距离

应用举例: LASSO 问题

- 考虑 LASSO 问题

$$\min_x \quad \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1$$

以及基追踪 (BP) 问题

$$\begin{aligned} \min \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

- 写成二次罚函数法形式

$$\min_x \quad \|x\|_1 + \frac{\sigma}{2} \|Ax - b\|^2$$

- 仅在 μ 趋于 0 时, LASSO 问题的解收敛于 BP 问题的解

- 当 μ 较小时问题病态, 收敛较慢, 可逐渐缩小 μ 的值求解子问题逼近



LASSO 问题罚函数法算法

```
1 给定 初值  $x_0$ , 最终参数  $\mu$ , 初始参数  $\mu_0$ , 因子  $\gamma \in (0, 1), k \leftarrow 0$   
2 while  $\mu_k \geq \mu$  do  
3 以  $x^k$  为初值, 求解问题  $x^{k+1} = \arg \min_x \{ \frac{1}{2} \|Ax - b\|^2 + \mu_k \|x\|_1 \}$   
4 if  $\mu_k = \mu$  then  
5 停止迭代, 输出  $x^{k+1}$   
6 else  
7 更新罚因子  $\mu_{k+1} = \max\{\mu, \gamma\mu_k\}$   
8  $k \leftarrow k + 1$   
9 end if  
10 end while
```

LASSO 问题——对比罚函数法和次梯度法

■ 次梯度法 $\mu = 10^{-3}$

■ 罚函数法 $\mu^0 = 10, \quad \gamma = 0.1, \quad \alpha = 0.0002$



其他类型的罚函数法：内点罚函数法

- 考虑不等式约束问题

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & c_i(x) \leq 0, \quad i \in \mathcal{I}\end{array}$$

- **定义 6.4** 定义对数罚函数

$$P_I(x, \sigma) = f(x) - \sigma \sum_{i \in \mathcal{I}} \ln(-c_i(x))$$

- 始终要求自变量 x 不能违反约束，适用于不等式约束优化问题
- 当 x 趋于可行域边界时， $P_I(x, \sigma)$ 会趋于正无穷，这说明对数罚函数的极小值严格位于可行域内部，应调整罚因子 σ 使其趋于 0

对数罚函数法算法

算法 6.3 对数罚函数法

```
1 给定  $\sigma_0 > 0$ , 可行解  $x^0$ ,  $k \leftarrow 0$ . 罚因子缩小系数  $\rho \in (0, 1)$   
2 while 未达到收敛准则 do  
3 以  $x^k$  为初始点, 求解  $x^{k+1} = \arg \min_x P_I(x, \sigma_k)$   
4 选取  $\sigma_{k+1} = \rho \sigma_k$   
5  $k \leftarrow k + 1$   
6 end while  
=====
```

- 初始点 x^0 必须是一个可行点
- 当 σ 趋于 0 时存在数值困难
- 常用的收敛准则 $|\sigma_k \sum_{i \in \mathcal{I}} \ln(-c_i(x^{k+1}))| \leq \varepsilon$



例 6.3

■ 考虑优化问题

$$\begin{aligned} \min \quad & x^2 + 2xy + y^2 + 2x - 2y \\ \text{s.t.} \quad & x \geq 0, y \geq 0 \end{aligned}$$

■ 容易求得最优解为 $(0, 1)$, 考虑对数罚函数 $(\sigma = 1, \sigma = 0.1)$

$$P_I(x, y, \sigma) = x^2 + 2xy + y^2 + 2x - 2y - \sigma(\ln x + \ln y)$$



其他类型的罚函数法：精确罚函数法

- 二次罚函数存在数值困难，并与原问题的解存在误差
- 精确罚函数是一种问题求解时不需要令罚因子趋于正无穷（或零）的罚函数
- **定义 6.5** 一般约束优化问题的 ℓ_1 罚函数

$$P(x, \sigma) = f(x) + \sigma \left[\sum_{i \in \mathcal{E}} |c_i(x)| + \sum_{i \in \mathcal{I}} \tilde{c}_i(x) \right]$$

- **定理 6.3** 设 x^* 是一般约束优化问题的一个严格局部极小解，且满足 KKT 条件，其对应的拉格朗日乘子为 $\lambda_i^*, i \in \mathcal{E} \cup \mathcal{I}$ ，则**当罚因子 $\sigma > \sigma^*$ 时**， x^* 也为 $P(x, \sigma)$ 的一个局部极小解，其中

$$\sigma^* = \|\lambda^*\|_\infty \stackrel{\text{def}}{=} \max_i |\lambda_i^*|$$

精确罚函数算法

```
1 给定  $\sigma_1 > 0, x_0, k \leftarrow 1$ . 罚因子增长系数  $\rho > 1$   
2 while 未达到收敛准则 do  
3 以  $x^k$  为初始点, 求解  
   
$$x^{k+1} = \arg \min_x \{f(x) + \sigma [\sum_{i \in \mathcal{E}} |c_i(x)| + \sum_{i \in \mathcal{I}} \tilde{c}_i(x)]\}$$
  
4 选取  $\sigma_{k+1} = \rho \sigma_k$   
5  $k \leftarrow k + 1$   
6 end while  
=====
```

- 初始罚因子过小, 迭代次数增加
- 初始罚因子过大, 子问题求解困难

Q&A

Thank you!

感谢您的聆听和反馈