

# 第七章 复合优化算法

修贤超

<https://xianchaoxiu.github.io>

- 7.1 近似点梯度法
- 7.2 Nesterov 加速算法
- 7.3 近似点算法
- 7.4 分块坐标下降法
- 7.5 对偶算法
- 7.6 交替方向乘子法
- 7.7 随机优化算法

# 典型问题形式

- 考虑如下凸问题

$$\begin{aligned} \min_{x_1, x_2} \quad & f_1(x_1) + f_2(x_2) \\ \text{s.t.} \quad & A_1 x_1 + A_2 x_2 = b \end{aligned} \tag{1}$$

- $f_1, f_2$  是适当的闭凸函数，但不要求是光滑的
- 目标函数可以分成彼此分离的两块，但是变量被线性约束结合在一起

## ■ 例 7.13 可以分成两块人无约束优化问题

$$\min_x f_1(x) + f_2(x)$$

引入一个新的变量  $z$  并令  $x = z$ , 将问题转化为

$$\begin{aligned} \min_{x,z} \quad & f_1(x) + f_2(z) \\ \text{s.t.} \quad & x - z = 0 \end{aligned}$$

## ■ 例 7.14 带线性变换的无约束优化问题

$$\min_x f_1(x) + f_2(Ax)$$

引入一个新的变量  $z$ , 令  $z = Ax$ , 则问题变为

$$\begin{aligned} \min_{x,z} \quad & f_1(x) + f_2(z) \\ \text{s.t.} \quad & Ax - z = 0 \end{aligned}$$

- 例 7.15 凸集  $C \subset \mathbb{R}^n$  上的约束优化问题

$$\begin{array}{ll}\min_x & f(x) \\ \text{s.t.} & Ax \in C\end{array}$$

引入约束  $z = Ax$ , 那么问题转化为

$$\begin{array}{ll}\min_{x,z} & f(x) + I_C(z) \\ \text{s.t.} & Ax - z = 0\end{array}$$

## ■ 例 7.16 全局一致性问题

$$\min_x \sum_{i=1}^N \phi_i(x)$$

令  $x = z$ , 并将  $x$  复制  $N$  份, 分别为  $x_i$ , 那么问题转化为

$$\begin{aligned} \min_{x_i, z} \quad & \sum_{i=1}^N \phi_i(x_i) \\ \text{s.t.} \quad & x_i - z = 0, \quad i = 1, 2, \dots, N \end{aligned}$$

# 增广拉格朗日函数法

- 首先写出问题(1)的增广拉格朗日函数

$$L_{\rho}(x_1, x_2, y) = f_1(x_1) + f_2(x_2) + y^{\top}(A_1x_1 + A_2x_2 - b) + \frac{\rho}{2}\|A_1x_1 + A_2x_2 - b\|_2^2$$

- 增广拉格朗日函数法为如下更新

$$(x_1^{k+1}, x_2^{k+1}) = \arg \min_{x_1, x_2} L_{\rho}(x_1, x_2, y^k)$$
$$y^{k+1} = y^k + \tau \rho (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b)$$

# 交替方向乘子法

- Alternating direction method of multipliers, ADMM
- 同时对  $x_1$  和  $x_2$  进行优化有时候比较困难，而固定一个变量求解关于另一个变量的极小问题可能比较简单
- 其迭代格式可以总结如下

$$x_1^{k+1} = \arg \min_{x_1} L_\rho(x_1, x_2^k, y^k)$$

$$x_2^{k+1} = \arg \min_{x_2} L_\rho(x_1^{k+1}, x_2, y^k)$$

$$y^{k+1} = y^k + \tau \rho (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b)$$



# 原问题最优性条件

- 问题(1)的拉格朗日函数为

$$L(x_1, x_2, y) = f_1(x_1) + f_2(x_2) + y^\top (A_1 x_1 + A_2 x_2 - b)$$

- 根据最优性条件定理, 若  $x_1^*, x_2^*$  为问题(1)的最优解,  $y^*$  为对应的拉格朗日乘子, 则以下条件满足

$$0 \in \partial_{x_1} L(x_1^*, x_2^*, y^*) = \partial f_1(x_1^*) + A_1^\top y^* \quad (2a)$$

$$0 \in \partial_{x_2} L(x_1^*, x_2^*, y^*) = \partial f_2(x_2^*) + A_2^\top y^* \quad (2b)$$

$$A_1 x_1^* + A_2 x_2^* = b \quad (2c)$$

- 条件(2c)又称为原始可行性条件, 条件(2a)和条件(2b)又称为对偶可行性条件

# ADMM 单步迭代最优性条件

- 由  $x_2$  的更新步骤

$$x_2^k = \arg \min_x \left\{ f_2(x) + \frac{\rho}{2} \|A_1 x_1^k + A_2 x - b + \frac{y^{k-1}}{\rho}\|^2 \right\}$$

- 根据最优性条件推出

$$0 \in \partial f_2(x_2^k) + A_2^\top [y^{k-1} + \rho(A_1 x_1^k + A_2 x_2^k - b)]$$

- 当  $\tau = 1$  时知

$$0 \in \partial f_2(x_2^k) + A_2^\top y^k$$

# ADMM 单步迭代最优性条件

- 由  $x_1$  的更新公式

$$x_1^k = \arg \min_x \left\{ f_1(x) + \frac{\rho}{2} \|A_1 x + A_2 x_2^{k-1} - b + \frac{y^{k-1}}{\rho}\|^2 \right\}$$

- 假设子问题能精确求解，根据最优性条件

$$0 \in \partial f_1(x_1^k) + A_1^\top [\rho(A_1 x_1^k + A_2 x_2^{k-1} - b) + y^{k-1}]$$

- 当  $\tau = 1$  时知

$$0 \in \partial f_1(x_1^k) + A_1^\top (y^k + \rho A_2 (x_2^{k-1} - x_2^k))$$

## ADMM 单步迭代最优性条件

- 对比条件(2a)可知多出来的项为  $A_1^\top A_2(x_2^{k-1} - x_2^k)$ , 因此要检测对偶可行性只需要检测残差

$$s^k = A_1^\top A_2(x_2^{k-1} - x_2^k)$$

- 综上当  $x_2$  更新取到精确解且  $\tau = 1$  时, 判断 ADMM 是否收敛只需要检测前述两个残差  $r^k, s^k$  是否充分小

$$0 \approx \|r^k\| = \|A_1 x_1^k + A_2 x_2^k - b\| \quad (\text{原始可行性})$$

$$0 \approx \|s^k\| = \|A_1^\top A_2(x_2^{k-1} - x_2^k)\| \quad (\text{对偶可行性})$$

- 线性化技巧使用近似点项对子问题目标函数进行二次近似
- 考虑第一个子问题

$$\min_{x_1} f_1(x_1) + \frac{\rho}{2} \|A_1 x_1 - v^k\|^2$$

- 当子问题目标函数可微时，线性化为

$$x_1^{k+1} = \arg \min_{x_1} \left\{ (\nabla f_1(x_1^k) + \rho A_1^\top (A_1 x_1^k - v^k))^\top x_1 + \frac{1}{2\eta_k} \|x_1 - x^k\|_2^2 \right\}$$

这等价于做一步梯度下降

- 当目标函数不可微时，可以考虑只将二次项线性化

$$x_1^{k+1} =_{x_1} \left\{ f_1(x_1) + \rho (A_1^\top (A_1 x_1^k - v^k))^\top x_1 + \frac{1}{2\eta_k} \|x_1 - x^k\|_2^2 \right\}$$

这等价于做一步近似点梯度步

## 缓存分解

- 如果目标函数中含二次函数, 例如  $f_1(x_1) = \frac{1}{2}\|Cx_1 - d\|_2^2$ , 那么针对  $x_1$  的更新等价于求解线性方程组

$$(C^\top C + \rho A_1^\top A_1)x_1 = C^\top d + \rho A_1^\top v^k$$

- 虽然子问题有显式解, 但是每步求解的复杂度仍然比较高
- 首先对  $C^\top C + \rho A_1^\top A_1$  进行 Cholesky 分解并缓存分解的结果, 在每步迭代中只需求解简单的三角形方程组
- 当  $\rho$  发生更新时, 就要重新进行分解. 特别地, 当  $C^\top C + \rho A_1^\top A_1$  一部分容易求逆, 另一部分是低秩的情形时, 可以用 SMW 公式来求逆

# 优化转移

- 为了方便求解子问题，可以用一个性质好的矩阵  $D$  近似二次项  $A_1^\top A_1$ ，此时子问题可替换为

$$x_1^{k+1} = \arg \min_{x_1} \left\{ f_1(x_1) + \frac{\rho}{2} \|A_1 x_1 - v^k\|_2^2 + \frac{\rho}{2} (x_1 - x^k)^\top (D - A_1^\top A_1) (x_1 - x^k) \right\}.$$

这种方法也称为**优化转移**

- 通过选取合适的  $D$ ，当计算  $\arg \min_{x_1} \left\{ f_1(x_1) + \frac{\rho}{2} x_1^\top D x_1 \right\}$  明显比计算  $\arg \min_{x_1} \{ f_1(x_1) + \frac{\rho}{2} x_1^\top A_1^\top A_1 x_1 \}$  要容易时，优化转移简化子问题的计算
- 特别地，当  $D = \frac{\eta_k}{\rho} I$  时，优化转移等价于做单步的近似点梯度步

## 二次罚项系数的动态调节

- 原始可行性和对偶可行性分别用  $\|r^k\|$  和  $\|s^k\|$  度量
- 求解过程中二次罚项系数  $\rho$  太大会导致原始可行性  $\|r^k\|$  下降很快，但是对偶可行性  $\|s^k\|$  下降很慢；二次罚项系数太小，则会有相反的效果。这样都会导致收敛比较慢或得到的解的可行性很差。
- 在每次迭代时动态调节惩罚系数  $\rho$  的大小，从而使得原始可行性和对偶可行性能够以比较一致的速度下降到零

$$\rho^{k+1} = \begin{cases} \gamma_p \rho^k, & \|r^k\| > \mu \|s^k\| \\ \rho^k / \gamma_d & \|s^k\| > \mu \|r^k\| \\ \rho^k, & \text{其他} \end{cases}$$

- 常见的选择为  $\mu = 10, \gamma_p = \gamma_d = 2$



# 多块问题的 ADMM

## ■ 考虑有多块变量的情形

$$\begin{aligned} \min_{x_1, x_2, \dots, x_N} \quad & f_1(x_1) + f_2(x_2) + \dots + f_N(x_N) \\ \text{s.t.} \quad & A_1 x_1 + A_2 x_2 + \dots + A_N x_N = b \end{aligned}$$

## ■ 多块 ADMM 迭代格式为

$$\begin{aligned} x_1^{k+1} &= \arg \min_x L_\rho(x, x_2^k, \dots, x_N^k, y^k) \\ x_2^{k+1} &= \arg \min_x L_\rho(x_1^{k+1}, x, \dots, x_N^k, y^k) \\ &\dots\dots\dots \\ x_N^{k+1} &= \arg \min_x L_\rho(x_1^{k+1}, x_2^{k+1}, \dots, x, y^k) \\ y^{k+1} &= y^k + \tau \rho(A_1 x_1^{k+1} + A_2 x_2^{k+1} + \dots + A_N x_N^{k+1} - b) \end{aligned}$$

其中  $\tau \in (0, (\sqrt{5} + 1)/2)$  为步长参数

## 应用举例: LASSO 问题

### ■ 考虑 LASSO 问题

$$\min \quad \mu \|x\|_1 + \frac{1}{2} \|Ax - b\|^2$$

### ■ 转换为标准问题形式

$$\begin{aligned} \min_{x,z} \quad & \frac{1}{2} \|Ax - b\|^2 + \mu \|z\|_1 \\ \text{s.t.} \quad & x = z \end{aligned}$$

### ■ 交替方向乘子法迭代格式为

$$\begin{aligned} x^{k+1} &= \arg \min_x \left\{ \frac{1}{2} \|Ax - b\|^2 + \frac{\rho}{2} \|x - z^k + y^k / \rho\|_2^2 \right\} \\ &= (A^\top A + \rho I)^{-1} (A^\top b + \rho z^k - y^k) \end{aligned} \tag{3}$$

- 交替方向乘子法迭代格式为

$$\begin{aligned} z^{k+1} &= \arg \min_z \left\{ \mu \|z\|_1 + \frac{\rho}{2} \|x^{k+1} - z + y^k / \rho\|^2 \right\} \\ &= \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left( x^{k+1} + y^k / \rho \right) \\ y^{k+1} &= y^k + \tau \rho (x^{k+1} - z^{k+1}) \end{aligned}$$

- 在求解  $x$  迭代时, 可以使用固定的罚因子  $\rho$ , 缓存矩阵  $A^\top A + \rho I$  的初始分解
- 主要运算量来自更新  $x$  变量时求解线性方程组, 复杂度为  $O(n^3)$

## 应用举例: LASSO 问题

- 考虑 LASSO 问题的对偶问题

$$\begin{aligned} \min \quad & b^\top y + \frac{1}{2} \|y\|^2 \\ \text{s.t.} \quad & \|A^\top y\|_\infty \leq \mu \end{aligned}$$

- 引入约束  $A^\top y + z = 0$ , 可以得到如下等价问题

$$\begin{aligned} \min \quad & \underbrace{b^\top y + \frac{1}{2} \|y\|^2}_{f(y)} + \underbrace{I_{\|z\|_\infty \leq \mu}(z)}_{h(z)} \\ \text{s.t.} \quad & A^\top y + z = 0 \end{aligned}$$

- 对约束  $A^\top y + z = 0$  引入乘子  $x$ , 对偶问题的增广拉格朗日函数为

$$L_\rho(y, z, x) = b^\top y + \frac{1}{2} \|y\|^2 + I_{\|z\|_\infty \leq \mu}(z) - x^\top (A^\top y + z) + \frac{\rho}{2} \|A^\top y + z\|^2$$

## 应用举例: LASSO 问题

- 当固定  $y, x$  时, 对  $z$  的更新即向无穷范数球  $\{z \mid \|z\|_\infty \leq \mu\}$  做欧几里得投影, 即将每个分量截断在区间  $[-\mu, \mu]$  中
- 当固定  $z, x$  时, 对  $y$  的更新即求解线性方程组

$$(I + \rho AA^\top)y = A(x^k - \rho z^{k+1}) - b$$

- ADMM 迭代格式为

$$\begin{aligned} z^{k+1} &= \mathcal{P}_{\|z\|_\infty \leq \mu} \left( x^k / \rho - A^\top y^k \right) \\ y^{k+1} &= (I + \rho AA^\top)^{-1} (A(x^k - \rho z^{k+1}) - b) \\ x^{k+1} &= x^k - \tau \rho (A^\top y^{k+1} + z^{k+1}) \end{aligned}$$

- 由于  $m \ll n$ , 求解  $y$  更新的线性方程组需要的计算量是  $O(m^3)$

## 应用举例：矩阵分离问题

### ■ 考虑矩阵分离问题

$$\begin{aligned} \min_{X,S} \quad & \|X\|_* + \mu\|S\|_1 \\ \text{s.t.} \quad & X + S = M \end{aligned}$$

### ■ 引入乘子 $Y$ 作用在约束 $X + S = M$ 上，得到增广拉格朗日函数

$$L_\rho(X, S, Y) = \|X\|_* + \mu\|S\|_1 + \langle Y, X + S - M \rangle + \frac{\rho}{2}\|X + S - M\|_F^2$$

### ■ 对于 $X$ 子问题

$$\begin{aligned} X^{k+1} &= \arg \min_X L_\rho(X, S^k, Y^k) \\ &= \arg \min_X \left\{ \|X\|_* + \frac{\rho}{2} \left\| X + S^k - M + \frac{Y^k}{\rho} \right\|_F^2 \right\} \\ &= \arg \min_X \left\{ \frac{1}{\rho} \|X\|_* + \frac{1}{2} \left\| X + S^k - M + \frac{Y^k}{\rho} \right\|_F^2 \right\} \\ &= U \text{Diag}(\text{prox}_{(1/\rho)\|\cdot\|_1}(\sigma(A))) V^\top \end{aligned}$$

其中  $A = M - S^k - \frac{Y^k}{\rho}$ ,  $\sigma(A)$  为  $A$  的所有非零奇异值构成的向量并且  $U \text{Diag}(\sigma(A)) V^\top$  为  $A$  的约化奇异值分解

### ■ 对于 $S$ 子问题

$$\begin{aligned} S^{k+1} &= \arg \min_S L_\rho(X^{k+1}, S, Y^k) \\ &= \arg \min_S \left\{ \mu \|S\|_1 + \frac{\rho}{2} \|X^{k+1} + S - M + \frac{Y^k}{\rho}\|_F^2 \right\} \\ &= \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left( M - X^{k+1} - \frac{Y^k}{\rho} \right) \end{aligned}$$

### ■ 交替方向乘子法的迭代格式为

$$\begin{aligned} X^{k+1} &= U \text{Diag}(\text{prox}_{(1/\rho)\|\cdot\|_1}(\sigma(A))) V^\top \\ S^{k+1} &= \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left( M - L^{k+1} - \frac{Y^k}{\rho} \right) \\ Y^{k+1} &= Y^k + \tau \rho (X^{k+1} + S^{k+1} - M) \end{aligned}$$



# 应用举例：全局一致性优化问题

## ■ 考虑全局一致性优化问题

$$\begin{aligned} \min_{x_i, z} \quad & \sum_{i=1}^N \phi_i(x_i) \\ \text{s.t.} \quad & x_i - z = 0, \quad i = 1, 2, \dots, N \end{aligned}$$

## ■ 增广拉格朗日函数为

$$L_\rho(x_1, \dots, x_N, z, y_1, \dots, y_N) = \sum_{i=1}^N \phi_i(x_i) + \sum_{i=1}^N y_i^\top (x_i - z) + \frac{\rho}{2} \sum_{i=1}^N \|x_i - z\|^2$$

## ■ 固定 $z^k, y_i^k$ , 更新 $x_i$ 的公式为

$$x_i^{k+1} = \arg \min_x \left\{ \phi_i(x) + \frac{\rho}{2} \|x - z^k + y_i^k / \rho\|^2 \right\}$$

## 应用举例：全局一致性优化问题

- 在一般情况下更新  $x_i$  的表达式为

$$x_i^{k+1} = \text{prox}_{\phi_i/\rho}(z^k - y_i^k/\rho)$$

- 固定  $x_i^{k+1}, y_i^k$ , 关于  $z$  可以直接写出显式解

$$z^{k+1} = \frac{1}{N} \sum_{i=1}^N (x_i^{k+1} + y_i^k/\rho)$$

- 交替方向乘子法迭代格式为

$$x_i^{k+1} = \text{prox}_{\phi_i/\rho}(z^k - y_i^k/\rho), \quad i = 1, 2, \dots, N$$

$$z^{k+1} = \frac{1}{N} \sum_{i=1}^N (x_i^{k+1} + y_i^k/\rho)$$

$$y_i^{k+1} = y_i^k + \tau\rho(x_i^{k+1} - z^{k+1}), \quad i = 1, 2, \dots, N$$

*Q&A*

*Thank you!*

感谢您的聆听和反馈